

FIAP - Faculdade de Informática e Administração Paulista



CardiolA — Fase 1: Batimentos de Dados

Grupo Aura

Integrantes:

- Murilo Salla — RM568041
- Elias da Silva de Souza — RM568500
- Julia Duarte de Carvalho — RM567816

Professores:

Tutor(a)

- Leonardo Ruiz Orabona

Coordenador(a)

- André Godoi Chiovato

Descrição

O **CardioIA** é um projeto acadêmico da FIAP que simula, ao longo de 7 fases, um ecossistema de cardiologia inteligente, integrando dados clínicos, IoT, Machine Learning, Visão Computacional e NLP para apoiar o cuidado cardiovascular. Nesta **Fase 1 — "Batimentos de Dados: Mapeando o Coração Moderno"**, o papel assumido pela equipe é o de cientista de dados hospitalar: buscar, organizar, validar e documentar três tipos de dados fundamentais para a saúde cardiovascular — numéricos, textuais e visuais — que servirão de base para as fases seguintes do curso (diagnóstico automatizado por IA, monitoramento via IoT, visão computacional em exames e assistente virtual por NLP).

O repositório está disponível em github.com/murilosalla-blip/fiap-ano02-fase01-cap01-cardioia.

Parte 1 — Dados Numéricos: utiliza o dataset público *Heart Disease (Cleveland)*, do UCI Machine Learning Repository (303 registros, 14 variáveis clínicas — idade, sexo, pressão arterial, colesterol, sintomas, frequência cardíaca, entre outras), processado em `assets/dados/processed/`, com dicionário de variáveis e justificativa clínica da relevância de cada atributo documentados em `document/other/documentacao/` para aplicações futuras de Machine Learning (Fase 2).

Parte 2 — Dados Textuais: reúne dois textos `.txt` derivados de publicações oficiais do Ministério da Saúde/CONITEC — um sobre prevenção cardiovascular (fatores de risco, atenção básica) e outro sobre manejo de síndromes coronarianas agudas (sintomas, diagnóstico, tratamento) — formando um corpus complementar (antes vs. depois do evento cardíaco). Esse corpus poderá apoiar futuramente tarefas de NLP como identificação e extração de termos clínicos (sintomas, fatores de risco, procedimentos), classificação temática (prevenção vs. evento agudo), recuperação de informação e sumarização, além de servir de base textual para um sistema de perguntas e respostas ou para o Assistente Cardiológico Virtual (Fase 5).

Parte 3 — Dados Visuais: reúne 120 imagens de eletrocardiograma (ECG), curadas a partir do dataset público *ECG Images dataset of Cardiac Patients* (Mendeley Data), balanceadas em 4 classes (`normal`, `myocardial_infarction`, `history_mi`, `abnormal_heartbeat`), com curadoria rigorosa (deduplicação por hash, remoção de dados administrativos/pessoais). Cada arquivo `.jpg` representa uma imagem de um exame de ECG de 12 derivações — não necessariamente um paciente único. Esse conjunto poderá ser reutilizado futuramente para classificação de imagens de ECG, aprendizado de padrões visuais e experimentos de distinção entre as quatro classes disponibilizadas com técnicas de Visão Computacional (Fase 4), sem qualquer promessa de capacidade diagnóstica clínica nesta etapa.

Todas as três partes seguiram um processo de **governança de dados** com atenção à proveniência, privacidade, qualidade e rastreabilidade. Limitações e possíveis vieses identificados, detalhados nos documentos específicos em `document/other/documentacao/`: a Parte 1 usa uma base originada na Cleveland Clinic (EUA, década de 1980), sem representatividade populacional garantida para outros contextos; a Parte 2 usa textos institucionais brasileiros de linguagem técnica (não espontânea de pacientes), sendo que um dos materiais tem contexto temporal mais antigo (2006); a Parte 3 usa um dataset originado no Paquistão, com possíveis vieses de população e de equipamento de aquisição, e a amostra curada e balanceada não representa necessariamente a prevalência real das condições nas classes.

Estrutura de pastas

Dentre os arquivos e pastas presentes na raiz do projeto, definem-se:

.github: Nesta pasta ficarão os arquivos de configuração específicos do GitHub que ajudam a gerenciar e automatizar processos no repositório.

assets: aqui estão os arquivos relacionados a elementos não-estruturados deste repositório, como imagens.

config: Posicione aqui arquivos de configuração que são usados para definir parâmetros e ajustes do projeto.

document: aqui estão todos os documentos do projeto que as atividades poderão pedir. Na subpasta "other", adicione documentos complementares e menos importantes.

scripts: Posicione aqui scripts auxiliares para tarefas específicas do seu projeto. Exemplo: deploy, migrações de banco de dados, backups.

src: Todo o código fonte criado para o desenvolvimento do projeto ao longo das 7 fases.

README.md: arquivo que serve como guia e explicação geral sobre o projeto (o mesmo que você está lendo agora).

Nesta fase, os artefatos reais estão organizados assim dentro das pastas oficiais:

- `assets/dados/raw/` e `assets/dados/processed/`: dados brutos e processados da Parte 1 (numéricos).
- `assets/textos/`: corpus textual da Parte 2.
- `assets/imagens/ecg/`: amostra de imagens de ECG da Parte 3.
- `document/other/entrega/`: documento complementar de submissão (PDF para a plataforma FIAP).
- `document/other/documentacao/`: plano de execução e documentos de apoio das Partes 1, 2 e 3.
- `document/other/referencias/`: enunciado e mapa mental oficiais, fontes institucionais utilizadas na Parte 2, rastreabilidade da Parte 3 e materiais de aula da Fase 1.
- `scripts/`: scripts de preparação/reprodução dos datasets.

Links externos

- **Parte 1 — Dados Numéricos:** [Acessar pasta](#)
- **Parte 2 — Dados Textuais:** [Acessar pasta](#)
- **Parte 3 — Dados Visuais:** [Acessar pasta](#)

Como executar o código

Esta fase é de preparação e curadoria de dados. Os datasets finais já estão preparados e disponíveis nas pastas do projeto e nos links externos, portanto não é necessário executar código para avaliá-los.

Os scripts abaixo são fornecidos apenas para reprodução e rastreabilidade do processo de preparação dos dados.

Pré-requisitos: Python 3.12+ e a biblioteca `Pillow` (usada em `scripts/preparar_amostra_ecg.py`, Parte 3). O script `scripts/preparar_dataset_numerico.py` (Parte 1) usa apenas bibliotecas nativas do Python (`csv`, `pathlib`).

Clonar o repositório:

```
git clone
https://github.com/murilosalla-blip/fiap-ano02-fase01-cap01-cardioia.git
```

Reproduzir o dataset numérico da Parte 1 (gera `assets/dados/processed/heart_disease_cleveland.csv` a partir do dado bruto em `assets/dados/raw/`):

```
python scripts/preparar_dataset_numerico.py
```

Reproduzir a amostra de imagens de ECG da Parte 3 — requer preparação manual antes de executar (ver `document/other/referencias/parte3/fonte_dataset.md`):

1. baixar o dataset bruto completo do Mendeley Data e extraí-lo localmente;
2. ajustar a variável `RAW_DIR` no início de `scripts/preparar_amostra_ecg.py` para apontar para a pasta onde o dataset foi extraído;
3. então executar:

```
python scripts/preparar_amostra_ecg.py
```

Histórico de lançamentos

- 0.1.0 - 21/08/2026
 - Estrutura inicial do projeto CardioIA e configuração do repositório.
- 0.2.0 - 21/08/2026
 - Parte 1 concluída: dataset numérico (UCI Heart Disease Cleveland) processado, validado e documentado.
- 0.3.0 - 21/08/2026
 - Parte 2 concluída: corpus textual (prevenção cardiovascular e síndromes coronarianas agudas) preparado e documentado.

- 0.4.0 - 21/08/2026
- Parte 3 concluída: amostra de 120 imagens de ECG curada, validada e documentada.

Licença



[MODELO GIT FIAP](#) por [Fiap](#) está licenciado sobre [Attribution 4.0 International](#).