

07

GOVERNANÇA EM IA: O CÉREBRO ÉTICO DOS DADOS

LISTA DE FIGURAS

Figura 1 - Exemplificação de fluxograma de ciclo de vida de dados e modelos	9
Figura 2 - Cadeia evolutiva D-I-C-I	21
Figura 3 - Matriz SWOT de governança em IA.....	26



LISTA DE QUADROS

Quadro 1 - Principais riscos em cada fase do ciclo de vida de dados e modelos	15
Quadro 2 - Exemplificação de cadeia evolutiva de ativos informacionais	21
Quadro 3 - Cadeia D-I-C-I para caso fictício da farmácia FarmaVida	22
Quadro 4 - Exemplificação de autoavaliação simplificada	24
Quadro 5 - Autoavaliação de diagnóstico para empresa fictícia “Datario”	26
Quadro 6 - Perfis de liderança na governança de IA.....	29
Quadro 7 - <i>Power skills</i> , de acordo com o World Economic Forum	30
Quadro 8 - Comparação entre boas e más práticas de governança	36

SUMÁRIO

1 GOVERNANÇA EM IA: O CÉREBRO ÉTICO DOS DADOS	6
1.1 Introdução	6
1.2 O que é governança em IA e Big Data?	6
1.3 Definição e escopo	8
1.4 Importância da governança	9
1.5 Desafios na implementação	10
2 A IMPORTÂNCIA DA GOVERNANÇA NO CICLO DE VIDA DE DADOS E MODELOS	11
2.1 Estudo de caso: Viés na aplicação de Machine Learning para recrutamento de seleção	11
2.2 Estudo de caso: Viés algorítmico no diagnóstico médico – Stanford University (2019)	13
2.3 Ciclo de vida dos dados/modelos	14
2.4 Model Drift e a necessidade de revisão periódica	17
2.5 A importância da rastreabilidade e da explicabilidade	18
3 DADO, INFORMAÇÃO, CONHECIMENTO E INTELIGÊNCIA	19
3.1 Dado	19
3.2 Informação	19
3.3 Conhecimento	20
3.4 Inteligência	20
3.5 Relação entre os termos (cadeia evolutiva)	21
3.6 Estudo de caso fictício: Farmácia FarmaVida	21
3.7 Informação explícita x informação tácita	22
4 MATURIDADE EM GOVERNANÇA DE DADOS E IA: MODELOS E AVALIAÇÕES	23
4.1 O que é um modelo de maturidade?	23
4.2 Modelos de maturidade em governança de dados	23
4.3 Modelos de maturidade em governança de IA	24
4.3.1 Modelo da AI NOW Institute (2018)	25
4.3.2 Modelo do NIST AI RMF (2023)	25
4.4 Estudo de caso fictício: Diagnóstico da empresa fictícia “Datario”	26
4.5 Estratégias para evoluir na maturidade	27
5 O PAPEL DA LIDERANÇA E DAS COMPETÊNCIAS HUMANAS NA GOVERNANÇA	28
5.1 Liderança como pilar da governança	28
5.2 Perfis de liderança na governança de IA	29
5.3 Competências humanas críticas na era da IA	29
5.4 O papel das equipes multidisciplinares	30
6 DESAFIOS ÉTICOS E TÉCNICOS DA GOVERNANÇA EM IA	32
6.1 A dificuldade de explicar decisões automatizadas	32
6.2 O viés que nasce do histórico social	33
6.3 O paradoxo da explicabilidade	33
6.4 A corrida regulatória e seus riscos	34
6.5 Responsabilidade sem dono?	34

7 BOAS PRÁTICAS E MÁS PRÁTICAS NA GOVERNANÇA DE IA.....	36
8 GOVERNANÇA DE BIG DATA: COMPLEXIDADES E DESAFIOS PRÓPRIOS ...	37
9 AS QUATRO DIMENSÕES DA GOVERNANÇA DE DADOS E IA	39
9.1 Pessoas.....	39
9.2 Processos.....	39
9.3 Tecnologias	40
9.4 Dados	40
10 MODELOS CONVENCIONAIS <i>VERSUS</i> MODELOS DE IA GENERATIVA: IMPLICAÇÕES PARA A GOVERNANÇA	42
10.1 Modelos tradicionais: Escopo definido e controle prévio	42
10.2 Modelos generativos: Amplitude criativa e novos riscos	43
10.3 Implicações práticas para a governança	43
11 NOVOS RISCOS EMERGENTES EM IA E BIG DATA: UM OLHAR CRÍTICO ...	45
11.1 Drift ético: quando a inovação desalinha valores	45
11.2 Engenharia de prompt: Um novo vetor de vulnerabilidade.....	45
11.3 Alucinações algorítmicas: O risco da informação fabricada	46
11.4 Viés dinâmico: Viés que evolui e se reforça	46
CONCLUSÃO.....	48
REFERÊNCIAS.....	50
GLOSSÁRIO	52

1 GOVERNANÇA EM IA: O CÉREBRO ÉTICO DOS DADOS

1.1 Introdução

A sociedade contemporânea é atravessada por dados e algoritmos em praticamente todas as suas dinâmicas. A ascensão da Inteligência Artificial (IA) e do Big Data tem remodelado a maneira como organizações — tanto públicas quanto privadas — operam, decidem e interagem com seus públicos. Entretanto, à medida que o poder computacional aumenta, emergem preocupações legítimas: **como garantir que decisões automatizadas respeitem princípios éticos, assegurem a privacidade e mantenham a transparência?**

A governança em IA e Big Data é um campo essencial para garantir que o desenvolvimento e a aplicação dessas tecnologias ocorram de maneira alinhada aos valores sociais e legais. Ela envolve a criação de estruturas, políticas e práticas que assegurem o uso responsável, seguro e eficaz de dados e sistemas inteligentes.

Neste capítulo, serão discutidos os fundamentos da governança em IA e Big Data, a partir de seus conceitos essenciais, implicações ao longo do ciclo de vida dos dados e modelos, níveis de maturidade organizacional e o papel central da liderança e das competências humanas. A proposta é fornecer um panorama introdutório que permita às organizações refletir criticamente sobre como se posicionar diante das promessas — e riscos — dessas tecnologias emergentes.

1.2 O que é governança em IA e Big Data?

Em um primeiro olhar, a **governança em Inteligência Artificial e Big Data** pode parecer uma extensão da governança tradicional em Tecnologia da Informação (TI), uma vez que compartilha princípios como políticas bem definidas, processos estruturados, definição de responsabilidades e controles operacionais. A diferença fundamental, no entanto, está no modo como esses princípios se aplicam à realidade de sistemas inteligentes e dados massivos, exigindo novos critérios éticos, técnicos e sociais.

Enquanto a **governança de segurança da informação** concentra-se na garantia da confidencialidade, integridade e disponibilidade dos dados — mitigando riscos como vazamentos, acessos indevidos e fraudes —, e é comumente orientada por normas como a **ISO/IEC 27001** (ABNT, 2013), a **governança de processos** busca a padronização, eficiência e controle sobre as atividades organizacionais, com respaldo em frameworks como **COBIT** e **ITIL** (ISACA, 2012).

Por sua vez, a **governança de sistemas** está voltada à supervisão da arquitetura, desempenho e alinhamento dos sistemas com os objetivos estratégicos da organização (Weill & Ross, 2004). Já a **governança de dados** preocupa-se com a gestão eficaz dos ativos informacionais, assegurando sua qualidade, integridade, segurança e disponibilidade — conforme preconizado pela **DAMA-DMBOK2** (DAMA International, 2017).

A governança de IA e Big Data, por sua vez, expande essas camadas ao se aplicar diretamente tanto ao uso responsável de algoritmos quanto à gestão de grandes volumes de dados. Seu propósito é garantir a **transparência**, a **explicabilidade**, o **controle sobre vieses**, a **conformidade regulatória** e a **minimização dos impactos éticos e sociais** decorrentes do uso dessas tecnologias emergentes (OECD, 2019; Floridi *et al.*, 2018).

Em poucas palavras, no contexto de Big Data, a governança tem como foco a gestão dos chamados **5 V's** — **Volume**, **Variedade**, **Velocidade**, **Veracidade** e **Valor** —, buscando garantir a confiabilidade e aplicabilidade dos dados (DAMA, 2017). Já no contexto da IA, a governança preocupa-se com o **gerenciamento de modelos algorítmicos**, abordando questões como vieses, transparência, auditabilidade e responsabilidade legal.

Contudo, os modelos de IA não são estáticos. São sistemas adaptáveis, que podem aprender, evoluir e modificar seus próprios parâmetros continuamente. E é justamente nesse ponto que reside um dos maiores riscos: **como assegurar que esses modelos respeitem direitos humanos, estejam em conformidade com legislações locais, sigam normas éticas e não gerem alucinações**, mesmo diante de transformações constantes?

Dessa forma, surge a necessidade de **supervisão contínua** sobre os modelos de IA — uma das funções centrais da governança. É necessário garantir que um

modelo possa ser reutilizado para diferentes finalidades sem que isso resulte em riscos críticos.

Essa governança aplica-se tanto aos amplamente conhecidos **modelos generativos** quanto aos modelos preditivos clássicos. Embora as alucinações sejam mais perceptíveis em aplicações de IA Generativa, como grandes modelos de linguagem (LLMs), **vieses e distorções também ocorrem em modelos tradicionais**, como algoritmos de séries temporais, classificadores de texto, sistemas de reconhecimento de imagem, entre outros.

1.3 Definição e escopo

A governança em Inteligência Artificial e Big Data pode ser compreendida como um conjunto articulado de diretrizes, práticas e mecanismos que orientam o uso dessas tecnologias em contextos organizacionais e sociais. Muito além de um compliance técnico, trata-se de uma estrutura que busca equilibrar inovação com responsabilidade e poder computacional com princípios éticos.

Entre as dimensões centrais da governança, destaca-se o compromisso com a **ética e os direitos humanos**, prevenindo que decisões automatizadas reforcem desigualdades estruturais ou reproduzam vieses históricos. A **transparência e a explicabilidade**, por sua vez, garantem que os sistemas possam ser auditados, compreendidos por seus usuários e, quando necessário, contestados.

Outro pilar fundamental é a **segurança da informação e a proteção de dados pessoais**, especialmente em um cenário marcado pela vigência de legislações como a LGPD (Lei Geral de Proteção de Dados Pessoais) no Brasil e o GDPR (General Data Protection Regulation) na Europa. A **conformidade regulatória** não se limita à legalidade, mas se estende ao zelo pela reputação institucional e pela confiança do público. Por fim, a **gestão de riscos algorítmicos** torna-se uma exigência contínua: prever falhas, monitorar desvios e mitigar impactos é parte inseparável de qualquer aplicação séria de IA.

1.4 Importância da governança

Implantar uma governança eficaz em IA e Big Data não é apenas uma boa prática — é um pré-requisito para a sustentabilidade dos projetos que utilizam essas tecnologias. Uma governança bem estruturada não apenas reduz a exposição a riscos técnicos e éticos, mas também **cria um ambiente seguro para a inovação responsável**. Isso significa testar novos modelos e fluxos analíticos sem comprometer a confiança da sociedade ou o cumprimento das normas.

Além disso, a governança fortalece a **legitimidade das decisões automatizadas**, ampliando a aceitação entre os stakeholders internos e externos. A longo prazo, isso se traduz em uma reputação institucional mais robusta e em maior resiliência organizacional. Projetos bem governados tendem a ser mais consistentes, escaláveis e ajustáveis às transformações regulatórias, tecnológicas e culturais.

O ciclo de vida dos dados e dos modelos de IA pode ser representado de forma visual, evidenciando as principais fases e pontos críticos em que a governança precisa atuar.




Figura 1 - Exemplificação de fluxograma de ciclo de vida de dados e modelos
Fonte: Elaborado pelo autor (2025)

1.5 Desafios na implementação

Apesar da sua relevância, implantar uma governança robusta para IA e Big Data ainda é um desafio em muitas organizações. A primeira barreira é técnica: **os sistemas baseados em IA, especialmente os mais complexos, nem sempre são facilmente compreensíveis**, mesmo por quem os desenvolve. Isso dificulta a implementação de controles eficazes e a explicação de resultados para o público leigo.

Outro desafio relevante é a **velocidade com que as tecnologias evoluem**. Políticas que funcionam hoje podem tornar-se obsoletas em poucos meses, exigindo atualizações constantes e capacidade institucional de Aprendizado Contínuo. Soma-se a isso a ausência de normas globais amplamente aceitas, o que gera abordagens fragmentadas e inseguras do ponto de vista jurídico.

Por fim, ainda existe o obstáculo cultural, no qual **muitas organizações ainda veem a governança como uma limitação à liberdade criativa dos times técnicos**, e não como uma aliada estratégica da inovação. Essa percepção precisa ser revertida com exemplos, educação interna e liderança ativa — temas que serão retomados no final deste capítulo.

A governança em IA e Big Data é um componente essencial para o uso responsável e eficaz dessas tecnologias. Ao estabelecer estruturas e práticas que promovam a ética, a transparência e a responsabilidade, as organizações podem maximizar os benefícios da IA e do Big Data, ao mesmo tempo em que minimizam os riscos associados.

2 A IMPORTÂNCIA DA GOVERNANÇA NO CICLO DE VIDA DE DADOS E MODELOS

2.1 Estudo de caso: Viés na aplicação de Machine Learning para recrutamento de seleção

Imagine que você se candidatou a uma big tech e possui um currículo de dar inveja — recheado de certificações, experiências profissionais, além de um portfólio rico e bem elaborado. Ainda assim, a concorrência é enorme. Agora pense: como um recrutador conseguiria avaliar todos esses currículos, em tempo hábil, e selecionar o candidato mais qualificado para ocupar a posição? Geralmente, essa rotina é insana. Mesmo com um time de recrutadores repletos de especialistas em perfis técnicos, nem sempre todos os currículos são lidos ou interpretados a tempo. Já pensou em aplicar um modelo de IA misto com Big Data, capaz de ler todos esses documentos e informar quais são os melhores candidatos?

Atualmente, algumas plataformas já abordam os recrutamentos dessa forma, como a Amazon, que tentou utilizar esse modelo em 2018. Porém, infelizmente, eles não contavam com um viés na seleção. Leia um trecho do texto:

“Os especialistas em Machine Learning da Amazon.com Inc identificaram um grande problema: seu novo mecanismo de recrutamento não gostava de mulheres. [...] Em 2015, a empresa percebeu que o sistema não avaliava candidatos para cargos técnicos de maneira neutra em relação ao gênero. Isso porque os modelos foram treinados com base em currículos recebidos pela companhia ao longo de dez anos. A maioria vinha de homens, refletindo a predominância masculina na indústria de tecnologia. [...] Na prática, o sistema da Amazon aprendeu sozinho que candidatos do sexo masculino eram preferíveis. Ele penalizava currículos que incluíam a palavra ‘feminino’, como em ‘capitã do clube de xadrez feminino’, e rebaixava formadas em faculdades exclusivamente femininas” (Reuters, 2018).

Conseguiu identificar o problema?

- A Amazon gerou um modelo de análise de currículo;
- Utilizou, como base de dados para treinamento de modelos, a base de currículos recebidos ao longo de 10 anos;

- Além dos dados pertinentes às hard skill, havia informações como gênero na base, e o modelo as utilizou para a classificação;
- A partir dos currículos convertidos em funcionários, consolidou o modelo;
- **O problema:** a indústria de tecnologia da informação é amplamente composta por pessoas do gênero masculino. Logo, o modelo entendeu que essa característica é um atributo promotor para a decisão da vaga no processo. E isso, chamamos de viés.

O viés, nesse caso, não surgiu com o modelo inferindo nos 5 V's de Big Data, mas sim com o modelo considerando uma característica de gênero para filtrar os candidatos. Mesmo que a grande maioria dos profissionais de TI sejam do gênero masculino, o modelo não deve utilizar esse item como escolha, pois segregaria ainda mais um ambiente pouco diverso. O modelo deveria utilizar, para a vaga, fatores de hard skill, experiência e cases profissionais, além de formações e certificações. O trecho informa algumas ações tomadas pela Amazon:

“A Amazon editou os programas para torná-los neutros em relação a esses termos específicos. Mas isso não garantia que as máquinas não criariam outras formas de classificar os candidatos de maneira discriminatória. [...] A empresa de Seattle acabou desmantelando a equipe no início do ano seguinte, pois os executivos perderam as esperanças no projeto. [...] O experimento da Amazon oferece um estudo de caso sobre as limitações do Aprendizado de Máquina e serve como lição para empresas que buscam automatizar etapas do recrutamento” (Reuters, 2018).

Os impactos negativos da aplicação de uma IA com viés são inúmeros, mas nesse caso podemos citar alguns:

- **Perda de credibilidade e reputação à imagem da marca:** mesmo que em testes, uma IA que penalize candidatas por serem do gênero feminino pode gerar uma reputação negativa para a marca — ainda mais para a Amazon, uma das líderes do setor. Com isso, surge também a cobrança por um papel mais responsável dessas empresas, considerando que são catalisadoras de novas tendências tecnológicas.
- **Desperdício de investimento:** tente calcular os seguintes custos: quatro anos de trabalho técnico, 500 modelos de IA desenvolvidos e a mão de obra alocada no projeto. Após a repercussão negativa, os executivos decidiram

cancelar o projeto, devido a receios quanto à aplicação da tecnologia sem riscos discriminatórios.

- **Advertência global e freio na automação de RH:** esse ocorrido passou a ser utilizado como estudo de caso sobre o que não deve ser feito e sobre a importância de modelos de supervisão contínua, gerando também um alerta para grandes corporações. Além disso, as empresas passaram a reavaliar aspectos relacionados à ética, à transparência e à governança na implementação de projetos semelhantes.

Embora o setor de tecnologia tenha sido um dos primeiros a evidenciar falhas significativas na governança de IA, como ilustrado no caso da Amazon, os riscos associados ao uso não supervisionado de algoritmos estendem-se para além do ambiente corporativo. Setores altamente sensíveis, como o da saúde pública, também começam a revelar os impactos de modelos preditivos mal governados. A seguir, um estudo de caso real demonstra como a ausência de curadoria rigorosa e de validação ética em sistemas de IA pode aprofundar desigualdades históricas em contextos sociais essenciais.

2.2 Estudo de caso: Viés algorítmico no diagnóstico médico – Stanford University (2019)

Em 2019 (Obermayer *et al.* 2019), pesquisadores da Universidade de Stanford identificaram um grave problema de **viés algorítmico** em sistemas de IA utilizados para gerenciar cuidados médicos em grandes redes hospitalares nos Estados Unidos.

O modelo analisava dados financeiros para prever quais pacientes necessitariam de cuidados médicos intensivos no futuro. Contudo, utilizava como **variável principal o histórico de “gastos médicos anteriores” — assumindo que quem gastou mais no passado teria maior necessidade de cuidado futuro.**

Essa premissa, aparentemente neutra, desconsiderava o fato de que, historicamente, pacientes negros recebiam menos tratamentos e investimentos médicos devido a barreiras socioeconômicas e raciais estruturais.

Assim, o **algoritmo sistematicamente subestimava a necessidade de atenção médica para esses pacientes**, priorizando, em muitos casos, indivíduos brancos com maior histórico de consumo de serviços de saúde.

O erro não residia apenas nos dados históricos — mas, sobretudo, na **falta de supervisão ética sobre as variáveis utilizadas como proxies** para inferir necessidade médica.

Estimativas apontaram que, devido a esse viés, cerca de 17% dos pacientes negros que deveriam ser classificados como prioritários foram excluídos da priorização automatizada.

Após a denúncia pública, diversas redes hospitalares precisaram revisar seus modelos, modificar variáveis e instituir comitês de revisão ética para projetos que envolvessem algoritmos de decisão médica.

Este caso evidencia a **importância da governança** não apenas na fase de modelagem técnica, mas também na **definição criteriosa dos dados de entrada**, nas **validações de justiça algorítmica** e no **monitoramento contínuo** do impacto social das decisões automatizadas.

Tanto no ambiente corporativo de tecnologia quanto em setores essenciais como a saúde pública, a ausência de governança estruturada sobre dados e modelos de IA revela riscos concretos de perpetuação de desigualdades, discriminação sistêmica e danos sociais profundos. Esses exemplos reforçam que a governança em IA e Big Data deve ser compreendida não apenas como um requisito operacional, mas como um compromisso ético permanente, transversal a diferentes setores e realidades.

2.3 Ciclo de vida dos dados/modelos

Após compreender os impactos de um modelo enviesado, como nos estudos de caso anteriores, torna-se evidente a importância da aplicação de governança em todas as etapas do desenvolvimento de soluções baseadas em Inteligência Artificial. Para isso, é essencial compreender o que constitui o **ciclo de vida de dados e de modelos de IA**.

De acordo com o **DAMA-DMBOK2** (2017), o ciclo de vida dos dados envolve uma sequência de atividades interdependentes que, quando bem governadas, garantem a integridade, a qualidade e a conformidade das informações utilizadas nos processos organizacionais. As principais etapas incluem:

1. **Planejamento e definição de dados:** alinhamento com as necessidades do negócio, definição de requisitos e objetivos dos dados.
2. **Aquisição e ingestão:** obtenção dos dados de fontes internas e externas.
3. **Armazenamento e organização:** estruturação e modelagem dos dados em repositórios apropriados.
4. **Qualidade e limpeza:** verificação de consistência, remoção de duplicidades e tratamento de dados faltantes ou incorretos.
5. **Distribuição e acesso:** definição de políticas de acesso, segurança e disponibilização.
6. **Uso e análise:** consumo dos dados para geração de valor por meio de relatórios, dashboards e modelos analíticos.
7. **Arquivamento e descarte:** encerramento do ciclo de dados em conformidade com políticas de retenção e privacidade.

A seguir, apresentam-se os principais riscos em cada fase do ciclo de vida de dados e modelos, bem como as ações de governança recomendadas para mitigá-los:

Fase	Riscos	Contramedidas de Governança
Coleta	Dados inconsistentes ou enviesados.	Definir políticas de coleta e validação.
Curadoria	Perda de diversidade de dados.	Análises de qualidade e balanceamento.
Modelagem	Viés algorítmico oculto.	Testes de <i>fairness</i> e revisão crítica.
Validação	Overfitting, falta de generalização.	Avaliação cruzada e validação externa.
Implantação	Model drift, obsolescência.	Monitoramento contínuo e planos de atualização.
Monitoramento	Falhas não detectadas.	KPIs e alertas automatizados.
Descarte	Vazamento de dados sensíveis.	Políticas de descarte seguro e anonimização.

Quadro 1 - Principais riscos em cada fase do ciclo de vida de dados e modelos
Fonte: Elaborado pelo autor (2025)

Já no campo da ciência de dados e da IA, frameworks como o **CRISP-DM** (Cross-Industry Standard Process for Data Mining) e o mais recente **NIST AI Risk Management Framework (2023)** estruturam o desenvolvimento e uso de modelos de forma cíclica e iterativa. As etapas podem ser descritas da seguinte forma:

1. **Entendimento do problema (negócio e técnico):** identificação do objetivo da modelagem, métricas de sucesso e restrições.
2. **Coleta e preparo dos dados:** limpeza, balanceamento, transformação e seleção de variáveis relevantes.
3. **Modelagem e treinamento:** escolha de algoritmos, parametrização e aprendizado com dados históricos.
4. **Validação e teste:** avaliação de performance e identificação de possíveis vieses, overfitting ou instabilidade.
5. **Implantação e operacionalização:** publicação do modelo em ambiente produtivo, integração com sistemas e processos.
6. **Monitoramento e manutenção:** verificação contínua da performance, detecção de model drift, re-treinamento e atualização do modelo.
7. **Aposentadoria do modelo:** decisão de descontinuar o uso do modelo, seja por obsolescência, mudanças no negócio ou riscos identificados.

A ausência de governança em qualquer uma dessas fases pode **comprometer a integridade, a acurácia e a confiabilidade** do sistema. Por exemplo, se a curadoria dos dados de entrada for negligenciada, o modelo será treinado com insumos enviesados ou inconsistentes. Se o monitoramento contínuo for inexistente, desvios de performance (como model drift) podem gerar decisões errôneas. E se não houver processos claros para revalidação periódica, os riscos técnicos e éticos se amplificam ao longo do tempo.

Assim, a governança deve atuar de forma transversal durante todo o ciclo, garantindo que cada decisão — desde a definição do problema até a utilização dos resultados — esteja fundamentada em critérios de transparência, responsabilidade, equidade e conformidade legal.

2.4 Model Drift e a necessidade de revisão periódica

Mesmo após um modelo de IA ser implantado e validado, ele não está livre de deterioração. Um dos fenômenos mais relevantes nesse contexto é o model drift, ou “deriva de modelo”. Esse termo se refere à degradação gradual da performance preditiva de um modelo ao longo do tempo, ocasionada por mudanças nos dados de entrada, nas relações entre variáveis ou até no comportamento dos usuários e do ambiente de negócio.

Existem duas categorias principais de model drift:

- **Data drift:** quando a distribuição dos dados de entrada muda significativamente em relação ao que foi utilizado no treinamento original.
 - **Exemplo:** um modelo de crédito treinado antes de uma crise econômica pode se tornar ineficaz após mudanças no padrão de consumo ou inadimplência da população.
- **Concept drift:** quando a relação entre variáveis de entrada e a variável-alvo muda com o tempo, mesmo que os dados pareçam semelhantes.
 - **Exemplo:** um modelo de detecção de fraudes pode perder acurácia à medida que os fraudadores adotam novas estratégias.

Ignorar o model drift compromete diretamente a confiabilidade do modelo e pode gerar decisões equivocadas — desde concessões indevidas de crédito até diagnósticos clínicos incorretos ou distorções em campanhas de marketing.

Dessa forma, a governança precisa incluir **rotinas estruturadas de monitoramento e revalidação periódica dos modelos**, contendo indicadores de desempenho atualizados, auditorias automatizadas, alarmes de performance e protocolos para retreinamento. Isso garante que o modelo permaneça adequado ao seu propósito e continue atendendo critérios de acurácia, imparcialidade e responsabilidade.

Frameworks como o **NIST AI RMF (2023)** destacam esse ponto como um dos pilares da gestão de risco em IA, ressaltando a importância da **manutenção ativa dos modelos em produção**. Sem isso, os sistemas tornam-se obsoletos, não apenas tecnicamente, mas também em termos de conformidade ética e regulatória.

2.5 A importância da rastreabilidade e da explicabilidade

Além da performance técnica, a governança deve garantir que os modelos sejam **explicáveis e rastreáveis**. Isso implica manter registros de:

- Quais dados foram utilizados e por quê;
- Quais variáveis influenciam as decisões;
- Qual algoritmo foi aplicado e em que versão;
- Quem aprovou cada etapa.

Essa rastreabilidade é essencial para auditorias externas, respostas a litígios legais, prestação de contas à sociedade e para a própria evolução do sistema.

A governança no ciclo de vida dos dados e modelos é uma jornada contínua, que requer envolvimento técnico, estratégico e ético em todas as fases. Governar IA e Big Data não significa apenas criar políticas ou prevenir falhas futuras: significa atuar em **tempo real**, adaptando-se a um ambiente onde os dados mudam, os algoritmos evoluem e os impactos são cada vez mais significativos.

3 DADO, INFORMAÇÃO, CONHECIMENTO E INTELIGÊNCIA

Para compreender a governança em sistemas de Inteligência Artificial e Big Data, é necessário primeiro compreender a **natureza e o papel dos ativos informacionais** que sustentam essas tecnologias. Diferenciar **dado, informação, conhecimento e inteligência** não é apenas um exercício conceitual, mas um passo essencial para entender como esses elementos se transformam e se conectam ao longo do tempo — e, principalmente, **como devem ser governados de forma distinta e integrada**.

3.1 Dado

O **dado** é o elemento mais bruto da cadeia. Trata-se de um registro, símbolo ou valor isolado, sem contexto ou interpretação. Pode ser um número (como “23”), um sinal (como um pixel escuro), ou uma palavra (como “sim”), e não tem, por si só, significado. Ele é o insumo primário da análise computacional.

Por exemplo, o registro “23” pode representar uma idade, uma temperatura ou um valor de venda — mas, isoladamente, não diz nada.

Na governança, o dado exige políticas de coleta, classificação, armazenamento e controle de qualidade para garantir que seja **válido, íntegro e seguro**.

3.2 Informação

A **informação** surge quando os dados são organizados, interpretados e contextualizados. Ao atribuir significado ao dado, transformamos um valor bruto em um elemento útil para a tomada de decisão.

Por exemplo, “23 anos” se torna uma informação se soubermos que é a idade de um candidato a uma vaga.

A informação precisa ser **relevante, precisa e acessível**, e sua governança envolve gestão de metadados, rastreabilidade e políticas de compartilhamento adequadas.

3.3 Conhecimento

O **conhecimento** emerge da combinação de múltiplas informações, associadas à experiência, ao raciocínio ou a modelos estruturados de compreensão da realidade. Ele permite **explicar o porquê das coisas** e guiar decisões com base em padrões reconhecidos.

Por exemplo, um recrutador entende que candidatos entre 22 e 30 anos, com pós-graduação e experiência internacional, tendem a ter melhor adaptação em projetos de tecnologia. Isso é conhecimento.

Na prática organizacional, o conhecimento deve ser **organizado, documentado e distribuído**, e sua governança está ligada à **gestão do capital intelectual** e à preservação do saber institucional.

3.4 Inteligência

A **inteligência** é o estágio mais elevado da cadeia e se refere à **capacidade de aplicar o conhecimento para agir estrategicamente**, antecipar cenários, resolver problemas complexos e tomar decisões de forma autônoma ou assistida.

Em sistemas computacionais, a inteligência se manifesta quando um modelo é capaz de reconhecer padrões, adaptar-se, prever ou recomendar ações com base em conhecimento estruturado — através de algoritmos.

Na governança de IA, a inteligência precisa ser explicável, auditável, controlável e alinhada aos valores organizacionais e sociais. Governar a inteligência, nesse caso, significa garantir que ela não ultrapasse limites éticos, legais e estratégicos definidos pela organização e pela sociedade.

3.5 Relação entre os termos (cadeia evolutiva)




Figura 2 - Cadeia evolutiva D-I-C-I
Fonte: Elaborado pelo autor (2025)

Cada elemento depende da integridade do anterior. Se os dados forem falhos, a inteligência resultante será questionável — reforçando a máxima: **garbage in, garbage out**. Por isso, a **governança deve atuar em todos os níveis dessa cadeia**, desde o registro bruto até os sistemas inteligentes de decisão. O quadro a seguir apresenta uma exemplificação da cadeia evolutiva.

Conceito	Definição	Exemplo	Governança relacionada
Dado	Elemento bruto, isolado e sem contexto.	“23”, “sim”, “8.000”, “SP”.	Coleta, armazenamento, integridade, classificação, privacidade.
Informação	Dado interpretado e contextualizado.	“Idade: 23 anos”, “Venda: R\$ 8.000 em São Paulo”.	Metadados, segurança, acesso, políticas de uso.
Conhecimento	Conjunto estruturado de informações que permite interpretação e ação.	“Clientes de SP com ticket médio acima de R\$ 7.000 tendem a ser fiéis”.	Capital intelectual, documentação, curadoria, treinamento organizacional.
Inteligência	Capacidade de aplicar o conhecimento para tomada de decisão estratégica.	“Sistema recomenda uma oferta com base no perfil de compra e comportamento”.	Explicabilidade, rastreabilidade, auditoria algorítmica, ética em IA.

Quadro 2 - Exemplificação de cadeia evolutiva de ativos informacionais
Fonte: Elaborado pelo autor (2025)

3.6 Estudo de caso fictício: Farmácia FarmaVida

A rede fictícia **FarmaVida** utiliza um sistema de BI (Business Intelligence) para acompanhar o desempenho de suas lojas.

Veja como ela percorre a cadeia D-I-C-I:

Nível	Aplicação prática
Dado	Leitura de “produto X vendido às 14h20 na loja 013”.
Informação	Consolidação: “Produto X vendeu 287 unidades na loja 013 em julho”.
Conhecimento	“Promoções relâmpago entre 14h e 16h aumentam vendas de analgésicos”.
Inteligência	O sistema automatiza campanhas de desconto nesse horário.

Quadro 3 - Cadeia D-I-C-I para caso fictício da farmácia FarmaVida
Fonte: Elaborado pelo autor (2025)

Nesse cenário, um **erro na leitura do dado** (exemplo: venda duplicada) **contaminaria toda a cadeia**, reforçando a importância de uma governança presente em todos os níveis.

3.7 Informação explícita x informação tácita

Outro aspecto importante é a distinção entre informação **explícita e tácita**:

- **Informação explícita:** pode ser facilmente registrada, digitalizada e transmitida (relatórios, manuais, planilhas).
- **Informação tácita:** é subjetiva, fruto da experiência, e difícil de formalizar (intuição, julgamento de risco, leitura de contexto).

Sistemas de IA frequentemente operam apenas com informações explícitas, o que os torna **limitados em contextos ambíguos ou complexos**. A governança deve reconhecer essas limitações e **complementar decisões algorítmicas com supervisão humana**.

A distinção entre dado, informação, conhecimento e inteligência revela que o valor real da informação não está apenas em sua coleta, mas na **forma como ela é interpretada, conectada e aplicada com responsabilidade**. Para que modelos de IA operem de forma confiável, é indispensável que cada elo dessa cadeia seja tratado com os devidos controles de governança. Mais do que assegurar que os dados sejam corretos, é necessário garantir que as **decisões automatizadas sejam coerentes com o contexto organizacional e os princípios éticos definidos**.

4 MATURIDADE EM GOVERNANÇA DE DADOS E IA: MODELOS E AVALIAÇÕES

Compreender os fundamentos da governança em IA e Big Data, bem como a estrutura conceitual que diferencia dado, informação, conhecimento e inteligência, é essencial — mas, por si só, não garante uma aplicação eficaz desses princípios nas organizações. É necessário que as instituições saibam **avaliar sua posição atual e estruturar uma jornada de evolução**, a fim de atingir níveis mais avançados de controle, transparência e geração de valor. Para isso, diversos modelos de **maturidade em governança** foram desenvolvidos nas últimas décadas, permitindo avaliar **níveis de capacidade organizacional** tanto na gestão de dados quanto no uso responsável de algoritmos e IA.

4.1 O que é um modelo de maturidade?

Modelos de maturidade são estruturas de avaliação que classificam o grau de desenvolvimento de processos, práticas e políticas organizacionais, geralmente em uma escala progressiva (de “inicial” a “otimizado”). Esses modelos permitem:

- **Diagnosticar** lacunas e vulnerabilidades;
- **Estabelecer** prioridades de melhoria;
- **Alinhar** ações com objetivos estratégicos;
- **Monitorar** o avanço da governança ao longo do tempo.

4.2 Modelos de maturidade em governança de dados

Um dos modelos mais amplamente adotados no contexto de dados é o proposto pela **DAMA International** no DAMA-DMBOK2 (2017). Ele descreve **cinco níveis de maturidade**:

- **Nível 1 – Ad hoc (caótico):** a organização não possui práticas estruturadas de governança de dados. Processos são informais, reativos e inconsistentes.

- **Nível 2 – Inicial (repetível):** algumas iniciativas isoladas começam a surgir, geralmente em áreas específicas.
- **Nível 3 – Gerenciado (definido):** processos de gestão e políticas de dados estão documentados e são aplicados com consistência.
- **Nível 4 – Medido (controlado):** há monitoramento de indicadores, auditoria de qualidade dos dados e responsabilização institucional.
- **Nível 5 – Otimizado:** a governança está integrada à estratégia da organização, com melhoria contínua, automação e cultura orientada a dados.

A DAMA também recomenda que cada área funcional da governança de dados (como qualidade, integração, segurança, entre outras) seja avaliada individualmente, permitindo uma visão granular do grau de maturidade.

Domínio	Nível 1 – Inicial	Nível 3 – Gerenciado	Nível 5 – Otimizado
Governança de Dados.	Práticas isoladas e reativas.	Política formal implementada e monitorada.	Cultura institucional orientada a dados com melhoria contínua.
Qualidade e Integridade.	Sem critérios claros.	Métricas definidas e revisadas periodicamente.	Qualidade gerenciada por automações e feedback contínuo.
Transparência em IA.	Opacidade total nos modelos.	Documentação mínima dos algoritmos.	Explicabilidade ativa e canais abertos de revisão.
Mitigação de Viés e Risco.	Não existe.	Avaliações pontuais em ciclos de desenvolvimento.	Auditoria contínua com análise de impacto social e jurídico.

Quadro 4 - Exemplificação de autoavaliação simplificada
Fonte: DAMA-DMBOK2 (2017), adaptado por FIAP (2025)

4.3 Modelos de maturidade em governança de IA

Na área de Inteligência Artificial, surgiram, nos últimos anos, estruturas específicas para avaliar a maturidade organizacional quanto à governança algorítmica. Dois modelos destacam-se:

4.3.1 Modelo da AI NOW Institute (2018)

O AI Now Institute, ligado à Universidade de Nova York, propõe que a maturidade da governança de IA deve ser avaliada com base em:

- Existência de políticas e diretrizes específicas para IA;
- Transparência sobre os modelos em uso;
- Registro e documentação dos dados utilizados no treinamento;
- Auditorias independentes sobre impactos éticos e legais;
- Participação de stakeholders diversos no processo decisório.

Quanto menos desses itens estiverem implementados, mais imatura é a organização no uso ético e transparente da IA.

4.3.2 Modelo do NIST AI RMF (2023)

O **NIST AI Risk Management Framework** não utiliza uma escala explícita de níveis, mas permite avaliar a maturidade com base na **completude e integração das quatro funções principais**:

- **Governar:** existem políticas de governança de IA alinhadas ao risco?
- **Mapear:** os impactos sociais e técnicos dos modelos são devidamente mapeados?
- **Medir:** os riscos estão sendo quantificados, monitorados e auditados?
- **Gerenciar:** a organização consegue mitigar riscos de forma estruturada e responder a falhas?

Organizações que cumprem integralmente essas funções demonstram **alta maturidade**, enquanto aquelas que não as aplicam ou o fazem de maneira parcial permanecem em níveis iniciais.

4.4 Estudo de caso fictício: Diagnóstico da empresa fictícia “Datario”

Contexto: a empresa fictícia **Datario** é uma fintech que oferece crédito pessoal utilizando modelos de IA para análise de risco. Após denúncias sobre possível discriminação nos algoritmos, a empresa decide realizar um diagnóstico de maturidade.

No quadro a seguir, é apresentado a avaliação de forma resumida:

Domínio	Nível Atual	Riscos Identificados
Qualidade dos dados	Nível 2	Falta de padronização nas fontes externas.
Gestão de metadados	Nível 1	Nenhuma documentação sobre variáveis utilizadas.
Explicabilidade	Nível 1	Clientes não entendem os motivos de reprovação.
Gestão de riscos	Nível 2	Sem política formal de avaliação de viés algorítmico.
Conformidade regulatória	Nível 3	Alinhamento parcial com a LGPD.

Quadro 5 - Autoavaliação de diagnóstico para empresa fictícia “Datario”
Fonte: Elaborado pelo autor (2025)

Observe a análise SWOT da Governança em IA:



Figura 3 - Matriz SWOT de governança em IA
Fonte: Elaborado pelo autor (2025)

O estudo revelou que, **apesar da sofisticação técnica**, a Datario operava com maturidade muito baixa em governança. Isso demonstra que **tecnologia avançada não significa maturidade organizacional** — e reforça a importância de frameworks bem implementados.

4.5 Estratégias para evoluir na maturidade

Para sair de um nível inicial para um nível otimizado, é preciso mais do que ferramentas — é necessário compromisso institucional. Algumas estratégias são:

- Patrocínio da alta liderança;
- Criação de comitês de governança de IA;
- Treinamentos em ética algorítmica;
- Adoção de padrões como ISO/IEC 42001;
- Incorporação de auditorias externas e internas;
- Comunicação clara com stakeholders.

A maturidade em governança de dados e IA é um indicador-chave da capacidade da organização de operar com segurança, ética e eficácia em um mundo orientado por algoritmos. Modelos como DAMA-DMBOK2 e NIST AI RMF não são apenas ferramentas de diagnóstico: são guias para uma transformação gradual, sustentável e auditável.

5 O PAPEL DA LIDERANÇA E DAS COMPETÊNCIAS HUMANAS NA GOVERNANÇA

A governança em Inteligência Artificial e Big Data vai além de frameworks, processos e tecnologias. Ela é, antes de tudo, **uma prática humana, estratégica e cultural**, que depende diretamente da atuação da liderança organizacional e das competências desenvolvidas pelas pessoas envolvidas na criação, validação e uso de soluções baseadas em dados e algoritmos.

5.1 Liderança como pilar da governança

Toda iniciativa de governança começa com **comprometimento institucional**. Líderes — sejam eles executivos, diretores técnicos ou gestores de produto — têm a responsabilidade de garantir que o uso de IA e dados:

- Esteja alinhado à missão, visão e valores da organização;
- Considere os impactos éticos, regulatórios e sociais das decisões automatizadas;
- Estabeleça limites claros para o uso de algoritmos, dados sensíveis e práticas automatizadas;
- Promova uma cultura de transparência, *accountability* e Aprendizado Contínuo.

Sem liderança ativa e consciente, a governança tende a se tornar um conjunto de documentos desconectados da prática real. Porém, com a atenção adequada, ela se transforma em uma **força orientadora que permeia decisões estratégicas, operacionais e tecnológicas**.

“A liderança em governança de IA é responsável por garantir que o poder da automação seja temperado pela sensibilidade humana e pelo compromisso com o bem comum” (Floridi *et al.*, 2018).

5.2 Perfis de liderança na governança de IA

Cada organização pode estruturar sua liderança para IA e dados de forma diferente. Contudo, alguns perfis típicos se destacam como referências:

Perfil	Papel na governança
Chief Data Officer (CDO)	Define estratégias de dados, padronização, qualidade e governança.
Chief AI/Analytics Officer (CAIO)	Coordena projetos de IA com foco em valor e responsabilidade.
Líder de Produto com IA	Garante que as soluções algorítmicas estejam alinhadas aos usuários.
Oficial de Privacidade (DPO)	Fiscaliza conformidade legal, como a LGPD.
Comitê de Ética em IA	Multidisciplinar, avalia impacto, riscos e representatividade social.

Quadro 6 - Perfis de liderança na governança de IA
Fonte: Elaborado pelo autor (2025)

5.3 Competências humanas críticas na era da IA

Mesmo em ambientes altamente automatizados, **as pessoas continuam sendo o principal vetor de governança ética e inteligente**. A atuação humana é essencial para:

- Interpretar resultados de modelos com senso crítico;
- Compreender os limites dos algoritmos e suas zonas de incerteza;
- Identificar vieses não previstos por métricas técnicas;
- Promover decisões híbridas, equilibrando recomendações da IA com julgamento humano.

Dessa forma, é imprescindível que profissionais envolvidos com dados, algoritmos e sistemas desenvolvam competências que extrapolam habilidades técnicas. O **World Economic Forum** (2023) destaca as chamadas *power skills*, que ultrapassam o domínio técnico e envolvem visão sistêmica, ética e pensamento crítico. Entre as mais relevantes:

Competência	Descrição
Pensamento crítico	Capacidade de questionar a validade, utilidade e impactos dos modelos.
Ética e responsabilidade	Compreensão dos limites morais e legais do uso de dados e IA.
Alfabetização em dados	Leitura e interpretação adequada de indicadores, modelos e visualizações.
Gestão de risco	Avaliação de potenciais falhas, impactos sociais e planos de contingência.
Comunicação e explicabilidade	Traduzir decisões técnicas para uma linguagem acessível e transparente.

Quadro 7 - *Power skills*, de acordo com o World Economic Forum
Fonte: World Economic Forum (2023)

O World Economic Forum (2023) ressalta que as chamadas “*power skills*” — pensamento sistêmico, ética digital, empatia e governança algorítmica — serão tão ou mais relevantes do que habilidades técnicas para os profissionais do futuro.

5.4 O papel das equipes multidisciplinares

A governança eficaz não é responsabilidade de um único setor. Ela depende de **colaboração entre diferentes áreas**, como:

- TI e Engenharia de Dados;
- Jurídico e Compliance;
- RH e Diversidade;
- Marketing, Produto e Atendimento;
- Alta liderança e Conselho Administrativo.

Ao reunir **visões diversas** sobre o impacto da IA e dos dados, as organizações constroem sistemas mais resilientes, éticos e alinhados à realidade social em que atuam. Isso reforça a necessidade de formar **comitês de ética, grupos de governança e espaços de escuta** para garantir que decisões algorítmicas sejam inclusivas e transparentes.

A governança em IA e Big Data exige tecnologias robustas, processos bem definidos e normas claras — mas nada disso funcionará sem **liderança consciente e pessoas preparadas**. São os indivíduos que determinam os limites, supervisionam os modelos, interpretam os resultados e, principalmente, respondem por suas consequências. Fortalecer competências humanas e empoderar lideranças é,

portanto, uma condição indispensável para transformar a governança em uma prática viva, confiável e alinhada ao interesse coletivo.

EURO

6 DESAFIOS ÉTICOS E TÉCNICOS DA GOVERNANÇA EM IA

Quando se discute a implementação de governança em Inteligência Artificial e Big Data, é comum imaginar um conjunto de boas práticas que, se aplicadas corretamente, garantiriam o funcionamento ético e seguro dessas tecnologias. Entretanto, a realidade prática se mostra muito mais desafiadora. **A governança em IA não enfrenta apenas problemas técnicos, mas dilemas éticos profundos, lacunas de explicabilidade e um cenário regulatório que ainda está em construção.** A seguir, discutem-se os principais obstáculos que organizações precisam enfrentar — e, idealmente, superar — para que a promessa de uma IA responsável possa, de fato, se materializar.

6.1 A dificuldade de explicar decisões automatizadas

Grande parte das técnicas modernas de Aprendizado de Máquina, especialmente as Redes Neurais Profundas, opera como verdadeiras caixas-pretas. A previsão gerada é precisa — muitas vezes, impressionante —, mas o caminho interno que resultou naquela decisão permanece obscuro, mesmo para seus próprios criadores.

Tal opacidade impõe **desafios graves**: não se trata apenas de um problema técnico, mas de um risco jurídico, ético e social. **Como exigir *accountability* de um modelo que nem mesmo seu engenheiro consegue explicar com clareza?** A questão torna-se ainda mais crítica em setores como saúde, crédito e justiça, onde decisões automatizadas podem impactar diretamente a vida das pessoas.

Embora técnicas de interpretabilidade como LIME (Local Interpretable Model-Agnostic Explanations) ou SHAP (SHapley Additive exPlanations) ofereçam alguma luz sobre o comportamento dos modelos, é necessário reconhecer que explicar não é trivial — e, muitas vezes, implica renunciar a performance em troca de transparência.

6.2 O viés que nasce do histórico social

Muito se fala sobre o viés algorítmico como se fosse uma anomalia do código. Na prática, o viés nasce antes, na sociedade, e é absorvido pelos dados que usamos para treinar nossos modelos.

Dados históricos carregam desigualdades de acesso, discriminações veladas e preferências estruturais. **Sem uma governança crítica, a IA reproduz — ou pior, amplifica — essas distorções.**

Casos emblemáticos, como o sistema **COMPAS** no judiciário norte-americano ou o modelo de saúde analisado por Obermayer *et al.* (2019), mostram que confiar cegamente nos dados históricos é renunciar à responsabilidade moral sobre os resultados.

A governança precisa, portanto, olhar para trás antes de projetar para frente, analisando ativamente os dados de treinamento e implementando validações de *fairness* específicas para cada contexto.

6.3 O paradoxo da explicabilidade

A exigência por explicações compreensíveis esbarra em uma tensão difícil de resolver: os modelos mais simples são mais fáceis de interpretar, mas tendem a ser menos eficientes em tarefas complexas.

Já os modelos de alta performance, como Ensembles ou Deep Learning, são praticamente indecifráveis em seu funcionamento interno.

Esse paradoxo exige que as organizações façam escolhas estratégicas:

- Optar por transparência em detrimento de alguma performance?
- Ou aceitar uma “caixa-preta” em nome de melhores resultados?

Não há uma única resposta. Em setores críticos, a tendência — já observada no AI Act europeu — é **exigir explicabilidade mínima como pré-requisito de segurança jurídica**. Mesmo que isso implique sacrificar alguns pontos de acurácia.

6.4 A corrida regulatória e seus riscos

Em 2023, a União Europeia deu passos decisivos para regular a IA com o AI Act, categorizando aplicações por níveis de risco e impondo exigências crescentes conforme a criticidade da tecnologia.

Nos Estados Unidos, embora predomine a abordagem da autorregulação, cresce a pressão para normas federais específicas. No Brasil, o debate sobre o Marco Legal da IA caminha com prudência, mas ainda sem definições concretas.

Essa corrida regulatória coloca as organizações diante de um novo desafio: como manter modelos de IA em conformidade em múltiplas jurisdições, com regras distintas e em constante mutação?

A governança precisa ser dinâmica, antecipando tendências legais e se estruturando para revisões frequentes. Aquele que enxergar a regulação apenas como ameaça, e não como oportunidade para consolidar confiança, perderá espaço no mercado.

6.5 Responsabilidade sem dono?

A automação algorítmica cria uma zona cinzenta de responsabilidade: **quem responde por uma decisão tomada por um sistema de IA?** O programador que escreveu o código? O gestor que aprovou o projeto? O C-level que liberou o uso em larga escala?

Se a responsabilidade não for claramente atribuída desde o início, os riscos aumentam exponencialmente.

É função da governança estabelecer **linhas formais de accountability, documentar processos de desenvolvimento, validação e revisão, e garantir que cada ator envolvido saiba seu papel e seus limites de atuação.**

Em um futuro próximo, a ausência dessa definição poderá custar caro — tanto juridicamente quanto em termos de reputação e credibilidade.

Governar IA e Big Data não é apenas uma tarefa técnica; é um exercício permanente de consciência crítica, visão estratégica e responsabilidade social. Os

desafios discutidos neste tópico mostram que **não existe governança verdadeira sem assumir a complexidade do que se quer controlar.**

Governar é, antes de tudo, resistir à tentação da simplificação fácil, abraçando as ambiguidades e incertezas que são parte inerente da Inteligência Artificial.

EURO

7 BOAS PRÁTICAS E MÁ PRÁTICAS NA GOVERNANÇA DE IA

A implementação da governança em projetos de Inteligência Artificial e Big Data exige mais do que boas intenções: requer práticas consistentes, replicáveis e sensíveis aos riscos inerentes ao uso dessas tecnologias. Ainda assim, na prática cotidiana das organizações, **nem sempre a governança é conduzida de forma adequada.**

A seguir, apresenta-se um quadro comparativo com exemplos de boas práticas — que reforçam a governança ética e eficiente — e más práticas — que frequentemente ocasionam falhas, riscos e perda de credibilidade.

Aspecto	Boa prática	Má prática
Coleta de Dados	Definir propósito claro e consentimento informado.	Coletar dados indiscriminadamente sem transparência.
Curadoria de Dados	Aplicar validação de qualidade e diversidade.	Utilizar bases históricas sem auditoria ou balanceamento.
Modelagem	Escolher algoritmos considerando explicabilidade e risco.	Focar apenas em performance sem avaliar impactos sociais.
Teste e Validação	Conduzir testes de <i>fairness</i> , segurança e estabilidade.	Validar apenas desempenho técnico, ignorando vieses.
Implantação	Monitorar modelos em tempo real e revisar periodicamente.	Implantar e abandonar sem monitoramento contínuo.
Documentação	Manter registros claros de decisões e mudanças.	Falta de versionamento e rastreabilidade.
Comunicação	Tornar decisões algorítmicas compreensíveis para stakeholders.	Manter lógica de decisão oculta (“black-box” não auditável).
Accountability	Atribuir responsabilidades formais sobre o modelo.	Não definir responsáveis, dificultando a responsabilização.

Quadro 8 - Comparação entre boas e más práticas de governança
Fonte: Elaborado pelo autor (2025)

O sucesso da governança em IA está diretamente relacionado à capacidade da organização de reconhecer seus próprios pontos frágeis e atuar proativamente para consolidar boas práticas em todos os níveis. Ignorar qualquer uma dessas etapas — desde a coleta inicial de dados até a *accountability* final sobre decisões algorítmicas — cria espaços de vulnerabilidade ética, jurídica e operacional.

Portanto, a governança não pode ser encarada como um processo complementar, mas sim como um eixo estruturante de todo o ciclo de vida de soluções baseadas em IA e Big Data.

8 GOVERNANÇA DE BIG DATA: COMPLEXIDADES E DESAFIOS PRÓPRIOS

A emergência do Big Data transformou radicalmente a dinâmica de gestão da informação nas organizações. Volume, variedade, velocidade, veracidade e valor — os “5 V’s” que definem o Big Data — colocaram em xeque modelos tradicionais de controle e exigiram novas abordagens de governança. Contudo, o debate sobre governança em IA frequentemente ofusca a complexidade própria da governança em ambientes massivos de dados.

Governar Big Data é muito mais do que controlar acesso ou armazenar informações. Trata-se de enfrentar a realidade de dados heterogêneos, em formatos variados, oriundos de fontes internas e externas, muitas vezes com qualidades e finalidades divergentes. A governança precisa garantir que, mesmo diante dessa diversidade, os dados sejam úteis, confiáveis, rastreáveis e estejam em conformidade com as legislações vigentes.

Um dos primeiros grandes desafios é o da **coleta de dados**. Em ambientes de Big Data, a coleta é frequentemente automatizada e contínua, envolvendo múltiplos sistemas e pontos de captura. Sem políticas claras de finalidade, consentimento e minimização de coleta, a organização pode facilmente infringir normas de proteção de dados e éticas de privacidade.

Outro ponto crítico é **a curadoria e a qualidade dos dados**. Em grandes volumes, torna-se fácil ignorar inconsistências, duplicidades e vieses ocultos que comprometem análises futuras. **Uma governança eficiente exige a criação de processos de verificação, duplicação, enriquecimento e auditoria da qualidade dos dados** — atividades frequentemente negligenciadas sob a pressão por velocidade analítica.

A **integração de dados** também se revela um desafio. Informações oriundas de diferentes sistemas, em formatos e semânticas distintos, precisam ser harmonizadas para que análises baseadas em Big Data sejam significativas. A governança precisa definir padrões de interoperabilidade e vocabulários controlados, mitigando a fragmentação informacional.

Além disso, o aspecto da **segurança** em Big Data é sensível. Não basta proteger bancos de dados tradicionais: ambientes de Big Data geralmente envolvem *storage* distribuído, *cloud computing*, APIs expostas e múltiplas camadas de processamento. A governança precisa garantir que a proteção dos dados seja considerada de forma transversal, abrangendo desde os dados em repouso até aqueles em trânsito e em processamento.

Finalmente, o valor do dado precisa ser continuamente avaliado. O armazenamento de grandes volumes de informações irrelevantes não apenas consome recursos, mas também pode resultar em riscos jurídicos desnecessários. Dados sem valor estratégico ou operacional devem ser descartados com segurança, respeitando políticas claras de ciclo de vida da informação.

Dessa forma, a governança de Big Data não pode ser um apêndice improvisado da governança de TI ou da governança de IA. Ela precisa ter identidade própria, reconhecendo a especificidade dos riscos e oportunidades que ambientes massivos de dados trazem para a gestão organizacional.

Governar Big Data é, antes de tudo, reconhecer que nem todo dado é valioso, que nem toda coleta é legítima, e que nem toda análise é neutra. Exige visão crítica, processos robustos e uma cultura organizacional que entenda o dado como ativo estratégico — e também como responsabilidade social.

9 AS QUATRO DIMENSÕES DA GOVERNANÇA DE DADOS E IA

A governança de Big Data e Inteligência Artificial não é um sistema que depende apenas de boas tecnologias ou de processos técnicos eficazes. Ela se estrutura sobre quatro dimensões fundamentais, que atuam de forma integrada e simultânea para assegurar a eficácia, a ética e a sustentabilidade dos projetos que envolvem grandes volumes de dados e algoritmos inteligentes.

Compreender essas quatro dimensões é essencial para que a governança deixe de ser considerada apenas como um conjunto de políticas normativas e passe a ser reconhecida como um **pilar estratégico** da organização.

9.1 Pessoas

O componente humano é a alma da governança. Não existem processos eficazes nem tecnologias seguras sem a atuação consciente e crítica de pessoas capacitadas.

Em ambientes de dados e IA, todos os envolvidos — cientistas de dados, gestores de negócios, profissionais de TI e analistas jurídicos — precisam compreender o papel que desempenham no ecossistema de governança.

Mais do que treinamento técnico, é necessário formar indivíduos **eticamente conscientes** de que suas decisões no tratamento de dados e algoritmos possuem impactos concretos sobre indivíduos, grupos sociais e sociedades inteiras. A cultura de dados e a alfabetização em IA precisam ser disseminadas de forma transversal nas organizações, promovendo a autonomia crítica de seus agentes.

9.2 Processos

A dimensão processual é o eixo que organiza a ação. Governar dados e IA significa desenhar, implementar e monitorar processos que regulem:

- A coleta de dados (com consentimento e finalidade legítima);
- A curadoria e classificação de informações;

- A seleção, treinamento e validação de modelos de IA;
- O monitoramento contínuo de performance e riscos;
- A atualização ou aposentadoria de sistemas obsoletos.

Esses processos devem ser documentados, auditáveis e continuamente revisados. Não basta apenas criar processos: é necessário garantir que eles sejam vividos na prática e estejam adaptados à realidade organizacional e ao seu ambiente regulatório.

9.3 Tecnologias

Embora a tecnologia seja frequentemente o foco das atenções, ela deve ser vista como meio, e não como fim da governança. Ferramentas de gestão de dados, plataformas de Data Governance, sistemas de controle de versionamento de modelos, técnicas de explainability e frameworks de avaliação de risco algorítmico são fundamentais — mas a sua escolha e configuração precisam refletir os princípios e as necessidades definidos pelas pessoas e processos.

A governança tecnológica exige, ainda, que haja mecanismos para a avaliação contínua das ferramentas utilizadas, considerando aspectos como:

- Segurança e proteção da informação;
- Escalabilidade e adaptação a novos contextos;
- Capacidade de integração e interoperabilidade;
- Possibilidade de explicação de outputs algorítmicos.

A dependência cega de soluções técnicas, sem crítica e sem alinhamento ético, compromete qualquer iniciativa de governança.

9.4 Dados

Por último, mas não menos importante, estão os próprios dados, que constituem uma dimensão essencial da governança. Eles devem ser vistos como

ativos organizacionais — e, ao mesmo tempo, como elementos que carregam direitos, valores e impactos sociais. Governar dados implica:

- Classificar e catalogar adequadamente (metadados);
- Garantir a qualidade e consistência dos registros;
- Controlar o ciclo de vida, desde o armazenamento até a eliminação;
- Preservar a segurança e a privacidade.

Estabelecer políticas claras de compartilhamento interno e externo vai muito além do que simplesmente “acumular” — o desafio é curar e qualificar os dados, assegurando que sejam utilizados de maneira justa, eficiente e alinhado à finalidade para a qual foram coletados.

A interação dessas quatro dimensões — **Pessoas, Processos, Tecnologias e Dados** — define a maturidade e a efetividade da governança de Big Data e IA.

Ignorar qualquer uma delas significa fragilizar toda a estrutura, resultando em pontos de vulnerabilidade que podem comprometer a segurança, a ética e a eficácia dos projetos. Uma governança sólida nasce do equilíbrio e da atenção constante a todas essas dimensões, compreendendo que nenhuma tecnologia, por mais avançada que seja, substitui o compromisso humano com a responsabilidade, a ética e a crítica consciente.

10 MODELOS CONVENCIONAIS *VERSUS* MODELOS DE IA GENERATIVA: IMPLICAÇÕES PARA A GOVERNANÇA

O avanço recente dos modelos de Inteligência Artificial Generativa inaugurou uma nova era de desafios para a governança de ativos digitais. Diferentemente dos modelos tradicionais, como classificadores, preditores de séries temporais e sistemas de recomendação, os modelos generativos ampliam a complexidade e os riscos da gestão algorítmica. Compreender essas diferenças é essencial para ajustar os princípios fundamentais da governança às novas realidades tecnológicas.

10.1 Modelos tradicionais: Escopo definido e controle prévio

Modelos tradicionais de IA operam, em geral, sob escopos claramente delimitados:

- **Entrada controlada:** dados estruturados e limpos, com variáveis conhecidas.
- **Objetivo específico:** classificar, prever ou recomendar com base em padrões identificados.
- **Riscos previsíveis:** falhas de generalização, viés de treinamento, sobreajuste.

A governança desses modelos concentra-se em assegurar a qualidade dos dados de entrada, validar a performance dentro de métricas específicas (como precisão, recall, F1-score) e monitorar o comportamento do modelo em ambiente de produção.

Embora desafios como viés algorítmico já sejam relevantes nesse contexto, o fato de o escopo ser bem definido permite a criação de políticas e controles relativamente estáveis e auditáveis.

10.2 Modelos generativos: Amplitude criativa e novos riscos

Os modelos de IA Generativa — como os LLMs (Large Language Models), os geradores de imagens e os sintetizadores de dados — operam sob lógicas fundamentalmente distintas:

- **Entrada ampla e despadronizada:** textos livres, imagens variadas, prompts abertos.
- **Saídas criativas:** produção de conteúdos novos, não existentes previamente nos dados de treinamento.
- **Riscos ampliados:** alucinações, geração de desinformação, plágio não intencional, outputs eticamente questionáveis.

Em modelos generativos, não basta controlar a entrada e a performance de maneira convencional. A imprevisibilidade das saídas exige novas camadas de governança, voltadas para:

- **Definição clara de escopos permitidos:** estabelecendo fronteiras éticas e jurídicas para a utilização dos outputs.
- **Monitoramento contínuo dos outputs gerados:** avaliando não apenas acurácia, mas também veracidade, relevância e potencial de dano.
- **Revisão humana obrigatória:** especialmente para aplicações críticas, como saúde, direito e comunicação institucional.

Além disso, surge a necessidade de políticas de responsabilidade sobre o conteúdo gerado, para evitar que organizações sejam responsabilizadas judicialmente por outputs problemáticos de suas IAs.

10.3 Implicações práticas para a governança

A transição do paradigma de modelos convencionais para modelos generativos demanda uma reconfiguração da governança:

- **Expandir os frameworks de validação:** incorporando métricas de veracidade, toxicidade, viés discursivo e compliance ético.

- **Documentar detalhadamente os limites de uso:** registrando finalidades autorizadas, exclusões explícitas e protocolos de revisão.
- **Treinar equipes específicas para auditoria de conteúdo gerado:** desenvolvendo novas competências de análise crítica dos outputs.

O crescimento dos modelos generativos não elimina a necessidade de governar dados e algoritmos tradicionais. Pelo contrário, exige que a governança se torne ainda mais adaptativa, reflexiva e proativa.

O surgimento da IA Generativa não apenas expande as fronteiras do que a tecnologia pode fazer, mas também testa os limites da governança atual.

Organizações que não anteciparem essas mudanças correm o risco de enfrentar crises éticas, jurídicas e reputacionais significativas. A governança do futuro — e já do presente — deve incorporar essa nova complexidade, reconhecendo que a criatividade algorítmica, embora fascinante, carrega consigo responsabilidades ampliadas.

11 NOVOS RISCOS EMERGENTES EM IA E BIG DATA: UM OLHAR CRÍTICO

O avanço exponencial das tecnologias de Big Data e Inteligência Artificial trouxe benefícios inegáveis para a sociedade e para os negócios. Entretanto, junto com essas possibilidades, surgem riscos novos e complexos, que desafiam os paradigmas tradicionais de governança.

Governar ambientes de dados e algoritmos já não pode ser um exercício apenas de conformidade normativa: exige **vigilância crítica e capacidade adaptativa contínua**.

Os riscos emergentes, se não forem identificados e tratados, podem comprometer não apenas projetos isolados, mas também a confiança pública na adoção de tecnologias inteligentes como um todo.

11.1 Drift ético: quando a inovação desalinha valores

O chamado drift ético ocorre quando, ao longo do tempo, tecnologias inicialmente aceitáveis passam a gerar desconforto ou rejeição social diante da evolução de valores e normas coletivas. Exemplos emblemáticos incluem:

- Sistemas de vigilância massiva aceitos em contextos de segurança, mas posteriormente questionados por violações de privacidade.
- Algoritmos de recomendação que, sem governança adequada, contribuem para o reforço de bolhas ideológicas e polarização social.

A governança deve incluir mecanismos de **revisão periódica de impactos éticos**, garantindo que o alinhamento com os valores sociais não seja assumido como permanente, mas monitorado de forma dinâmica.

11.2 Engenharia de prompt: Um novo vetor de vulnerabilidade

Com a disseminação de modelos de IA Generativa, surge a prática da **engenharia de prompt** — manipulação maliciosa de entradas para induzir sistemas

de IA a gerarem respostas inadequadas, tóxicas ou perigosas. Essas vulnerabilidades podem ser exploradas para:

- Divulgar desinformação;
- Quebrar barreiras de segurança internas;
- Violar restrições éticas embutidas nos modelos.

A governança deve prever políticas específicas para treinamento de resistência à engenharia de prompt e para auditoria contínua de interações.

11.3 Alucinações algorítmicas: O risco da informação fabricada

Modelos generativos, como grandes modelos de linguagem, apresentam a capacidade de gerar **informações completamente fabricadas**, mas com aparência extremamente convincente — um fenômeno conhecido como **alucinações**. Essa característica compromete:

- A confiabilidade de sistemas automatizados de resposta;
- A acurácia de análises e relatórios;
- A segurança de aplicações críticas nos setores da saúde, do direito e das finanças.

A governança precisa considerar a avaliação sistemática da veracidade dos outputs e incorporar **filtros de verificação factual**, além de responsabilizar revisores humanos por conteúdos de alto impacto.

11.4 Viés dinâmico: Viés que evolui e se reforça

O viés em IA não é apenas herdado dos dados históricos. Com modelos que continuam aprendendo em produção (sistemas de Aprendizado Contínuo), novos padrões de viés podem emergir e se reforçar com o tempo — o chamado bias dinâmico. Sem monitoramento apropriado, sistemas inicialmente balanceados podem:

- Reproduzir discriminações sutis;
- Excluir grupos minoritários;

- Degradar sua performance social ao longo do uso.

A governança deve implementar mecanismos de **detecção contínua de viés**, revisão periódica de datasets e revalidação ética dos modelos em produção.

Os riscos emergentes no ecossistema de IA e Big Data exigem que a governança deixe de ser estática ou apenas reativa.

A capacidade de antecipar, detectar e corrigir novas formas de risco será o diferencial entre organizações que mantêm a confiança de seus stakeholders e aquelas que se veem em crise.

Governar, nesse novo contexto, é sobretudo **prever o imprevisível** e construir estruturas suficientemente resilientes para se adaptar a riscos que, muitas vezes, ainda nem foram totalmente compreendidos.

CONCLUSÃO

A ascensão da Inteligência Artificial e do Big Data impõe uma transformação profunda na forma como organizações e sociedades lidam com a informação, a decisão e a responsabilidade. Neste capítulo, foram estabelecidos os fundamentos que sustentam a governança nesse novo cenário, percorrendo conceitos, aplicações e desafios emergentes.

Inicialmente, discutiu-se que a governança em IA e Big Data herda princípios da governança de TI, mas amplia suas dimensões, incorporando a necessidade de controle sobre vieses, transparência, explicabilidade, rastreabilidade e respeito aos direitos humanos. Esta expansão se reflete na aplicação crítica da governança no ciclo de vida dos dados e modelos, evidenciando a importância da supervisão contínua para prevenir deriva de modelo (model drift), garantir a qualidade dos dados e assegurar a validade ética das soluções.

Ao nos aprofundarmos na diferença entre dado, informação, conhecimento e inteligência, tornou-se evidente que a gestão responsável dos ativos informacionais é a base para qualquer iniciativa de IA sustentável e segura. Em seguida, foi discutida a maturidade organizacional em governança de dados e IA, apresentando frameworks internacionais como o DAMA-DMBOK2 e o NIST AI RMF, que orientam o diagnóstico e a evolução de práticas de governança.

Reconheceu-se também que liderança e competências humanas são pilares indispensáveis para a efetividade da governança. Sem pessoas capacitadas em ética, pensamento crítico e gestão de riscos, nenhuma estrutura normativa é capaz de garantir a operação responsável de soluções de IA.

O capítulo também abordou os desafios éticos e técnicos contemporâneos, como a dificuldade de explicar decisões automatizadas, o viés histórico embutido nos dados e o paradoxo entre explicabilidade e performance técnica. Foram discutidas ainda as boas práticas e más práticas de governança, destacando que omissões na coleta, curadoria, documentação e *accountability* geram vulnerabilidades críticas.

Por fim, analisou-se a governança específica de Big Data, as quatro dimensões essenciais da governança (pessoas, processos, tecnologias e dados), a distinção entre modelos tradicionais de IA e modelos de IA Generativa, e os novos riscos

emergentes, como drift ético, engenharia de prompt, alucinações algorítmicas e viés dinâmico.

Esses conteúdos ampliaram a percepção de que a governança em IA e Big Data é um campo dinâmico, em evolução constante, que exige práticas adaptativas, reflexão crítica permanente e compromisso ético estrutural.



REFERÊNCIAS

- AI NOW INSTITUTE. **Algorithmic Impact Assessments: A Practical Framework for Public Agency Accountability**. New York: New York University, 2018.
- BRYNJOLFSSON, E.; MCAFEE, A. **The Second Machine Age**. New York: Norton, 2014.
- CHAPMAN, P. *et al.* **CRISP-DM 1.0: Step-by-step data mining guide**. SPSS Inc., 2000. Disponível em: <<https://www.the-modeling-agency.com/crisp-dm.pdf>>. Acesso em: 5 maio 2025.
- CMMI INSTITUTE. **Data Management Maturity Model (DMM)**. 2014.
- DAMA INTERNATIONAL. **The DAMA Guide to the Data Management Body of Knowledge (DAMA-DMBOK2)**. 2. ed. Bradley Beach, NJ: Technics Publications, 2017.
- DAVENPORT, T. H.; PRUSAK, L. **Conhecimento empresarial: como as organizações gerenciam seu capital intelectual**. 2. ed. Rio de Janeiro: Campus, 1998.
- FLORIDI, L. *et al.* AI4People – An Ethical Framework for a Good AI Society: Opportunities, Risks, Principles, and Recommendations. **Minds and Machines**, v. 28, n. 4, p. 689–707, 2018. Disponível em: <<https://doi.org/10.1007/s11023-018-9482-5>>. Acesso em: 5 maio 2025.
- GAMA, J. *et al.* A survey on concept drift adaptation. **ACM Computing Surveys (CSUR)**, v. 46, n. 4, p. 1–37, 2014.
- GOODMAN, B.; FLAXMAN, S. European Union regulations on algorithmic decision-making and a "right to explanation". **AI Magazine**, v. 38, n. 3, 2017. Disponível em: <<https://ojs.aaai.org/index.php/aimagazine/article/view/2741>>. Acesso em: 5 maio 2025.
- ISACA. **COBIT 5: A Business Framework for the Governance and Management of Enterprise IT**. Rolling Meadows, IL: ISACA, 2012.
- ISO/IEC. **ISO/IEC 38505-1:2017 Governance of Data for IT**. International Organization for Standardization, 2017
- KITCHIN, Rob. **Big Data: Principles and Paradigms**. Nature Publishing, 2014
- LU, J.; LI, Q.; YUAN, C. A Survey on Concept Drift Adaptation. **ACM Computing Surveys**, v. 54, n. 6, 2021.
- MACHADO, F. N. S. **Gestão do conhecimento, dados e informações**. São Paulo: Atlas, 2016.
- NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY. **AI Risk Management Framework (AI RMF 1.0)**. 2023. Disponível em: <<https://www.nist.gov/itl/ai-risk-management-framework>>. Acesso em: 5 maio 2025.

NIST. **AI Risk Management Framework** (AI RMF 1.0). National Institute of Standards and Technology, 2023. Disponível em: <<https://www.nist.gov/itl/ai-risk-management-framework>>. Acesso em: 5 maio 2025.

NONAKA, I.; TAKEUCHI, H. **The Knowledge-Creating Company**: How Japanese Companies Create the Dynamics of Innovation. Oxford: Oxford University Press, 1995.

OBERMAYER, Ziad; POWELL, Brian; VOGEL, Jonathon; ZOUBIN, Cynthia. Dissecting racial bias in an algorithm used to manage the health of populations. **Science**, v. 366, n. 6464, p. 447-453, 2019. Disponível em: <<https://www.science.org/doi/10.1126/science.aax2342>>. Acesso em: 5 maio 2025.

OPENAI. GPT-4 Technical Report. **OpenAI**, 2023. Disponível em: <<https://openai.com/research/gpt-4>>. Acesso em: 5 maio 2025

ORGANISATION FOR ECONOMIC CO-OPERATION AND DEVELOPMENT. **OECD Principles on Artificial Intelligence**. Paris: OECD Publishing, 2019. Disponível em: <<https://oecd.ai/en/dashboards/ai-principles>>. Acesso em: 5 maio 2025.

REUTERS. Amazon scraps secret AI recruiting tool that showed bias against women. **Reuters**, 10 out. 2018. Disponível em: <<https://www.reuters.com/article/world/insight-amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK0AG>>. Acesso em: 5 maio 2025.

WEILL, P.; ROSS, J. W. **IT Governance**: How Top Performers Manage IT Decision Rights for Superior Results. Boston: Harvard Business Press, 2004.

GLOSSÁRIO

<i>Accountability</i>	Capacidade de atribuir responsabilidade formal e documentada pelas decisões e operações realizadas em projetos de dados e IA.
Alucinação Algorítmica	Fenômeno em que sistemas de IA Generativa produzem informações falsas ou incorretas de maneira convincente.
Big Data	Conjunto de dados caracterizado por grande volume, variedade, velocidade, veracidade e valor, exigindo técnicas específicas para armazenamento, processamento e análise.
Viés dinâmico	Processo de evolução do viés algorítmico ao longo do tempo, à medida que modelos aprendem continuamente de novas bases de dados.
Ciclo de vida de dados e modelos	Sequência de fases pelas quais dados e modelos passam, desde a coleta e preparação até a modelagem, monitoramento e descarte.
Curadoria de dados	Conjunto de práticas destinadas a validar, classificar, limpar e catalogar dados para garantir sua qualidade e adequação aos objetivos analíticos.
Drift ético	Desalinhamento progressivo entre práticas tecnológicas e valores éticos sociais vigentes, exigindo revisão constante da governança.
Explainability	Capacidade de um sistema de IA de fornecer explicações compreensíveis sobre seus

	processos de decisão para stakeholders humanos.
Governança de Dados	Estrutura de políticas, processos e responsabilidades que assegura o gerenciamento ético, seguro e eficiente dos ativos de dados.
Governança de Inteligência Artificial	Estrutura organizacional que estabelece políticas, processos, métricas e responsabilidades para assegurar o uso ético, transparente e seguro de sistemas de IA.
Alucinação em IA	Produção de respostas factualmente incorretas ou inventadas por sistemas de IA Generativa.
LIME	Técnica de interpretabilidade de modelos de IA que gera explicações locais, aproximando o comportamento do modelo em torno de uma predição específica.
Model Drift	Desvio de comportamento de um modelo de IA ao longo do tempo, causado por mudanças no ambiente de dados ou contexto de aplicação.
Pessoas, Processos, Tecnologias e Dados	As quatro dimensões fundamentais da governança de IA e Big Data, cuja integração assegura práticas eficazes, éticas e sustentáveis.
SHAP	Método de interpretabilidade de modelos de IA baseado em Teoria dos Jogos, que atribui de forma precisa a contribuição de cada variável para a predição.