FIAP ON

03

CÉREBROS DE SILÍCIO: NEUROMORFISMO, MEMRISTORES E SIMULAÇÕES BIOLÓGICAS

PDF exclusivo para Murilo Salla - rm568041
murilosalla@protonmail.com

LISTA DE FIGURAS

Figura 1 - Elemento de Chua: relação entre carga e fluxo magnético.....8
Figura 2 - Curva I-V observada por pesquisadores da HP em 2008 9
Figura 3 - Curva I-V prevista teoricamente por Chua em 1976 10
Figura 4 - Chaveamentos resistivos: (a) eletroquímico, (b) por vacâncias e (c) por mudança de fase.....13
Figura 5 - Simulando chaveamento memristivo: emulando sinapses em circuitos eletrônicos.....15
Figura 6 - Gravação no Memristor (LRS) 18
Figura 7 - Leitura no LED (LSR).....19
Figura 8 - Gravação no memristor (HSR).....20
Figura 9 - Leitura no LED (HSR) 21
Figura 10 - Membrana Celular.....24
Figura 11 - Circuito elétrico equivalente para o modelo HH 25
Figura 12 - Circuito equivalente para o modelo de neurônio LIF.....29
Figura 13 - Tensão em função do tempo no modelo LIF.....37
Figura 14 - Comparação entre algoritmo (a) e matriz de barras cruzadas (b) para realizar operações de multiplicação-acumulação em Redes Neurais 41
Figura 15 - Comparação entre redes neurais de segunda geração (à esquerda) e de terceira geração (à direita) 43

FIAP

SUMÁRIO

1 CÉREBROS DE SILÍCIO: NEUROMORFISMO, MEMRISTORES E SIMULAÇÕES BIOLÓGICAS 4
1.1 Fundamentos das sinapses biológicas e artificiais 4
1.2 Modelos de sinapses artificiais com memristores 8
2 MODELOS DE NEURÔNIOS BIOLÓGICOS E ARTIFICIAIS: HODGKIN-HUXLEY E INTEGRA-E-DISPARA 23
2.1 Modelo de Hodgkin-Huxley na Computação Neuromórfica: Da biologia neuronal à emulação em hardware 23
2.2 Modelo Integra-e-Dispara: A engenharia por trás da Computação Neuromórfica eficiente 28
2.3 Modelos simplificados 33
3 SIMULAÇÕES DE CIRCUITOS RC PARA PRODUZIR COMPORTAMENTO NEURONAL 36
4 IMPLEMENTAÇÃO DE MODELOS UTILIZANDO CIRCUITOS ANALÓGICOS E DIGITAIS 40
REFERÊNCIAS 47

FIAP

1 CÉREBROS DE SILÍCIO: NEUROMORFISMO, MEMRISTORES E SIMULAÇÕES BIOLÓGICAS

A busca por sistemas computacionais mais eficientes, escaláveis e energeticamente econômicos motivou o desenvolvimento da computação neuromórfica. Inspirados no funcionamento do cérebro humano, tais sistemas buscam simular o comportamento de neurônios e sinapses utilizando componentes eletrônicos. Neste contexto, os memristores surgem como elementos promissores na construção de sinapses artificiais, por integrarem processamento e armazenamento de dados no mesmo componente físico.

1.1 Fundamentos das sinapses biológicas e artificiais

A estrutura biológica do cérebro humano apresenta um exemplo notável de sistema computacional altamente eficiente, adaptativo e distribuído. Composto por bilhões de neurônios interconectados através de trilhões de sinapses, o cérebro realiza processamento paralelo e aprendizado contínuo, operando com cerca de 20 watts de potência. Essa eficiência é resultado direto da maneira como os neurônios se organizam e processam informações, principalmente por meio das sinapses, que não só transmitem sinais, mas adaptam-se dinamicamente com base na experiência, através de processos como a potenciação de longo prazo (LTP) e a depressão de longo prazo (LTD).

Cada sinapse biológica atua como uma unidade de processamento e memória integrada. Os sinais recebidos pelos dendritos são somados no corpo celular (soma), onde uma decisão é tomada: se a soma ultrapassar um limiar, o neurônio dispara um potencial de ação ao longo do axônio, transmitindo o sinal para outras células através das sinapses. Esse ciclo de integração, disparo e adaptação sináptica confere ao cérebro sua plasticidade, permitindo aprendizagem e formação de memória em tempo real.

Inspirada nessa arquitetura biológica, a computação neuromórfica propõe sistemas que integram processamento e armazenamento local, rompendo com o paradigma sequencial e energeticamente ineficiente da arquitetura de von Neumann.

Essa última impõe uma separação rígida entre processador e memória, gerando o conhecido gargalo de von Neumann — o que limita a velocidade e aumenta o consumo energético dos sistemas computacionais tradicionais.

Na arquitetura neuromórfica, o foco está em replicar as propriedades fundamentais do cérebro: conectividade massiva, processamento paralelo e plasticidade adaptativa. Para isso, são necessários dispositivos eletrônicos capazes de operar de forma análoga às sinapses biológicas — ou seja, que possam armazenar estados sinápticos, modificá-los com base na atividade e realizar operações de integração de sinais. É nesse contexto que surgem os memristores (do inglês *memory resistor*), componentes eletrônicos cuja resistência depende do histórico de corrente que os atravessa. Como as sinapses biológicas, os memristores possuem a capacidade de:

- Armazenar informação localmente, mesmo sem energia;
- Modificar sua condutância de forma contínua ou discreta, simulando a LTP/LTD;
- Realizar integração de sinais e responder de forma não linear a estímulos repetidos;
- Associar a condutância ao tempo e à frequência dos sinais, permitindo aprendizado local.

Em outras palavras, os memristores são os dispositivos que mais se aproximam, atualmente, do comportamento sináptico biológico, não apenas por sua capacidade funcional, mas também por sua viabilidade de fabricação em escala nanométrica, baixo consumo energético e possibilidade de organização em redes altamente conectadas.

A motivação para seu uso em sistemas neuromórficos reside, portanto, na convergência funcional com as sinapses naturais. A arquitetura do cérebro e seu mecanismo de processamento integrado de dados tornam-se modelo e justificativa técnica para buscar componentes que transcendam os limites da computação digital convencional. Os memristores surgem como ponte entre a eletrônica clássica e os sistemas bioinspirados, viabilizando a construção de hardware com capacidades adaptativas, robustez a falhas e baixo custo computacional.

Com essa motivação consolidada, agora é possível avançar para a descrição técnica dos memristores — sua estrutura, funcionamento físico e papel central no paradigma da memcomputação —, além de discutir seus desafios tecnológicos e aplicações práticas em sinapses artificiais.

As sinapses biológicas não apenas conectam neurônios, mas também modulam a força dessas conexões em função da experiência acumulada. Esse processo adaptativo é denominado plasticidade sináptica e é a base do aprendizado e da memória nos sistemas vivos. Nos sistemas artificiais, essa propriedade é implementada por meio de dispositivos cuja condutância pode ser alterada em resposta ao histórico de atividade, como ocorre nos memristores.

Além dos memristores, outros dispositivos têm sido investigados como candidatos a sinapses artificiais, incluindo transistores de efeito de campo modificados, dispositivos ferroelétricos e estruturas baseadas em materiais de mudança de fase. Cada tecnologia oferece vantagens específicas — como velocidade, durabilidade ou compatibilidade com tecnologias CMOS —, mas todas compartilham um mesmo objetivo: imitar a modulação sináptica observada na biologia.

A implementação de sinapses artificiais eficientes depende não apenas das propriedades dos materiais, mas também da arquitetura geral dos sistemas neuromórficos. Redes altamente conectadas, como as organizadas em arrays do tipo crossbar, permitem a interligação de milhares de sinapses artificiais com consumo reduzido de área e energia. Essa densidade de integração é essencial para atingir níveis de paralelismo comparáveis aos do cérebro.

A fidelidade com que um dispositivo eletrônico pode simular uma sinapse biológica depende, ainda, de sua capacidade de representar múltiplos estados de condutância. Enquanto sinapses biológicas operam de forma contínua e dinâmica, muitos dispositivos eletrônicos ainda se limitam a transições discretas entre estados, o que representa um desafio técnico importante.

Outro aspecto fundamental é a temporalidade das respostas sinápticas. Sinapses reais respondem de maneira diferente a estímulos com distintas frequências e padrões temporais, fenômeno que influencia diretamente os processos de aprendizado. A replicação desse comportamento em sistemas artificiais requer

circuitos capazes de detectar e adaptar-se ao tempo de chegada dos sinais, muitas vezes com precisão na faixa de milissegundos ou inferior.

Do ponto de vista computacional, modelos matemáticos como o de Hebb, STDP (Spike-Timing-Dependent Plasticity) e BCM (Bienenstock, Cooper e Munro) servem de base teórica para a implementação de algoritmos de aprendizado sináptico em hardware. Esses modelos orientam como a condutância de um dispositivo deve ser modificada com base na correlação entre os sinais de entrada e saída.

A combinação entre dispositivos físicos programáveis e modelos computacionais bem estabelecidos permite o desenvolvimento de sistemas híbridos, em que elementos analógicos e digitais cooperam para simular funções sinápticas com alta eficiência. Essa abordagem híbrida é uma das mais promissoras para superar os desafios técnicos atuais e alcançar níveis de desempenho comparáveis aos dos sistemas biológicos.

Em paralelo, a integração de sensores com redes sinápticas artificiais está permitindo o desenvolvimento de sistemas sensoriais neuromórficos, capazes de processar informações visuais, auditivas ou táteis em tempo real. Nesses casos, as sinapses não apenas transmitem sinais, mas participam ativamente do pré-processamento sensorial, realizando filtragem, detecção de padrões e aprendizado contextual.

A robustez das sinapses artificiais frente a ruídos e falhas é outro fator relevante. Inspiradas no cérebro, essas conexões artificiais podem ser projetadas para continuar operando mesmo com perdas parciais de elementos da rede, o que confere resiliência e adaptabilidade a sistemas críticos como veículos autônomos, robótica e dispositivos médicos implantáveis.

A tendência de miniaturização e integração de sinapses artificiais a processadores neuromórficos em plataformas portáteis abre novas possibilidades para a Computação Edge, na qual o processamento ocorre próximo à fonte de dados. Essa descentralização reduz a latência, o consumo de energia e a dependência de redes de comunicação externas.

Por fim, o estudo e a implementação de sinapses artificiais não são apenas um exercício de engenharia, mas também uma oportunidade de aprofundar nosso entendimento sobre os próprios princípios do funcionamento cerebral. Ao tentar

replicar o cérebro, aprendemos mais sobre ele — e, ao mesmo tempo, pavimentamos o caminho para uma nova geração de tecnologias computacionais mais inteligentes, eficientes e adaptativas.

1.2 Modelos de sinapses artificiais com memristores

O conceito de memristor foi proposto pelo pesquisador Leon Chua em 1971, ao postular a existência de um quarto elemento fundamental de circuito além do resistor, do capacitor e do indutor.

Enquanto os três elementos clássicos relacionam tensão, corrente e suas integrais (carga e fluxo magnético), Chua demonstrou que havia uma lacuna entre as variáveis carga elétrica (q) e fluxo magnético (φ), que não era diretamente coberta por nenhum dos elementos tradicionais.

O memristor, nomeado como contração de *memory resistor*, foi então proposto para preencher essa lacuna, estabelecendo uma relação direta entre carga e fluxo, como ilustrado na figura “Elemento de Chua: relação entre carga e fluxo magnético”.

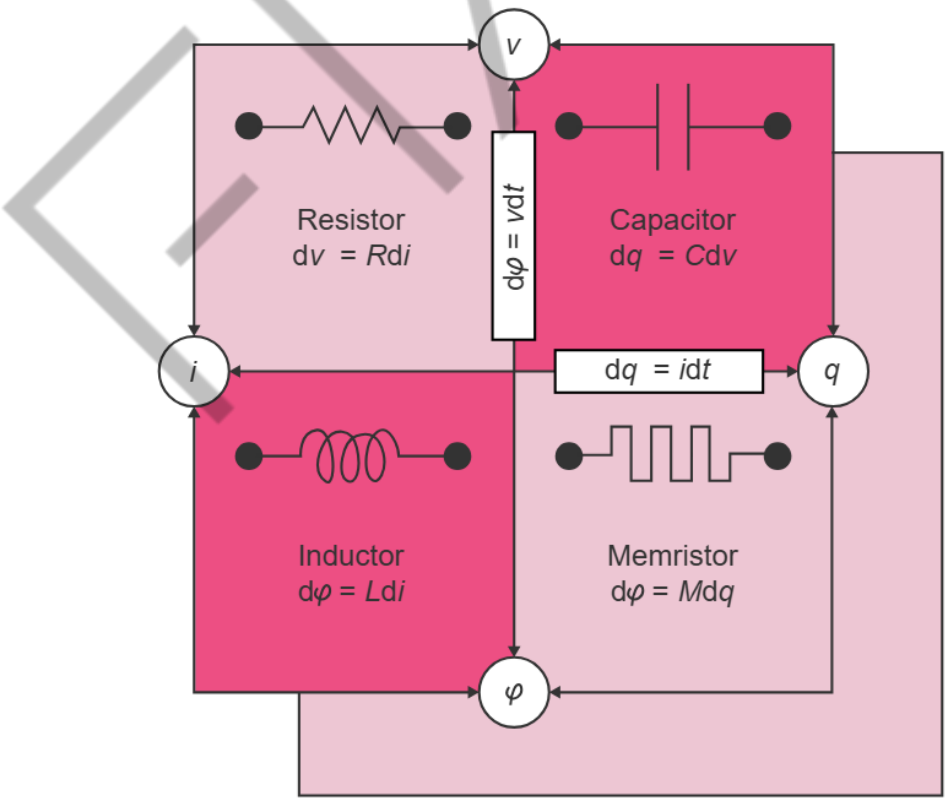


Figura 1 - Elemento de Chua: relação entre carga e fluxo magnético
Fonte: Chua; Kang (1976); Strukov *et al*. (2008), adaptado pelo autor (2025)

É possível observar na figura que, para cada par de variáveis fundamentais do eletromagnetismo — tensão v, corrente i, carga q e fluxo magnético (φ) —, existe um componente que as relaciona: o resistor relaciona v e i; o capacitor relaciona v e q; o indutor relaciona i e φ; e, finalmente, o memristor relaciona diretamente q e φ, fechando o ciclo teórico proposto por Chua.

Esse diagrama não apenas ilustra a completude matemática da teoria dos elementos de circuito, como também fundamenta a motivação para a busca por um componente físico que realizasse tal função.

Foi apenas em 2008 que pesquisadores do laboratório da Hewlett-Packard (HP Labs), liderados por Strukov, apresentaram evidências experimentais da existência física do memristor. Eles demonstraram que dispositivos construídos a partir de camadas de dióxido de titânio (TiO_2), intercaladas entre eletrodos metálicos de platina (Pt), exibiam características compatíveis com o comportamento previsto para memristores.

A estrutura básica desse dispositivo é apresentada na figura “Curva I–V observada por pesquisadores da HP em 2008”, evidenciando o empilhamento das camadas ativas.

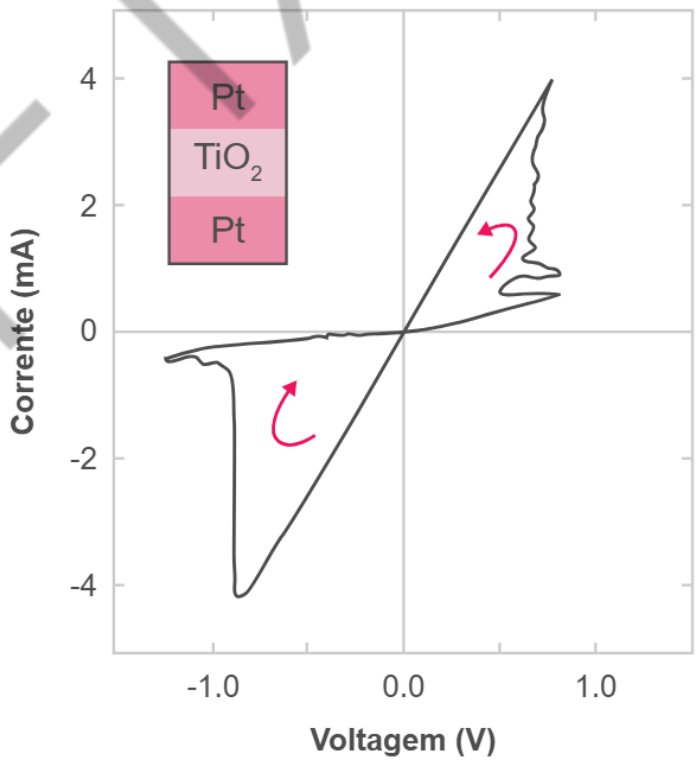


Figura 2 - Curva I-V observada por pesquisadores da HP em 2008
Fonte: Chua; Kang (1976); Strukov *et al*. (2008), adaptado pelo autor (2025)

Um dos principais comportamentos previstos por Chua era a histerese na curva corrente *versus* tensão (I-V), que deveria assumir uma forma de “laço de borboleta”, com a largura do laço variando conforme a frequência do sinal aplicado.

Essa característica é ilustrada na figura “Curva I-V prevista teoricamente por Chua em 1976”, em que se pode observar o estreitamento do laço histerético à medida que a frequência aumenta. Em altas frequências, o comportamento do dispositivo tende a se aproximar de um resistor linear, uma vez que o tempo de resposta iônico se torna insuficiente para alterar significativamente o estado interno do dispositivo. Já em baixas frequências, o laço se abre mais, evidenciando a dependência do estado condutivo em relação ao histórico de tensão aplicada.

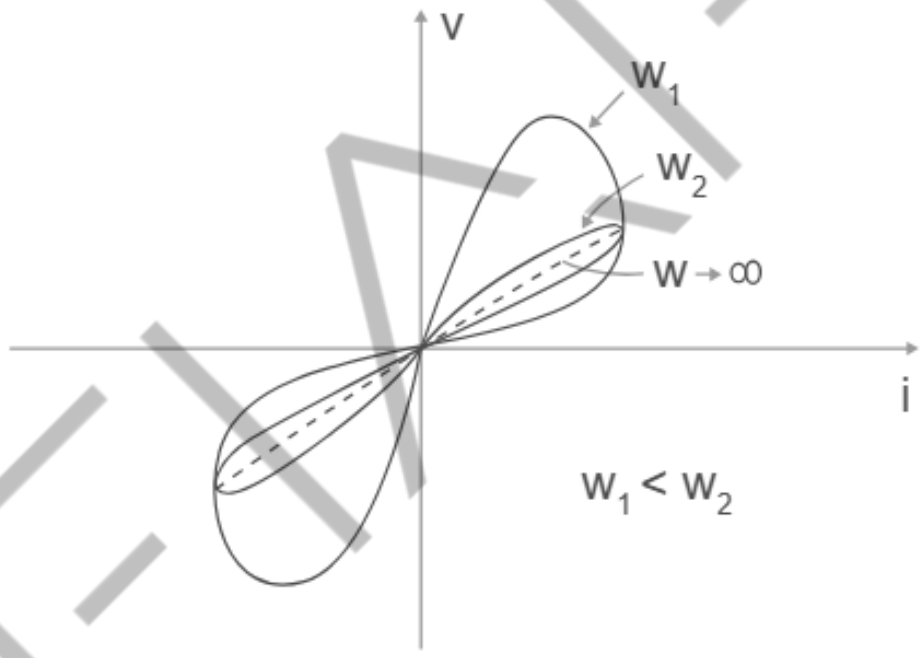


Figura 3 - Curva I-V prevista teoricamente por Chua em 1976
Fonte: Chua; Kang (1976); Strukov *et al*. (2008), adaptado pelo autor (2025)

Na figura “Elemento de Chua: relação entre carga e fluxo magnético”, são apresentados dados experimentais reais obtidos pelos pesquisadores da HP, nos quais se confirma o comportamento de histerese previsto na teoria, validando a existência física do memristor conforme originalmente concebido. Observa-se que a corrente varia de maneira não linear com a tensão, e a área interna do laço I-V depende da taxa de variação do estímulo, o que demonstra a propriedade de memória de estado do dispositivo.

Do ponto de vista físico, o funcionamento do memristor está associado à movimentação de íons de oxigênio ou vacâncias iônicas dentro da camada de dióxido

de titânio. Quando uma tensão é aplicada, esses íons migram, modificando a região de condução elétrica e, consequentemente, a resistência efetiva do dispositivo. É importante destacar que essa modificação persiste mesmo após a retirada da tensão, caracterizando o comportamento não volátil do memristor — uma propriedade desejável para aplicações em memórias e sinapses artificiais.

Em síntese, os memristores são dispositivos passivos de dois terminais cuja resistência varia de acordo com o histórico de corrente ou tensão aplicada, possuindo a capacidade de “lembrar” seu estado condutivo anterior. Essa característica os torna candidatos ideais para representar sinapses artificiais em sistemas neuromórficos. Assim como as sinapses biológicas ajustam sua eficiência sináptica com base na atividade elétrica, os memristores ajustam sua condutância em resposta aos estímulos aplicados, possibilitando a implementação de aprendizado local e plasticidade sináptica diretamente no hardware.

O chaveamento resistivo em memristores é um fenômeno ativado por um campo elétrico, que se manifesta a partir de um limiar de tensão característico. Isso significa que o dispositivo memristivo apresenta duas regiões de operação distintas: uma faixa de tensão inferior ao limiar, no qual o material permanece em um estado estável sem alterações significativas na resistência elétrica — denominada região de leitura —; e outra faixa, acima desse limiar, em que o campo elétrico é suficientemente intenso para induzir uma mudança no estado resistivo do material — denominada região de escrita.

Essa separação entre as regiões de leitura e escrita permite o controle preciso do estado do memristor, o que é crucial para sua aplicação em redes neurais artificiais. Durante o treinamento de uma rede, sinais mais intensos podem ser aplicados para modificar os pesos sinápticos, enquanto leituras com sinais mais fracos evitam a alteração inadvertida dos estados memorizados.

Além disso, o formato do laço de histerese I-V depende diretamente da frequência do sinal aplicado. Em baixas frequências, a histerese é mais pronunciada, evidenciando a propriedade de memória do dispositivo, enquanto em altas frequências o comportamento tende a se linearizar, aproximando-se do de um resistor convencional. Essa dependência temporal reforça o caráter dinâmico e adaptativo do memristor.

A escalabilidade dos memristores é outro fator importante a ser considerado. Devido à sua estrutura simples e à possibilidade de fabricação em nanoescala, esses dispositivos podem ser organizados em matrizes densas, conhecidas como crossbar arrays, permitindo a construção de redes sinápticas altamente integradas com consumo mínimo de energia.

Em aplicações neuromórficas, a integração de memristores com circuitos CMOS é uma estratégia recorrente, possibilitando a combinação de lógica digital tradicional com propriedades sinápticas analógicas. Isso favorece o desenvolvimento de arquiteturas híbridas, que se beneficiam da precisão digital e da flexibilidade adaptativa dos elementos memristivos.

É importante destacar que os memristores também podem ser programados com diferentes algoritmos de atualização de condutância, como Spike-Timing Dependent Plasticity, reforçando ainda mais a sua analogia funcional com as sinapses biológicas e ampliando suas aplicações em sistemas de aprendizagem não supervisionado.

Além disso, diferentes mecanismos físicos de chaveamento resistivo podem ser explorados para aprimorar ainda mais o desempenho e a adequação dos memristores a determinadas aplicações neuromórficas.

Essas mudanças resistivas ocorrem por diferentes mecanismos físicos, a depender da composição do dispositivo, sendo os principais: movimentação de vacâncias de oxigênio, metalização eletroquímica e mudança de fase do material ativo, como ilustrado na figura “Chaveamentos resistivos: (a) eletroquímico, (b) por vacâncias e (c) por mudança de fase”.

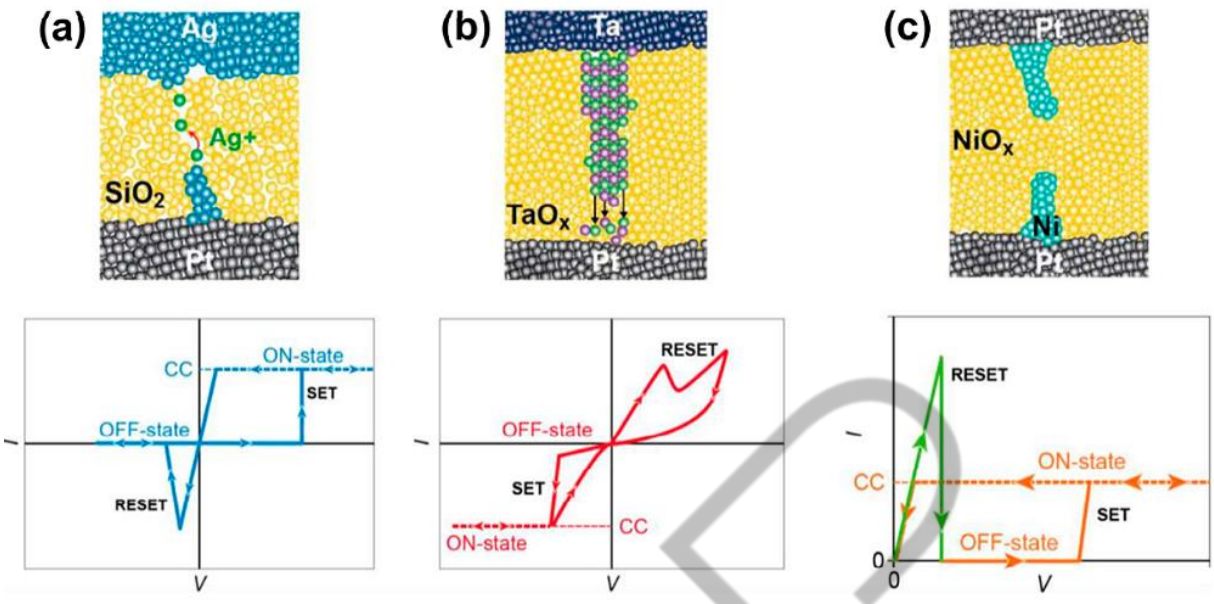


Figura 4 - Chaveamentos resistivos: (a) eletroquímico, (b) por vacâncias e (c) por mudança de fase
Fonte: Valov (2017)

No caso da metalização eletroquímica (ECM — ElectroChemical Metallization), representada no painel (a) da figura “Chaveamentos resistivos: (a) eletroquímico, (b) por vacâncias e (c) por mudança de fase”, o mecanismo baseia-se na utilização de um eletrodo ativo composto por metais como prata (Ag), cobre (Cu) ou níquel (Ni).

Quando um campo elétrico suficientemente elevado é aplicado, ocorre a oxidação do eletrodo ativo, gerando cátions metálicos (por exemplo, Ag^+), que migram por deriva e difusão através de uma camada dielétrica (como óxidos, selenetos ou sulfetos) até um eletrodo inerte (como Pt).

Esses íons metálicos se reduzem ao alcançar o eletrodo oposto, formando filamentos condutores entre os eletrodos, o que reduz a resistência da estrutura — um estado conhecido como baixa resistência (LRS). Esse tipo de chaveamento é bipolar, pois depende da polaridade do campo elétrico para formação e dissolução do filamento.

Já no mecanismo por deslocamento de vacâncias (VCM — Valence Change Memory), apresentado no painel (b) da figura “Chaveamentos resistivos: (a) eletroquímico, (b) por vacâncias e (c) por mudança de fase”, o chaveamento ocorre pela movimentação de vacâncias de oxigênio no interior de um óxido metálico, como o Ta_2O_5.

A aplicação de uma tensão provoca a migração dessas vacâncias, modificando localmente a condutividade do material. A acumulação ou dispersão das vacâncias forma ou rompe caminhos condutivos, permitindo alternar entre estados de alta resistência (HRS) e baixa resistência (LRS). Este mecanismo também é não volátil e bipolar, sendo a resistência modulada por processos iônicos internos ao material.

Por fim, o mecanismo de mudança de fase (PCM — Phase Change Memory), representado no painel c da figura “Chaveamentos resistivos: (a) eletroquímico, (b) por vacâncias e (c) por mudança de fase”, utiliza materiais baseados em calcogenetos, que podem alternar entre fases amorfa e cristalina mediante aquecimento induzido por pulsos elétricos. Inicialmente, o material está em estado amorfo (alta resistência).

Um pulso elétrico intenso ocasiona o aquecimento por efeito Joule, levando o material ao ponto de fusão. Ao interromper rapidamente o pulso (resfriamento abrupto), o material retorna ao estado amorfo. Se, por outro lado, for aplicado um pulso elétrico mais longo com resfriamento gradual, o material se reorganiza para a fase cristalina (baixa resistência). Esse processo é reversível e permite o controle preciso do estado resistivo por meio do perfil temporal e da intensidade dos pulsos aplicados.

Dessa forma, os diferentes tipos de chaveamento resistivo em memristores se baseiam em mecanismos distintos de transporte e modulação de propriedades materiais, sendo fundamentais para aplicações em memória não volátil, lógica reconfigurável e sistemas neuromórficos.

Os memristores são componentes fundamentais para a construção de sistemas que mimetizam o funcionamento de sinapses biológicas, devido à sua capacidade de armazenar estados resistivos distintos em resposta à aplicação de diferentes tensões.

No contexto da eletrônica neuromórfica, esses estados podem representar os pesos sinápticos em redes neurais artificiais.

Dica: para visualizar e explorar esse comportamento de forma prática, é possível utilizar o simulador online Falstad, disponível em: <https://www.falstad.com/circuit>.

Agora vamos aprender como montar um circuito simples que permita observar o efeito de chaveamento resistivo. Primeiramente, assista ao vídeo: <https://www.youtube.com/watch?v=W_Mn4YWblvk>.

Em seguida, acesse o simulador e insira os seguintes componentes (conforme o diagrama apresentado na figura “Simulando chaveamento memristivo: emulando sinapses em circuitos eletrônicos”):

- Três fontes de tensão, sendo uma de 3V, uma de -9V e uma de 9V (Desenhar > Entradas e Fontes > Inserir Fonte de Tensão CC (2 terminais));
- Três resistores de 1 kΩ (Desenhar > Inserir resistor) e um memristor (Desenhar > Componentes Passivos > Inserir Resistor com memória);
- Três chaves simples (Desenhar > componentes passivos > Inserir chave) e um LED (Desenhar > Saídas e Rótulos > Inserir LED).

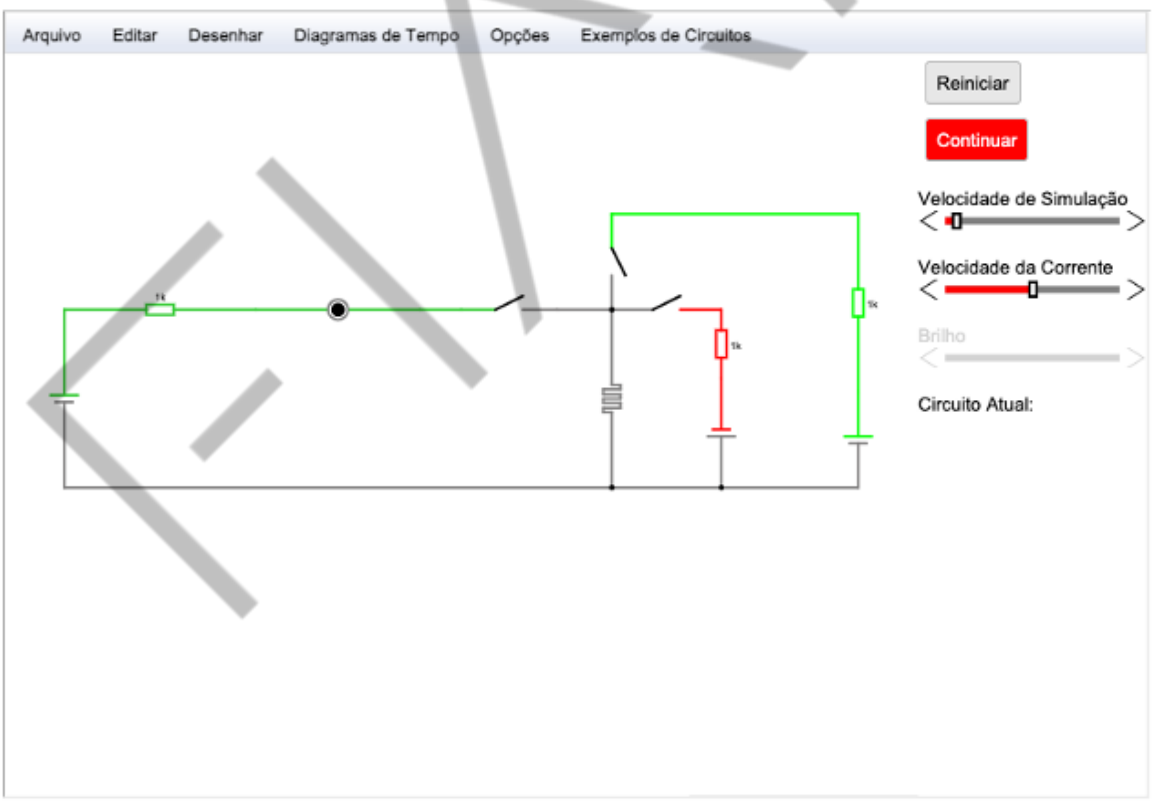


Figura 5 - Simulando chaveamento memristivo: emulando sinapses em circuitos eletrônicos
Fonte: Elaborado pelo autor (2025)

O circuito pode ser montado conectando todos os dispositivos. Ao ajustar as tensões das fontes e resistores (acionando um duplo clique do mouse sobre o dispositivo), conforme apresentado no vídeo, é possível verificar se o LED acende

com intensidade forte (indicando baixa resistência no memristor — estado "1") ou fraca/desligada (alta resistência — estado "0").

Para garantir a montagem correta do circuito, é importante utilizar os fios de conexão do simulador (Desenhar > Fios) com cuidado para não deixar conexões soltas. O Falstad permite reposicionar os elementos com facilidade, o que ajuda a manter o diagrama limpo e compreensível.

Outro recurso útil do simulador é a visualização em tempo real das correntes e tensões. Quando o circuito está ativado (Botão “Run/Stop”), surgem setas indicando o fluxo de corrente, e os valores de tensão são exibidos ao lado dos componentes, facilitando a análise do funcionamento do memristor em diferentes condições.

Durante a simulação, recomenda-se testar o acionamento das chaves em diferentes sequências. Isso permite observar como o memristor reage a estímulos distintos e quais combinações acendem o LED. Esses testes são importantes para entender o papel de cada fonte de tensão no processo de chaveamento.

Para simular o processo de "escrita" e "leitura" do estado resistivo, uma prática comum é aplicar um pulso de maior tensão com uma das fontes (por exemplo, 9V ou -9V) e depois alternar para uma fonte de menor tensão (como 3V) para verificar o estado armazenado. Essa técnica é frequentemente utilizada para emular sinapses eletrônicas.

O Falstad permite ainda alterar parâmetros dos componentes clicando duas vezes sobre eles. No caso do memristor, é possível ajustar os valores mínimo e máximo de resistência, assim como a taxa de variação. Esses ajustes tornam a simulação mais realista e personalizável de acordo com o tipo de comportamento sináptico desejado.

É interessante também utilizar o botão "Scope" (osciloscópio) do simulador, conectando-o entre dois pontos do circuito para observar a variação da tensão em função do tempo. Esse recurso é valioso especialmente quando se deseja analisar a resposta dinâmica do memristor durante mudanças rápidas no circuito.

Ao concluir a montagem e os testes, o simulador oferece a opção de salvar o circuito (File > Export As Text), permitindo que o usuário compartilhe ou reutilize o projeto posteriormente. Esse recurso é ideal para documentar variações de circuito ou realizar comparações entre diferentes configurações.

Além disso, caso ocorra qualquer erro de montagem, o Falstad oferece feedback imediato: componentes desconectados, polaridades invertidas ou fontes incompatíveis com o circuito são facilmente identificáveis, o que torna o processo de aprendizagem mais intuitivo e seguro.

Por fim, a repetição controlada dos testes no simulador ajuda a reforçar o entendimento sobre como o chaveamento resistivo pode ser controlado eletricamente. Essa abordagem prática torna os conceitos de sinapses artificiais mais acessíveis, mesmo para iniciantes, além de abrir espaço para futuras aplicações em projetos mais complexos de eletrônica neuromórfica.

Outro aspecto interessante do Falstad é a possibilidade de inserir anotações diretamente no circuito (Desenhar > Rótulo de texto), o que permite destacar pontos importantes, indicar os estados dos componentes ou organizar o raciocínio durante a análise. Isso é especialmente útil em atividades didáticas ou na elaboração de relatórios técnicos.

Procedimento de gravação e leitura no Memristor — Sistema com Baixa Resistência (LRS):

A **gravação no Memristor** (figura “Gravação no Memristor (LSR)”) é utilizada para configurá-lo em um estado de baixa resistência (conhecido como Low Resistance State ou LRS). Para isso, é necessário realizar um processo de gravação que simula uma analogia com o reforço de uma conexão sináptica em um sistema neuromórfico. O procedimento envolve a aplicação de uma tensão adequada e a observação do comportamento da corrente no circuito:

- **Aplicar tensão de gravação:** utilize uma fonte de +9V conectada ao memristor por meio de uma chave (switch). Quando esta chave é ativada, a tensão é aplicada ao componente. Caso a tensão seja positiva e suficientemente alta, o memristor entra no estado de baixa resistência (LRS), permitindo maior fluxo de corrente — isso simula o “reforço” de uma conexão ou aprendizado (estado "1").
- **Configurar simulação:** no menu "Velocidade de Simulação", ajuste a velocidade para visualizar o fluxo de corrente reversa durante a gravação. A corrente negativa durante este processo aumenta a resistência do memristor.

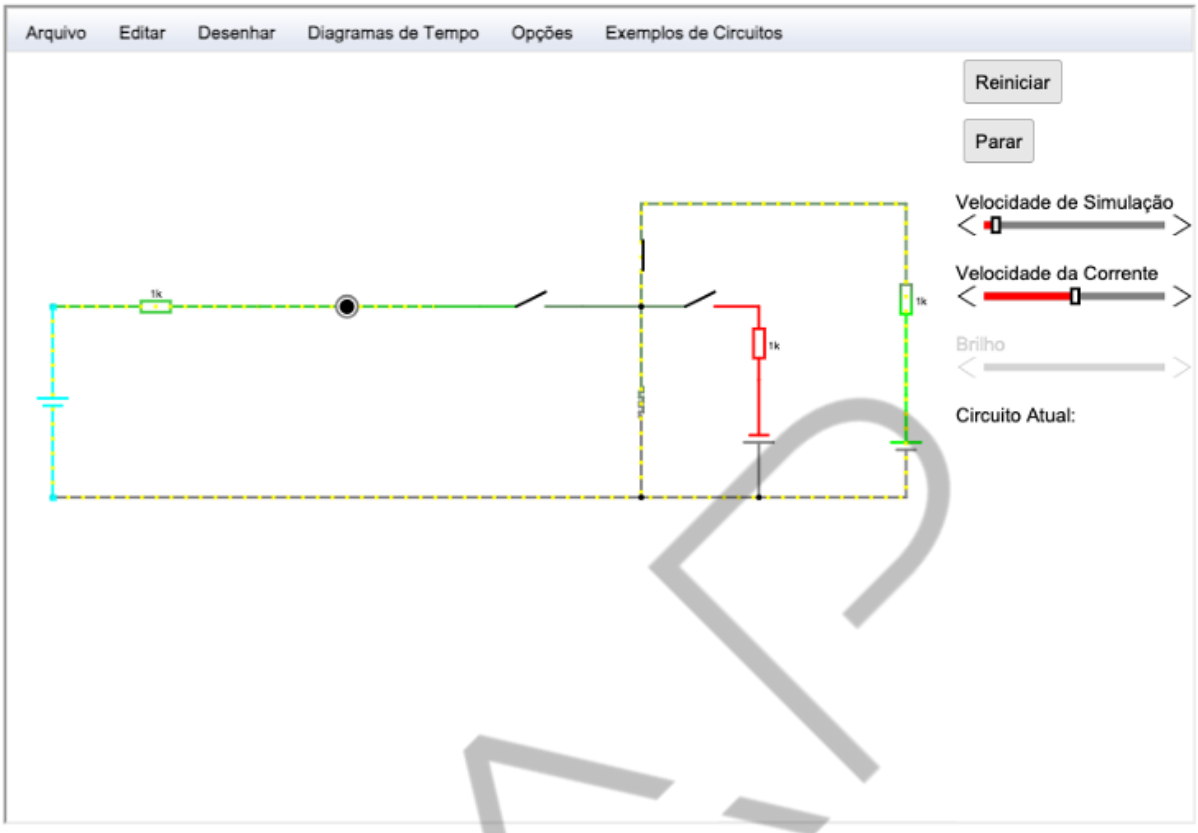


Figura 6 - Gravação no Memristor (LRS)
Fonte: Elaborado pelo autor (2025)

A **leitura no LED** (figura “Leitura no LED (LSR)”) tem como objetivo realizar a leitura do estado do memristor e verificar sua condição de baixa resistência (LRS). Por isso, siga atentamente os seguintes passos:

- **Aplicar tensão de leitura:** conecte a fonte de 3V por meio de uma chave dedicada ao circuito que contém o memristor em série com o LED. Essa tensão foi escolhida por ser suficientemente baixa para não induzir mudanças no estado do memristor — ou seja, não alterando sua resistência —, mas ainda alta o bastante para permitir uma leitura confiável do seu estado atual. A corrente que flui pelo circuito neste momento é diretamente proporcional à condutância do memristor.
- **Observar o LED:** a intensidade luminosa do LED serve como indicador visual direto do estado do memristor: o LED brilhante indica que o memristor está em estado de baixa resistência (LRS, estado "1"), permitindo que uma corrente significativa circule pelo circuito e excite o LED. O brilho intenso é resultado da maior corrente que flui através do memristor em LRS,

demonstrando claramente a condição de “sinapse fortalecida” no contexto neuromórfico.

- **Ajustar visualização:** use o controle "Brilho" para melhorar a visualização do LED se necessário.

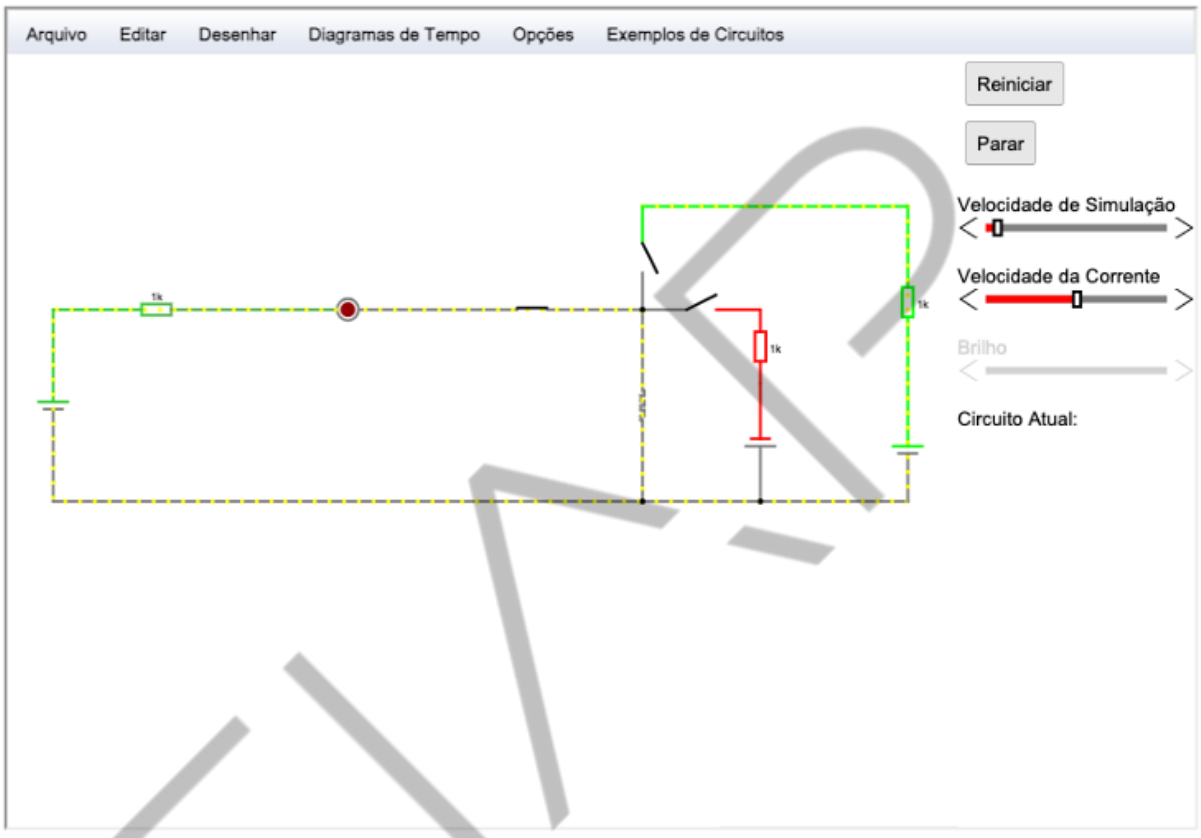


Figura 7 - Leitura no LED (LSR)
Fonte: Elaborado pelo autor (2025)

Procedimento de gravação e leitura no Memristor — Sistema com Alta Resistência (HRS):

A **Gravação no Memristor** (figura “Gravação no Memristor (HSR)”) tem como objetivo configurá-lo em um estado de alta resistência (conhecido como High Resistance State ou HRS), o qual pode ser interpretado como uma “sinapse enfraquecida” ou como a codificação de um dado ausente ou inválido no sistema. Esse estado é fundamental para representar uma interrupção ou bloqueio de sinal — por exemplo, a ausência de um comportamento padrão ou a identificação de um desvio.

- **Aplicar tensão de gravação:** utilize uma fonte de -9V conectada ao memristor por meio de uma chave (switch). Quando essa tensão negativa

elevada é aplicada, o memristor aumenta significativamente sua resistência, passando para o estado de alta resistência (HRS), que representa o estado lógico "0". Esse comportamento é análogo ao enfraquecimento ou desligamento de uma conexão sináptica — o sistema “esquece” ou marca aquele caminho como inválido.

- **Configurar simulação:** no menu "Velocidade de Simulação", ajuste a velocidade para visualizar o fluxo de corrente reversa durante a gravação. A corrente negativa durante esse processo aumenta a resistência do memristor.

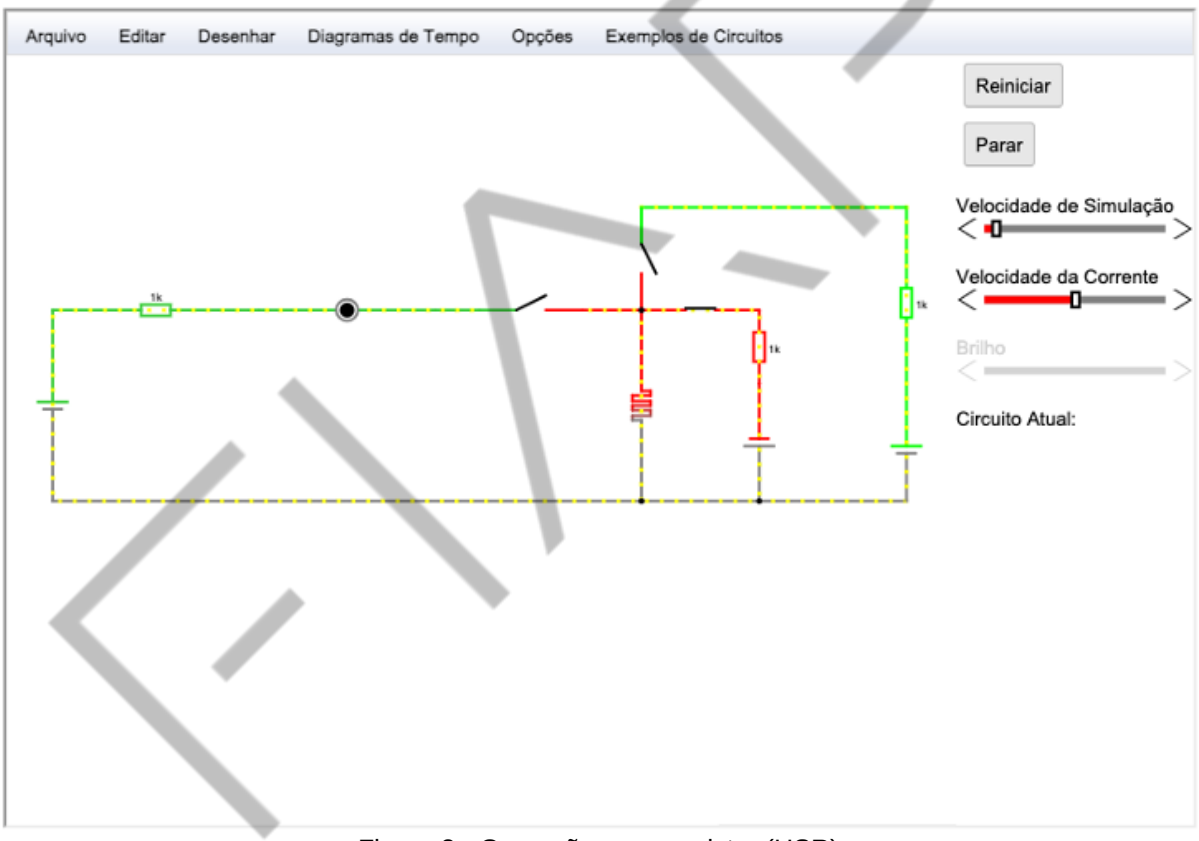


Figura 8 - Gravação no memristor (HSR)
Fonte: Elaborado pelo autor (2025)

A **Leitura no LED** (figura “Leitura no LED (HSR)”) ocorre após a gravação do estado de alta resistência no memristor (HRS), quando é necessário verificar visualmente o estado gravado sem alterá-lo. Isso é feito com uma tensão de leitura baixa e a observação de um componente indicador, como o LED. Os passos necessários são:

- **Aplicar tensão de leitura:** conecte uma fonte de 3V ao circuito por meio de uma segunda chave. Essa fonte deve estar ligada em série com o memristor

e um LED, formando um caminho de corrente controlada. A escolha de 3V garante que a tensão seja suficiente para iluminar o LED, mas baixa o bastante para não alterar o estado interno do memristor.

- **Observar o LED:** ao fechar o circuito, observe se o LED acende. Se o memristor estiver em estado de alta resistência (HRS), a corrente no circuito será muito baixa, o que fará com que o LED permaneça apagado ou com brilho extremamente fraco. Esse comportamento representa a presença de um obstáculo ou bloqueio na condução elétrica, coerente com o estado lógico “0”.

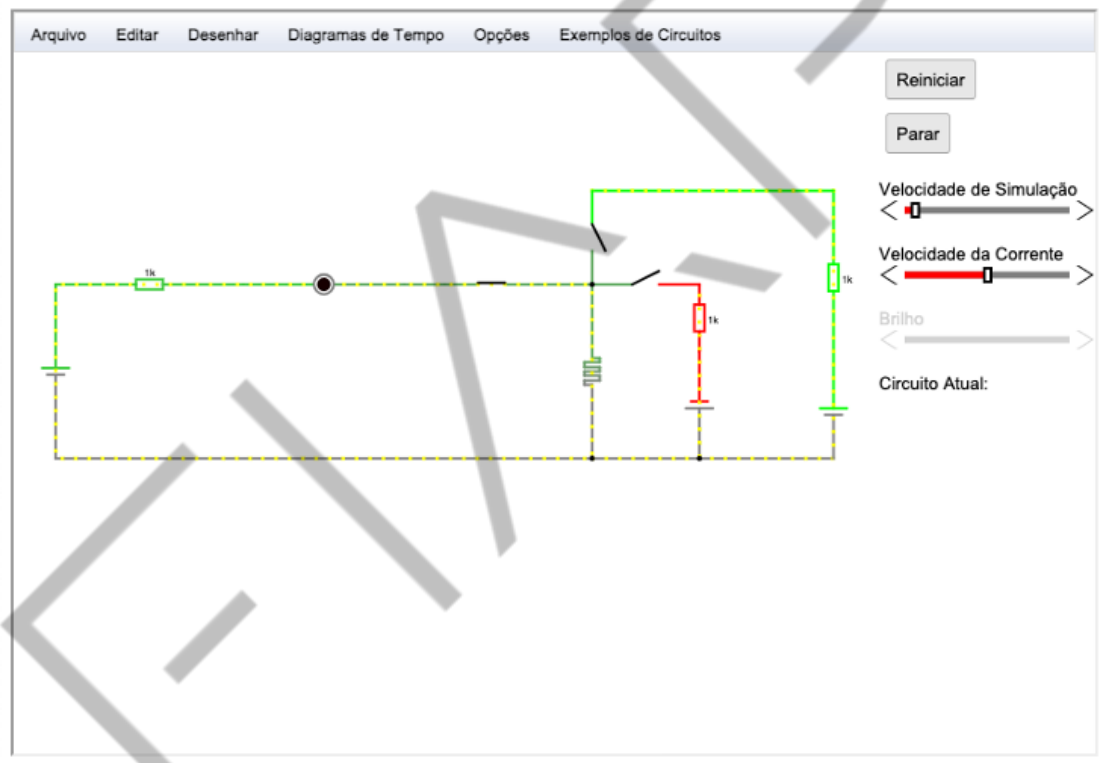


Figura 9 - Leitura no LED (HSR)
Fonte: Elaborado pelo autor (2025)

O experimento demonstra o princípio de chaveamento resistivo em memristores, simulando o comportamento de sinapses biológicas. Ao aplicar tensões positivas (+9V) ou negativas (-9V), o memristor alterna entre estados de baixa (LRS) e alta resistência (HRS), representando o fortalecimento ou enfraquecimento sináptico, respectivamente.

A leitura com 3V, indicada pelo brilho do LED, mostra como o componente “memoriza” seu estado anterior, similar à plasticidade sináptica em neurônios. O circuito replica a capacidade de armazenar informações não voláteis, em que a

resistência do memristor atua como um análogo ao peso sináptico em Redes Neurais Artificiais.

O circuito eletrônico mimetiza dois processos-chave das sinapses:

- **Plasticidade** — adaptação da resistência conforme estímulos elétricos, como a potenciação ou depressão sináptica;
- **Armazenamento de informação** — retenção do estado resistivo, análogo à memória de curto/longo prazo em neurônios.

Assim como as sinapses biológicas modificam sua eficácia mediante atividade elétrica (por exemplo, via LTP e LTD), o memristor altera sua resistência com tensões aplicadas. Isso permite a implementação de sistemas neuromórficos que emulam aprendizagem e processamento de informações no cérebro.

A leitura com 3V é não destrutiva, isto é, preserva o estado do memristor para operações subsequentes, característica essencial para aplicações em memórias resistivas e circuitos neuromórficos.

2 MODELOS DE NEURÔNIOS BIOLÓGICOS E ARTIFICIAIS: HODGKIN-HUXLEY E INTEGRA-E-DISPARA

Na Computação Neuromórfica, a emulação eficiente do comportamento neuronal é fundamental para o desenvolvimento de sistemas inteligentes e adaptativos. Dois modelos destacam-se nesse contexto: o **Hodgkin-Huxley (HH)**, uma descrição biofísica detalhada da dinâmica de canais iônicos em neurônios reais, e o **Integra-e-Dispara**, uma abstração simplificada que captura a essência do processamento neural com menor complexidade computacional.

Esta seção explora esses modelos, contrastando sua fidelidade biológica com sua aplicabilidade prática em hardware neuromórfico, em que trade-offs entre precisão e eficiência energética são cruciais. Enquanto Hodgkin-Huxley oferece insights para interfaces cérebro-máquina, Integra-e-Dispara possibilita implementações em larga escala, essenciais para Redes Neurais Artificiais em chips dedicados.

2.1 Modelo de Hodgkin-Huxley na Computação Neuromórfica: Da biologia neuronal à emulação em hardware

O modelo de Hodgkin-Huxley tem suas raízes em experimentos fisiológicos pioneiros realizados na década de 1950 por Alan Hodgkin e Andrew Huxley, utilizando axônios gigantes de lulas. Esses axônios, devido ao seu grande diâmetro, permitiram medições precisas de variações de potencial elétrico ao longo da membrana celular, fornecendo uma base empírica sólida para a modelagem quantitativa do comportamento elétrico dos neurônios.

A partir dessas observações experimentais, os pesquisadores identificaram que a geração do potencial de ação — o principal mecanismo de comunicação entre neurônios — dependia do movimento controlado de íons específicos através da membrana celular, especialmente os íons de sódio (Na^+) e potássio (K^+). Essas trocas iônicas ocorriam de forma dinâmica e regulada por canais iônicos dependentes de voltagem, estruturas que se abrem e fecham em resposta a variações no potencial da membrana, como mostra a figura “Membrana Celular”.

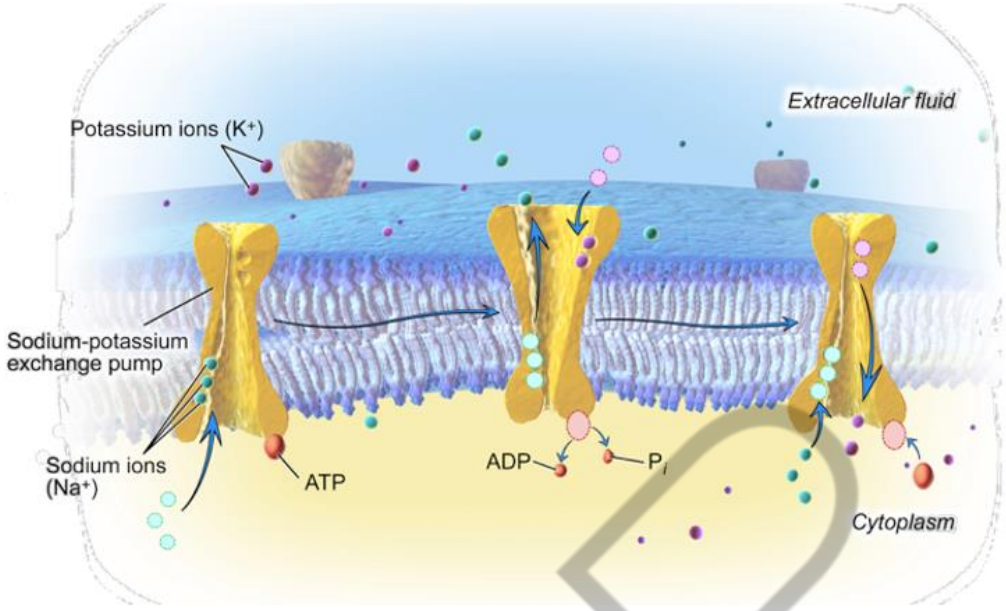


Figura 10 - Membrana Celular
Fonte: Khan Academy (2023), adaptado pelo autor (2025)

A figura “Membrana Celular” destaca o papel crucial da bomba de sódio-potássio (Na^+/K^+-ATPase), um dos principais componentes envolvidos na manutenção do potencial de repouso da célula. Essa proteína transportadora utiliza energia proveniente da hidrólise do ATP para expulsar ativamente três íons de sódio para fora da célula e importar dois íons de potássio para dentro, criando um gradiente eletroquímico fundamental para a excitabilidade neuronal.

Além das bombas, os canais iônicos presentes na membrana exibem seletividade e sensibilidade à voltagem, abrindo ou fechando em resposta a estímulos elétricos específicos. Esse comportamento permite a propagação do potencial de ação ao longo do axônio, promovendo uma sequência coordenada de influxo de Na^+ seguido por efluxo de K^+, o que caracteriza o ciclo clássico do impulso nervoso.

Durante esse processo, o equilíbrio iônico é temporariamente alterado, mas é rapidamente restaurado pela ação da bomba de sódio-potássio, assegurando que a célula esteja pronta para transmitir um novo sinal. Isso ilustra a importância da interação entre mecanismos passivos (como os canais) e ativos (como as bombas) na fisiologia celular.

Considerando essa base biofísica, o modelo HH formalizou essas dinâmicas por meio de equações diferenciais que descrevem as condutâncias de membrana e os fluxos iônicos ao longo do tempo. Essa abordagem matemática abriu caminho para o entendimento computacional de neurônios, sendo um marco não apenas na

neurociência, mas também nas áreas de modelagem e simulação de sistemas biológicos complexos.

Inspirados pelas propriedades elétricas da membrana neuronal, Hodgkin e Huxley propuseram uma analogia com circuitos elétricos (ilustrado na figura “Circuito Elétrico Equivalente para o modelo HH”), representando a membrana celular como um circuito equivalente. Nesse circuito, a capacitância da membrana é modelada por um capacitor, enquanto os canais de íons são representados como resistores variáveis (com condutância dependente do tempo e do potencial). Além disso, as diferenças de concentração iônica entre os meios intra e extracelular são representadas por fontes de potencial fixas, que simulam os potenciais de equilíbrio de Na^+, K^+ e de uma corrente de vazamento (leakage).

Essa representação elétrica possibilitou a formulação de um modelo matemático composto por um sistema de equações diferenciais acopladas, que descrevem com alta precisão a variação temporal do potencial de membrana. A principal equação baseia-se na Lei das correntes de Kirchhoff, que considera a soma de todas as correntes que atravessam a membrana: a corrente capacitiva e as correntes iônicas de sódio, potássio e vazamento.

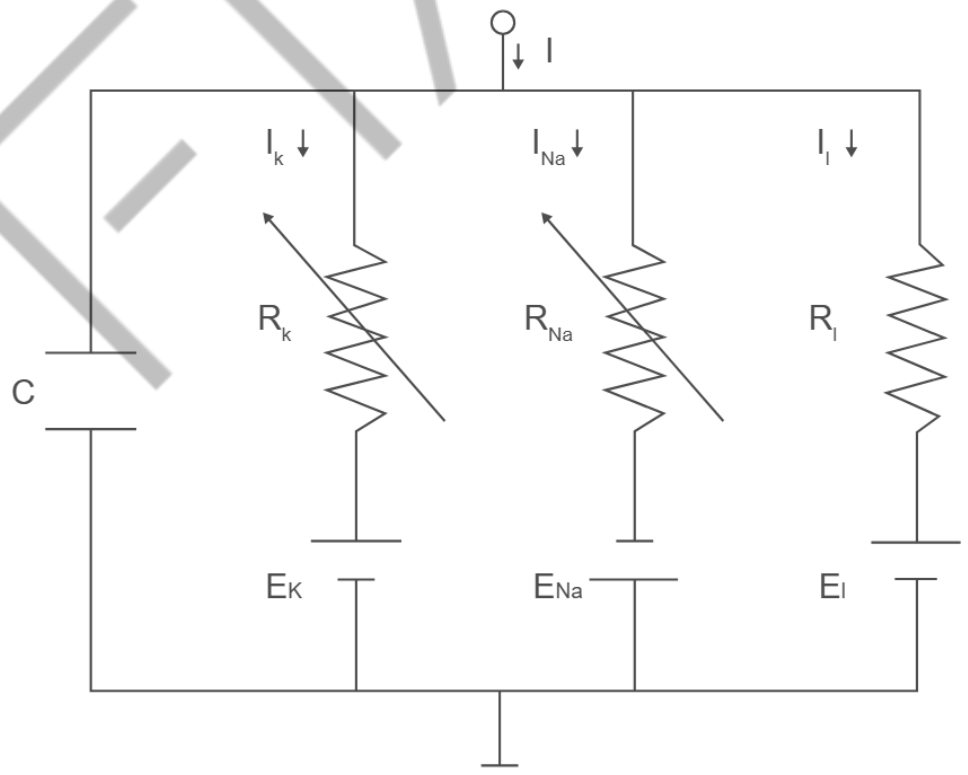


Figura 11 - Circuito elétrico equivalente para o modelo HH
Fonte: Hodgkin (1952), adaptado pelo autor (2025)

As condutâncias associadas aos canais iônicos não são constantes; elas variam no tempo e no potencial da membrana. Isso levou Hodgkin e Huxley a introduzirem variáveis de ativação e inativação (m, h, n) que obedecem a equações diferenciais próprias, adicionando um nível de realismo dinâmico ao modelo. Essas variáveis representam a probabilidade de abertura dos canais e seu comportamento ao longo do tempo.

A figura “Membrana Celular” ilustra, do ponto de vista biológico, o funcionamento dos canais iônicos e da bomba de sódio-potássio, que contribuem para a manutenção do gradiente eletroquímico. Essa base biológica dá origem à analogia elétrica representada na figura “Circuito Elétrico Equivalente para o modelo HH”, na qual é possível visualizar os elementos do modelo HH como componentes clássicos de circuitos elétricos.

Aplicando as Leis de Ohm e de Kirchhoff ao circuito equivalente da membrana neuronal, chega-se ao sistema completo de equações diferenciais que rege o modelo de Hodgkin-Huxley. Essas equações descrevem a evolução temporal do potencial de membrana em função da entrada de corrente externa, e são fundamentais para simulações computacionais do comportamento de neurônios. Elas são dadas por:

$$C_m \frac{dV}{dt} = I - g_{Na} \cdot m^3 \cdot h \cdot (V - E_{Na}) - g_K \cdot n^4 \cdot (V - E_K) - g_L \cdot (V - E_L) \quad (1)$$

$$\frac{dm}{dt} = \alpha_m(1 - m) - \beta_m m \qquad (2)$$

$$\frac{dh}{dt} = \alpha_h(1 - h) - \beta_h h \qquad (3)$$

$$\frac{dn}{dt} = \alpha_n(1 - n) - \beta_n n \qquad (4)$$

Na equação 1, V representa o potencial de membrana, C_m é a capacitância da membrana, e I é a corrente total injetada na célula. Os termos g_{Na}, g_K e g_L correspondem às condutâncias máximas dos canais de sódio, potássio e vazamento, respectivamente, enquanto E_{Na}, E_K e E_L são os respectivos potenciais de equilíbrio desses íons. As variáveis m, h e n são parâmetros de ativação e inativação dependentes do tempo e do potencial, representando, respectivamente, a ativação do canal de sódio, sua inativação e a ativação do canal de potássio. As equações 2, 3 e

4 descrevem a dinâmica temporal dessas variáveis, onde α e β são funções que dependem do potencial de membrana e determinam as taxas de abertura e fechamento dos canais.

A expressividade matemática do modelo HH, somada à sua precisão fisiológica, tornou-o um dos pilares da neurociência computacional e uma ferramenta amplamente empregada em áreas como a engenharia biomédica, a fisiologia e, mais recentemente, a Computação Neuromórfica. Esta última busca desenvolver sistemas eletrônicos que imitam o funcionamento dos neurônios biológicos.

Na Computação Neuromórfica, o modelo de Hodgkin-Huxley é utilizado como base para projetar circuitos analógicos ou digitais que reproduzam a dinâmica neuronal. Componentes como transistores, memristores e capacitores são organizados para emular as propriedades do circuito equivalente da membrana, permitindo a implementação física do comportamento dos neurônios em chips especializados.

Essa abordagem oferece vantagens em termos de eficiência energética e paralelismo massivo, características desejáveis para sistemas inteligentes e de aprendizado autônomo. Ao traduzir princípios biológicos para hardware eletrônico, o modelo HH atua como um elo entre a neurociência e a engenharia, contribuindo diretamente para o avanço da Inteligência Artificial inspirada no cérebro humano.

Em síntese, o modelo de Hodgkin-Huxley não apenas desvendou os mecanismos elétricos fundamentais do funcionamento neuronal, mas também forneceu uma ponte sólida para a transição desses conceitos para o campo da engenharia, viabilizando o desenvolvimento de novas tecnologias computacionais bioinspiradas.

As figuras apresentadas reforçam essa conexão entre a biologia e a modelagem elétrica, permitindo uma compreensão mais profunda e integrada das bases do processamento neural artificial.

Podemos mencionar como principais pontos a favor do modelo HH:

- **Precisão biofísica:** o modelo captura detalhadamente o comportamento dos canais iônicos, incluindo a despolarização rápida mediada pelo Na^+ e a repolarização mais lenta pelo K^+, além da inativação do sódio.

- **Base experimental sólida:** desenvolvido a partir de dados empíricos obtidos com técnicas de grampeamento de voltagem, o modelo é validado por observações fisiológicas.
- **Versatilidade:** serve como fundamento para estudos em neurociência, como o entendimento de doenças neuromusculares e o desenvolvimento de interfaces cérebro-máquina.

E como principais fatores limitantes do modelo HH:

- **Complexidade computacional:** o sistema de equações diferenciais não lineares exige alto poder de processamento, inviabilizando simulações em larga escala.
- **Foco no neurônio individual:** o modelo não descreve adequadamente interações em redes neurais complexas, limitando sua aplicação em sistemas com múltiplos neurônios.
- **Simplificações:** embora detalhado, o modelo não incorpora todos os aspectos da biologia neuronal, como a influência de outros íons ou a dinâmica espacial em dendritos e axônios.

2.2 Modelo Integra-e-Dispara: A engenharia por trás da Computação Neuromórfica eficiente

O modelo Integra-e-Dispara com Vazamento (Leaky Integrate-and-Fire — LIF) surgiu como uma simplificação computacional inspirada no famoso modelo de Hodgkin-Huxley (HH), desenvolvido em 1952. O modelo HH, embora biologicamente preciso, envolve um sistema de equações diferenciais não lineares que demandam elevado poder computacional para simulação. Almejando uma maior eficiência e aplicabilidade prática, especialmente em Sistemas Neuromórficos e de Aprendizado de Máquina, o modelo LIF propõe uma representação simplificada e funcional dos neurônios biológicos.

Enquanto o modelo HH simula com detalhamento os canais iônicos de sódio e potássio que regulam o potencial de ação nas membranas neuronais, o LIF abstrai esse comportamento por meio de uma estrutura elétrica elementar, composta por um

resistor e um capacitor conectados em paralelo. Essa aproximação capta de forma eficiente o processo de integração de estímulos e o mecanismo de disparo, mantendo a fidelidade dos principais comportamentos neuronais.

No modelo LIF, o neurônio é tratado como um integrador de corrente elétrica. A membrana celular é representada como um capacitor C_m, responsável por acumular carga elétrica, enquanto o resistor R_m simula o vazamento da membrana, refletindo sua condutância natural. A corrente elétrica total recebida pelo neurônio, representada como I_E, é somada e, ao atingir um valor limiar de tensão V_L, o modelo simula o disparo de um potencial de ação.

Essa configuração pode ser traduzida para um circuito elétrico equivalente, como mostra a figura “Circuito equivalente para o modelo de neurônio LIF”. Nesse circuito, a corrente entra pela via intracelular e é dividida entre o capacitor C_m e o resistor R, descarregando-se para a referência extracelular. A tensão V representa o potencial da membrana, e V_{rep} define o nível em que ocorre o disparo.

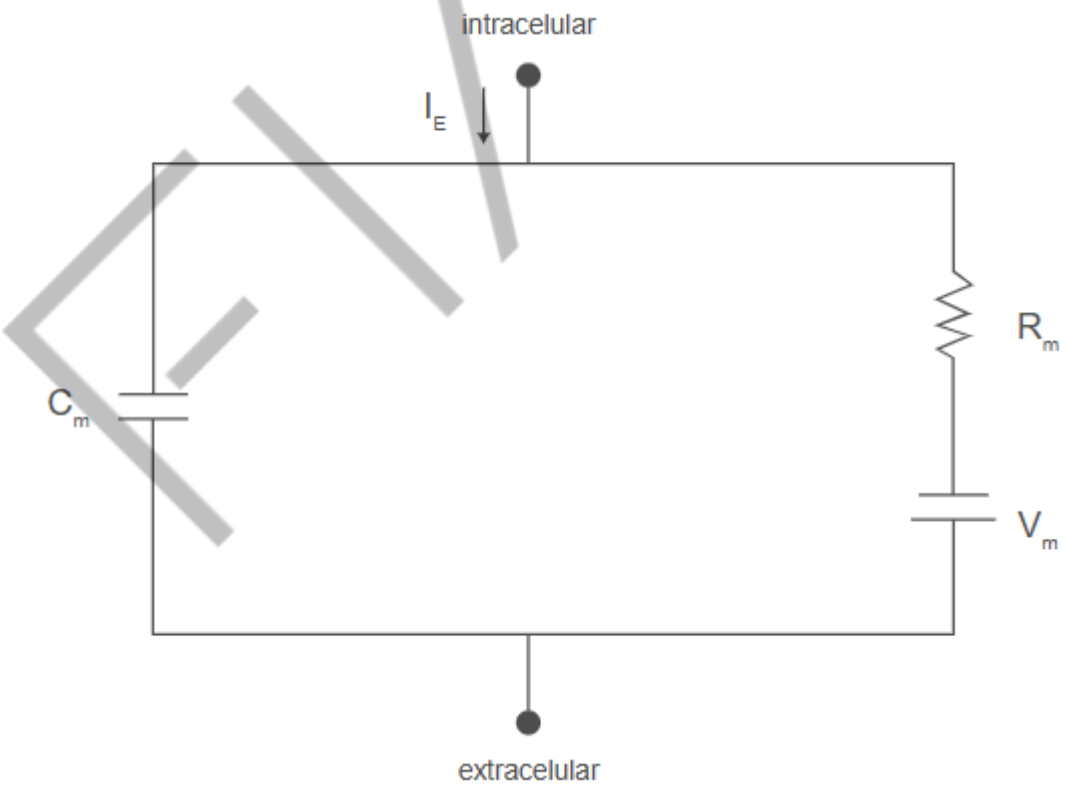


Figura 12 - Circuito equivalente para o modelo de neurônio LIF
Fonte: Elaborado pelo autor (2025)

Após o disparo, o modelo LIF assume que o neurônio entra imediatamente em um estado de reinicialização, em que a tensão de membrana V é resetada para um

valor de repouso pré-definido. Esse mecanismo de reinicialização é fundamental para simular o período refratário, no qual o neurônio permanece temporariamente inativo antes de poder disparar novamente.

Outra característica importante do modelo é a sua capacidade de acumular estímulos temporais. Ou seja, correntes de entrada fracas e espaçadas no tempo podem não ser suficientes para gerar um disparo isoladamente, mas, se forem suficientemente próximas, o capacitor acumula carga até ultrapassar o limiar, resultando em um disparo. Esse comportamento reflete a capacidade de integração temporal observada em neurônios biológicos.

O modelo também permite simulações eficientes com múltiplos neurônios, devido à sua simplicidade computacional. Em Redes Neurais Artificiais e Circuitos Neuromórficos, os elementos LIF podem ser conectados entre si, com sinapses modeladas como fontes de corrente que influenciam o comportamento dinâmico de cada unidade. Isso torna o LIF uma base versátil para estudar dinâmicas de rede em diferentes contextos de processamento sensorial ou cognitivo.

Por fim, o circuito equivalente, apresentado na figura “Circuito equivalente para o modelo de neurônio LIF”, é uma ferramenta didática poderosa para compreender a analogia entre propriedades elétricas e fenômenos neurobiológicos. Ele permite não apenas a visualização do comportamento do modelo, mas também a implementação prática em plataformas de simulação eletrônica, como SPICE ou simuladores interativos online, o que facilita o aprendizado e a experimentação com os fundamentos da neurocomputação.

Matematicamente, o modelo LIF é descrito por uma única equação diferencial ordinária:

$$C_m \frac{dV_m}{dt} + \frac{V_m - E_L}{R_m} = I_E \qquad (4)$$

Nessa equação 4, V_m representa o potencial da membrana do neurônio ao longo do tempo, ou seja, a diferença de potencial elétrico entre o interior e o exterior da célula. O termo C_m é a capacitância da membrana, que representa a capacidade da célula em acumular carga elétrica, funcionando como um integrador das correntes recebidas. Já R_m é a resistência da membrana, que modela a tendência da célula a

“vazar” parte dessa carga, ou seja, a perda natural de potencial ao longo do tempo. O valor E_L representa o potencial de vazamento ou potencial de repouso, indicando o nível de tensão para o qual o potencial da membrana tende na ausência de estímulos. Por fim, I_E é a corrente de entrada, que pode ser oriunda de sinapses ou outras fontes de excitação, sendo responsável por modificar o estado elétrico do neurônio.

O comportamento temporal do potencial V(t) pode ser visualizado graficamente, como também representado na figura, onde a tensão cresce continuamente à medida que o neurônio integra a corrente. Quando a tensão ultrapassa o limiar V_L, um potencial de ação é considerado disparado, e a tensão é reiniciada para um valor de redefinição V_{redef}, simulando o ciclo de excitação e repouso da célula.

Este processo de integração seguido por disparo define a dinâmica fundamental do modelo. Além disso, o termo “com vazamento” se refere ao fato de que, mesmo na ausência de entrada, o potencial tende a decair exponencialmente devido à resistência, refletindo a perda natural de carga ao longo do tempo.

Comparado ao modelo HH, o LIF oferece uma vantagem significativa em termos de simplicidade computacional. A presença de apenas uma equação diferencial permite a simulação de Redes Neurais compostas por milhares de neurônios com custo computacional reduzido. Isso o torna especialmente atrativo para arquiteturas neuromórficas e aplicações embarcadas.

Além disso, o modelo LIF captura adequadamente o comportamento de integração temporal de estímulos sinápticos. Ele permite o uso de estratégias como disparo com limiar fixo, integração estocástica de entradas e reset após disparo, tornando-se uma ferramenta versátil em engenharia de sistemas cognitivos.

Do ponto de vista da engenharia, o LIF pode ser diretamente implementado em circuitos eletrônicos analógicos ou híbridos, o que possibilita a construção de chips neuromórficos com alta eficiência energética. Essa aplicabilidade direta em hardware é um dos principais motivadores de seu uso em sistemas como o IBM TrueNorth e o Intel Loihi.

Em termos de aprendizagem e modelagem, o modelo também é compatível com regras locais como STDP, permitindo a construção de redes autoajustáveis capazes de simular a plasticidade sináptica observada no cérebro.

No entanto, a simplicidade do modelo também traz limitações. O LIF não representa diretamente os mecanismos iônicos subjacentes ao potencial de ação, nem simula o comportamento refratário natural de forma detalhada. A ausência de variáveis adicionais limita sua capacidade de descrever oscilações complexas e padrões de disparo irregulares observados em neurônios reais.

Além disso, o modelo não distingue entre tipos de canais iônicos nem simula adaptações de disparo em resposta a estímulos sustentados. Essas características, embora não sejam essenciais para muitas aplicações, são críticas em estudos mais precisos da fisiologia neuronal.

Podemos mencionar como principais pontos a favor do modelo LIF:

- Simplicidade matemática e computacional (uma equação diferencial);
- Alta eficiência energética e viabilidade de implementação em hardware;
- Boa representação do comportamento de integração e disparo;
- Facilidade de simulação em larga escala;
- Compatível com regras de aprendizado sináptico como STDP.

E como principais fatores limitantes do modelo LIF:

- Não representa os mecanismos biofísicos detalhados dos canais iônicos;
- Não simula bem os períodos refratários ou a adaptação de disparo;
- Incapacidade de modelar padrões complexos de resposta neural;
- Aplicabilidade limitada em simulações fisiológicas de alta precisão.

Em resumo, o modelo Integra-e-Dispara com Vazamento é uma ferramenta poderosa para aplicações em Computação Neuromórfica, oferecendo um equilíbrio eficiente entre fidelidade biológica e viabilidade computacional. Seu uso é recomendado sempre que a simplicidade e a eficiência forem mais relevantes do que a exatidão fisiológica detalhada.

2.3 Modelos simplificados

Para finalizar essa seção, vamos explorar um modelo neuronal, intermediário entre o HH e o LIF, que é denominado FitzHugh-Nagumo (FHN).

O modelo de FitzHugh-Nagumo surgiu como uma tentativa de simplificar o complexo sistema de equações do modelo de Hodgkin-Huxley, mantendo, entretanto, as principais características dinâmicas da excitabilidade neuronal.

Desenvolvido na década de 1960, o modelo foi concebido por Richard FitzHugh, que propôs uma versão reduzida do sistema HH, e por J. Nagumo, que posteriormente mostrou como esse modelo poderia ser representado eletricamente. Trata-se, portanto, de um modelo intermediário entre o rigor biológico do modelo HH e a simplicidade operacional do modelo LIF.

A principal motivação por trás do modelo FHN foi capturar o comportamento qualitativo de disparos neuronais sem a necessidade de representar explicitamente os canais iônicos de sódio e potássio, como no HH. FitzHugh abstraiu a dinâmica complexa em dois componentes fundamentais: uma variável rápida, representando o potencial de membrana, e uma variável lenta, responsável pela recuperação do sistema após um disparo. Esse arranjo permitiu a análise de excitação e repouso neuronal com menor custo computacional.

O modelo FHN possui duas equações diferenciais acopladas que descrevem a evolução temporal do sistema. A primeira equação modela a ativação rápida da membrana, enquanto a segunda regula a recuperação lenta, analogamente à reativação dos canais iônicos. Essa estrutura captura o limiar de disparo, o tempo refratário e o ciclo de recuperação de maneira qualitativa, fornecendo um retrato simplificado, porém funcional, do comportamento neuronal.

Do ponto de vista da engenharia, o modelo FHN pode ser representado como um circuito eletrônico composto por elementos não lineares, resistores, capacitores e fontes de corrente. A variável rápida é modelada por um capacitor que armazena a energia elétrica, representando o potencial de membrana. A não linearidade essencial do modelo é inserida por meio de um amplificador com feedback ou um diodo com curva característica cúbica, que simula o comportamento não linear do neurônio próximo ao limiar de disparo.

A variável lenta do modelo, por sua vez, é implementada por uma combinação de resistor e capacitor que opera em uma escala de tempo mais longa. Esse componente é responsável pela inibição temporária do disparo, imitando a fase de recuperação após a excitação. Em algumas implementações, essa variável é controlada por um gerador de corrente controlado por tensão, o que facilita a simulação do retorno gradual do sistema ao estado de repouso.

Uma característica marcante do circuito equivalente do modelo FHN é a presença de um componente cúbico não linear, geralmente implementado com amplificadores operacionais e diodos em configuração especial. Essa não linearidade garante que o sistema possua múltiplos pontos de equilíbrio, dos quais apenas um é estável em condições normais, mas que pode ser ultrapassado com a injeção de um estímulo suficientemente forte — simulando, assim, o disparo de um neurônio real.

A simplicidade do circuito equivalente torna o modelo FHN altamente atrativo para experimentos de hardware neuromórfico. Ele permite o estudo de osciladores biológicos, redes neuronais simples e até mesmo fenômenos de sincronização em sistemas acoplados. Em sistemas de computação analógica, o modelo FHN pode ser implementado de maneira eficiente, ocupando pouco espaço e consumindo pouca energia, o que é uma grande vantagem frente a modelos mais detalhados.

Em ambientes de simulação computacional, o modelo FHN também se destaca por sua grande eficiência. Ele pode ser integrado numericamente com passos de tempo maiores que os exigidos pelo modelo HH, sem perda significativa na acurácia qualitativa do comportamento dinâmico. Por essa razão, é frequentemente utilizado em estudos teóricos sobre Redes Neuronais, propagação de pulsos e comportamento oscilatório de neurônios.

O modelo também permite a inclusão de ruído ou entrada externa modulada no sistema, facilitando o estudo de resposta a estímulos estocásticos ou periódicos. Isso o torna útil em contextos de neurociência teórica, particularmente na investigação de fenômenos como codificação sensorial e ressonância estocástica.

Outro ponto forte do modelo FHN é a sua aplicabilidade na modelagem de sistemas fora da biologia, como circuitos osciladores, modelagem de células cardíacas e análise de sistemas dinâmicos excitatórios em engenharia e física aplicada. A versatilidade do modelo reside justamente na sua capacidade de

representar dinâmicas universais em sistemas que compartilham características semelhantes aos neurônios biológicos.

Entretanto, o modelo de FitzHugh-Nagumo não é isento de limitações. Por ser um modelo qualitativo, ele não fornece valores precisos para parâmetros biológicos, como condutâncias iônicas ou concentrações de íons. Isso o torna inadequado para estudos que exigem acurácia quantitativa sobre propriedades eletrofisiológicas reais.

Além disso, embora o modelo seja eficiente em simular a dinâmica de um único neurônio ou de pequenos circuitos, ele pode perder a capacidade de representar fenômenos mais complexos, como a modulação sináptica, o comportamento dependente de frequência ou as interações entre múltiplos tipos de canais iônicos presentes em neurônios reais.

Em comparação com o modelo LIF, o FHN é mais expressivo e capaz de reproduzir um conjunto maior de comportamentos dinâmicos, incluindo limiares suaves, oscilação espontânea e períodos refratários contínuos. No entanto, ele também é mais complexo e requer maior esforço de implementação, tanto em software quanto em hardware.

Por outro lado, em relação ao modelo HH, o FHN representa uma economia computacional significativa e uma redução drástica na complexidade matemática, tornando-se uma alternativa viável quando o objetivo é capturar apenas a estrutura geral da excitabilidade neuronal.

O modelo de FitzHugh-Nagumo representa um compromisso entre fidelidade biológica e simplicidade matemática. Ele é ideal para contextos em que se busca uma compreensão qualitativa do disparo neuronal com baixa demanda computacional. Seus pontos fortes incluem a capacidade de representar excitação e recuperação de forma compacta e versátil, enquanto seus pontos fracos residem na ausência de parâmetros biológicos precisos e na limitação para simulações altamente detalhadas.

3 SIMULAÇÕES DE CIRCUITOS RC PARA PRODUZIR COMPORTAMENTO NEURONAL

O modelo de neurônio mais utilizado para representar o comportamento pulsado de Redes Neurais é o modelo Integrate-and-Fire, e em sua versão com fuga, denominado Leaky Integrate-and-Fire (LIF). Esse modelo foi inicialmente inspirado nos trabalhos pioneiros de Hodgkin e Huxley (1952) e, mais tarde, formalizado de maneira compacta e computacionalmente eficiente por Gerstner e Kistler (2002).

Trata-se de uma abordagem simplificada, porém poderosa, para simular a atividade elétrica de neurônios reais, capturando dois aspectos fundamentais: a **integração temporal de sinais** e a **geração de disparos elétricos** (spikes).

O modelo LIF assume que o potencial da membrana de um neurônio pode ser representado por um circuito elétrico composto por um capacitor e um resistor. O capacitor simula a membrana celular, que acumula carga elétrica à medida que correntes entram no neurônio, enquanto o resistor representa os canais de vazamento de íons da membrana, os quais fazem com que parte dessa carga escape ao longo do tempo. A interação entre esses dois componentes define a dinâmica do potencial de membrana do neurônio, determinando se ele irá disparar ou não um pulso elétrico.

O funcionamento do modelo é governado por uma equação diferencial ordinária de primeira ordem, cuja solução descreve como o potencial de membrana evolui ao longo do tempo em resposta a uma corrente de entrada. Essa equação é derivada a partir da Lei de Kirchhoff para circuitos elétricos, e representa o balanço entre a corrente que entra na célula, a corrente que carrega o capacitor e a corrente que "vaza" pela resistência da membrana. A equação é apresentada a seguir:

$$C_m \frac{dV_m}{dt} + \frac{V_m - E_L}{R_m} = I_E \qquad (5)$$

Na equação 5, C_m representa a capacitância da membrana, V_m é o potencial de membrana, E_L é o potencial de repouso (ou de equilíbrio), R_m é a resistência da membrana e I_E é a corrente de entrada. A solução dessa equação mostra que, na ausência de estímulo (isto é, quando I_E=0), o potencial de membrana tende

exponencialmente ao valor E_L. Esse comportamento reflete a propriedade de “fuga” do modelo: sem estímulo contínuo, o neurônio retorna ao seu estado de repouso.

Quando há uma corrente de entrada constante, o potencial de membrana se aproxima de um valor de equilíbrio que depende da magnitude de I_E. No entanto, esse valor não pode crescer indefinidamente. O modelo LIF introduz uma regra adicional: se o potencial de membrana atingir um valor de limiar V_{th}, considera-se que o neurônio disparou um pulso (ou spike), e então o potencial é imediatamente resetado para um valor inferior, tipicamente chamado de V_{reset}. Esse reset simula o fenômeno biológico de repolarização da membrana após um disparo.

O comportamento do potencial de membrana ao longo do tempo pode ser visualizado em um gráfico que relaciona potencial V e tempo t como o apresentado na figura “Tensão em função do tempo no modelo LIF”. Inicialmente, com a aplicação de uma corrente constante, o potencial cresce de forma exponencial até atingir o limiar. Nesse momento, ocorre o disparo, seguido de um reset. Esse ciclo se repete enquanto a corrente de entrada for mantida. O gráfico assume, portanto, uma forma serrada, com rampas ascendentes suaves seguidas de quedas abruptas. Esse padrão é característico de neurônios de disparo regular.

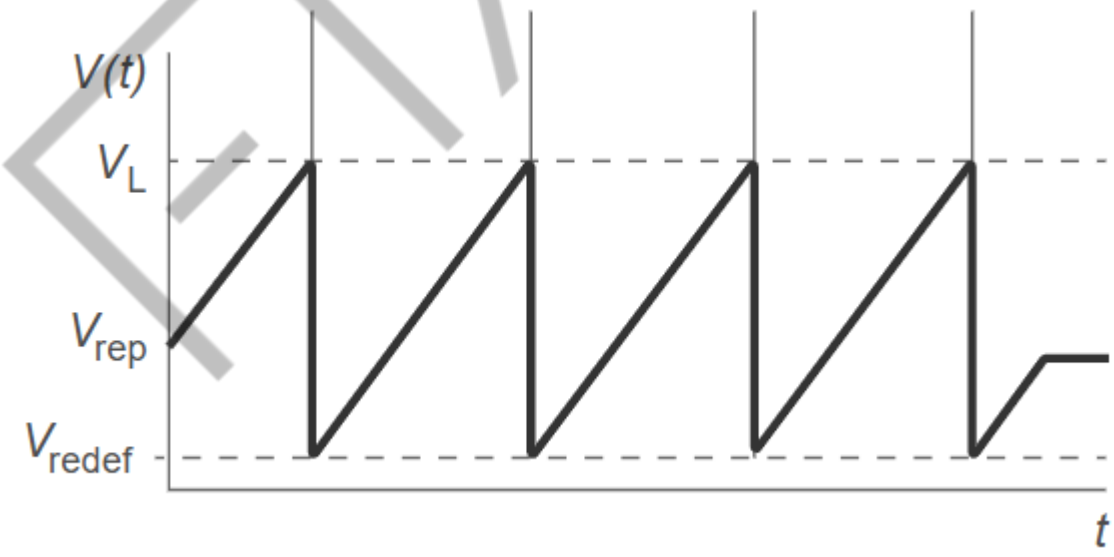


Figura 13 - Tensão em função do tempo no modelo LIF
Fonte: Zanona *et al.* (2009), adaptado pelo autor (2025)

A frequência com que esses disparos ocorrem depende diretamente da intensidade da corrente de entrada. Correntes mais fortes fazem com que o potencial de membrana atinja o limiar mais rapidamente, aumentando a taxa de disparos. Essa

propriedade do modelo permite construir curvas de ativação, conhecidas como curvas f-I, que mostram a frequência de disparos f em função da corrente I. Tais curvas são úteis para caracterizar como um neurônio responde a diferentes intensidades de estímulo.

Além disso, esse comportamento permite estimar o intervalo entre dois disparos consecutivos, chamado intervalo interpulso (interspike interval — ISI). Em correntes constantes e sem ruído, esse intervalo é regular, gerando um neurônio de disparo previsível. No entanto, ao introduzir variações ou ruídos na corrente, esse intervalo se torna mais variável, aproximando o modelo da complexidade observada em neurônios biológicos reais.

Outra característica relevante do modelo LIF é sua simples implementação computacional. A equação diferencial pode ser discretizada utilizando métodos numéricos, como o método de Euler, e implementada facilmente em linguagens como Python, MATLAB ou até mesmo em hardware analógico com componentes RC. A discretização permite calcular a evolução do potencial de membrana a cada pequeno passo de tempo, simulando em tempo real o comportamento do neurônio.

Uma limitação do modelo LIF clássico é a ausência de descrição explícita de mecanismos biológicos que geram o pulso de ação. Em outras palavras, o modelo não reproduz a forma real do spike, apenas sua ocorrência. No entanto, para muitos estudos e aplicações em Redes Neurais Artificiais e Neuromórficas, essa simplificação é suficiente, pois o importante é saber quando o neurônio dispara, e não a forma exata do pulso.

Do ponto de vista da engenharia de circuitos neuromórficos, o modelo LIF se destaca por sua viabilidade física. Como ele pode ser representado com poucos componentes analógicos (um capacitor, um resistor e um circuito de comparação limiar), é ideal para integração em chips de alta densidade, permitindo simular redes com milhares ou milhões de neurônios artificiais.

Além disso, a detecção de limiar pode ser implementada com circuitos comutadores sensíveis à tensão, que acionam o reset do potencial. Para que esse reset ocorra de forma estável, frequentemente se empregam dispositivos com histerese, garantindo que o disparo e o retorno ao estado de repouso sejam distintos

e bem definidos — condição que também modela o período refratário do neurônio, durante o qual ele não pode disparar novamente.

Dessa forma, o modelo LIF oferece uma combinação ideal entre simplicidade matemática, realismo funcional básico e facilidade de implementação, sendo uma ferramenta fundamental tanto no ensino quanto na pesquisa sobre Redes Neurais Biológicas e Artificiais.

Em resumo, simular circuitos RC como representação de neurônios do tipo LIF nos permite compreender como o acúmulo e a dissipação de cargas elétricas podem gerar comportamento pulsado, que é a base do funcionamento cerebral. Essa abordagem serve como ponto de partida para modelos mais complexos, como o de Hodgkin-Huxley, e prepara o terreno para a construção de sistemas neuromórficos eficientes e inspirados na natureza.

4 IMPLEMENTAÇÃO DE MODELOS UTILIZANDO CIRCUITOS ANALÓGICOS E DIGITAIS

O desenvolvimento de Redes Neurais Artificiais tem evoluído de forma significativa desde seus primeiros modelos, passando por diversas gerações de arquiteturas e formas de representação de dados. Essa trajetória de evolução reflete-se diretamente nas estratégias de implementação física, as quais podem ser agrupadas, em linhas gerais, em duas abordagens principais: **analógica** e **digital**. Ambas possuem características próprias, vantagens e desafios, e vêm sendo exploradas tanto de forma independente quanto de forma híbrida.

O interesse por simulações inspiradas no modelo LIF impulsiona diretamente o avanço de arquiteturas neuromórficas físicas. Esse modelo, por sua simplicidade e aderência ao comportamento dos neurônios biológicos, permite representar o processamento neural como uma integração de sinais ao longo do tempo até o disparo de um pulso — comportamento fundamental para Redes Neurais pulsadas da terceira geração.

Particularmente, a eficiência observada em sistemas biológicos de computação motiva a implementação de Redes Neurais utilizando circuitos analógicos. Nessa abordagem, os neurônios e sinapses são modelados diretamente com componentes eletrônicos como resistores, capacitores e memristores, permitindo representar o fluxo de informações por meio de sinais elétricos contínuos em tempo real.

Uma das operações fundamentais para Redes Neurais é a multiplicação-acumulação (MAC), que pode ser realizada diretamente no domínio físico utilizando matrizes de barras cruzadas. Essas estruturas permitem a computação de produtos escalares entre vetores de entrada e pesos sinápticos de forma paralela e altamente eficiente, como é ilustrado na figura “Comparação entre algoritmo (a) e matriz de barras cruzadas (b) para realizar operações de multiplicação-acumulação em Redes Neurais”. Nessa arquitetura, os sinais de entrada são aplicados como tensões, enquanto os pesos sinápticos são codificados na condutância dos elementos localizados nas interseções das barras — frequentemente, memristores. A corrente gerada em cada coluna representa o somatório ponderado das entradas, em conformidade com a Lei de Ohm, e atua como valor de ativação de um neurônio.

Essas matrizes promovem a chamada computação em memória (*in-memory computing*), eliminando a necessidade de transferências constantes entre unidades de processamento e memória — um dos gargalos centrais das arquiteturas tradicionais de von Neumann. A computação ocorre diretamente onde os dados estão armazenados.

Os memristores, nesse contexto, desempenham um papel central. Além de não voláteis, possuem propriedades analógicas e capacidade de ajuste dinâmico de condutância em função da corrente aplicada. Essa plasticidade os torna ideais como sinapses artificiais em Redes Neuromórficas.

Além disso, sua alta densidade de integração e baixo consumo energético favorecem aplicações embarcadas e dispositivos com recursos limitados, como sensores inteligentes, sistemas autônomos e interfaces neurais.

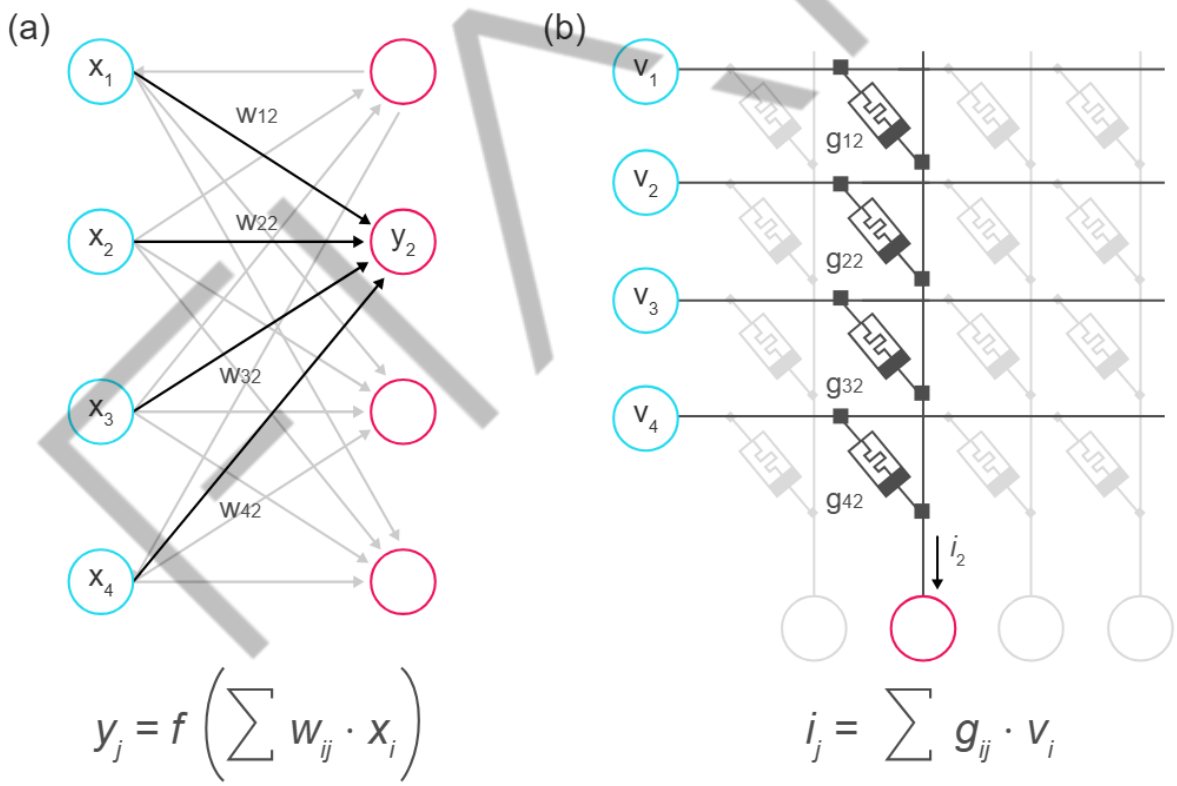


Figura 14 - Comparação entre algoritmo (a) e matriz de barras cruzadas (b) para realizar operações de multiplicação-acumulação em Redes Neurais
Fonte: Chen *et al*. (2021), adaptado pelo autor (2025)

No entanto, para que a operação ocorra com fidelidade, é preciso considerar os circuitos periféricos. Esses circuitos atuam como intermediários entre sinapses e neurônios, ajustando níveis de tensão e corrente para garantir compatibilidade entre os diferentes blocos do sistema.

Os neurônios artificiais implementados em circuitos analógicos baseados no modelo LIF disparam pulsos quando a corrente acumulada ultrapassa um limiar pré-determinado. Após o disparo, o neurônio retorna ao estado de repouso, pronto para uma nova integração.

O comportamento pulsado é altamente eficiente do ponto de vista energético, uma vez que não há consumo estático de energia enquanto os neurônios permanecem em repouso. Isso torna as Redes Neurais Pulsadas (RNPs) particularmente atrativas para aplicações de baixo consumo.

Apesar dessas vantagens, o projeto de circuitos analógicos neuromórficos enfrenta desafios. Questões como distorções de sinal, interferências e sensibilidade a ruído exigem técnicas robustas de projeto e caracterização dos dispositivos.

Nesse ponto, a simulação com circuitos RC baseados no modelo LIF torna-se uma etapa fundamental tanto para validar conceitos quanto para prever o comportamento dinâmico de redes reais antes da implementação física.

Ao longo das décadas, o avanço nos modos de representação dos sinais neurais também influenciou a forma como as Redes Neurais são implementadas.

Desde as primeiras gerações, com redes de limiar discreto como as de McCulloch-Pitts, até as redes contínuas com funções de ativação, e finalmente as pulsadas, houve um claro movimento em direção à fidelidade biológica e à eficiência temporal.

Na primeira geração, os sinais eram binários. Com a segunda, passou-se à representação contínua, viabilizando implementações digitais mais robustas, com funções como ReLU e sigmoide (observe a figura “Comparação entre redes neurais de segunda geração (à esquerda) e de terceira geração (à direita)”). Essa geração impulsionou as Redes Neurais Artificiais tradicionais, que são amplamente utilizadas na indústria hoje.

Com a terceira geração, a codificação temporal por pulsos abriu um novo paradigma. A presença do tempo como variável computacional permitiu a representação de latências, frequências e padrões de disparo, o que levou a um novo nível de expressividade e aproximação com a neurobiologia.

Observe a figura:

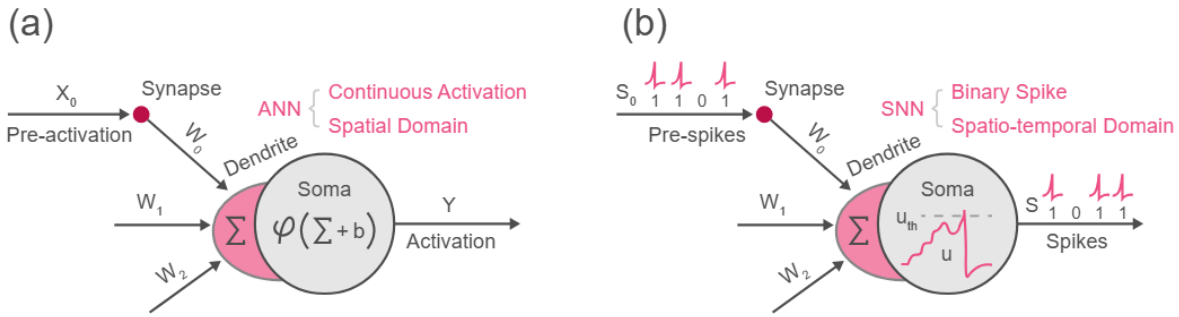


Figura 15 - Comparação entre redes neurais de segunda geração (à esquerda) e de terceira geração (à direita)
Fonte: Deng *et al*. (2020), adaptado pelo autor (2025)

Essa nova abordagem, conhecida como Redes Neurais Pulsadas (Spiking Neural Networks — SNNs), permite que os neurônios artificiais disparem sinais discretos de forma assíncrona, similar ao comportamento observado em neurônios biológicos. Isso não apenas possibilita representações mais compactas e eficientes, como também permite explorar propriedades emergentes, como aprendizado local e codificação esparsa.

Além disso, a terceira geração abre espaço para implementações neuromórficas de baixo consumo energético, ideais para aplicações em sistemas embarcados, robótica e dispositivos com restrições de energia. A combinação entre representação temporal e arquitetura distribuída contribui para o desenvolvimento de sistemas que operam de forma mais próxima ao cérebro, tanto em termos funcionais quanto de eficiência computacional.

Um aspecto relevante das SNNs é a possibilidade de incorporar regras de aprendizado inspiradas na plasticidade sináptica, como a Spike-Timing Dependent Plasticity, que ajusta os pesos sinápticos com base no intervalo temporal entre os disparos dos neurônios pré e pós-sinápticos. Isso permite um tipo de aprendizado não supervisionado com forte analogia biológica.

Com isso, abre-se um caminho promissor para o desenvolvimento de sistemas adaptativos que respondem a estímulos em tempo real, aprendem com o ambiente e se ajustam de maneira contínua. Esse avanço representa não apenas uma inovação na arquitetura de Redes Neurais, mas uma mudança de paradigma no modo como projetamos sistemas computacionais inteligentes.

Nesse contexto, a implementação digital também tem ganhado espaço. Mesmo que redes LIF sejam mais intuitivamente associadas à eletrônica analógica, implementações digitais em CMOS são comuns — especialmente em sistemas que necessitam de escalabilidade, reprodutibilidade e integração com outras plataformas digitais.

Para isso, circuitos digitais são utilizados para modelar neurônios, com o uso extensivo de conversores analógico-digital (ADC) e digital-analógico (DAC), que permitem que sinais contínuos sejam interpretados ou gerados por circuitos digitais.

Esses circuitos CMOS digitais oferecem precisão, estabilidade e facilidade de reconfiguração por software, tornando-os ideais para experimentação e prototipagem. Contudo, apresentam maior área de silício ocupada e maior consumo energético quando comparados às abordagens analógicas com memristores.

A integração entre os dois domínios — analógico e digital — tem sido explorada com sucesso em arquiteturas híbridas, que aproveitam o melhor de ambos os mundos: a eficiência energética do analógico e a flexibilidade do digital.

Em tais arquiteturas, o processamento básico pode ser realizado por uma matriz de memristores (em domínio analógico), enquanto a supervisão, controle e ajustes dinâmicos dos pesos sinápticos são gerenciados por microcontroladores ou FPGAs digitais.

Essa abordagem híbrida também permite incluir estratégias de Aprendizado Supervisionado e Online, uma vez que os controladores digitais podem atualizar as condutâncias dos memristores em tempo real com base em critérios externos.

Além disso, tecnologias emergentes como o uso de transistores de efeito de campo programáveis por carga (FeFETs) e dispositivos spintrônicos vêm ampliando as possibilidades de integração entre circuitos analógicos e digitais.

Projetos como o Loihi (Intel) e o TrueNorth (IBM) exemplificam essa busca por plataformas neuromórficas eficientes, muitos deles combinando elementos digitais com lógica assíncrona e comunicação por eventos — um modelo inspirado diretamente no cérebro.

Essas plataformas apresentam tamanha eficiência energética que viabiliza seu uso em robótica autônoma, drones e dispositivos vestíveis que exigem alto desempenho computacional com consumo mínimo.

Portanto, ao considerar a implementação de modelos utilizando circuitos analógicos e digitais, é essencial compreender não apenas os dispositivos envolvidos, mas também as arquiteturas sistêmicas e os paradigmas computacionais adotados.

Modelos baseados em LIF se mostram especialmente promissores para tais aplicações, pois podem ser adaptados a diferentes domínios físicos, facilitando sua implementação tanto em hardware analógico quanto em circuitos digitais.

Ao explorar essas possibilidades, o projeto de sistemas neuromórficos pode se beneficiar da complementaridade entre os domínios, oferecendo novas soluções computacionais que rompem com os limites impostos pela arquitetura de von Neumann tradicional.

Essa ruptura se manifesta principalmente na separação entre memória e processamento, uma limitação clássica da arquitetura de von Neumann que gera gargalos de comunicação e consumo elevado de energia. Nos sistemas neuromórficos, o armazenamento e o processamento de informações podem ocorrer no mesmo local, de forma distribuída, semelhante ao que ocorre em sinapses biológicas.

Por exemplo, o uso de memristores como elementos sinápticos permite não apenas a retenção do peso sináptico, mas também o ajuste dinâmico da condutância em resposta ao histórico de estímulos, viabilizando aprendizado local em hardware. Isso contribui para reduzir a necessidade de transferências de dados extensas entre a memória e a unidade de processamento.

Outro ponto crucial é a escalabilidade dos sistemas neuromórficos. Devido à natureza paralela e distribuída de seu funcionamento, é possível aumentar significativamente a densidade das unidades de processamento sem incorrer no mesmo custo energético e térmico das arquiteturas tradicionais. Isso abre espaço para aplicações em Edge Computing e Inteligência Artificial Embarcada.

No entanto, a adoção em larga escala de sistemas neuromórficos ainda enfrenta desafios técnicos, como a padronização de interfaces, a reprodutibilidade dos dispositivos e a integração com sistemas convencionais. Além disso, simular redes de

neurônios em tempo real, com fidelidade e estabilidade, exige abordagens híbridas bem projetadas.

As ferramentas de modelagem e simulação desempenham, nesse contexto, um papel fundamental. Ambientes como NEST, Brian2 e SpikingJelly, além de simuladores físicos como o Falstad e plataformas FPGA, permitem explorar e validar comportamentos neurais em diferentes níveis de abstração antes da implementação em silício.

Por fim, a interdisciplinaridade torna-se um fator-chave no avanço desses sistemas. O diálogo entre engenheiros eletrônicos, neurocientistas, físicos e cientistas da computação é essencial para desenvolver soluções verdadeiramente inovadoras, que possam ir além da simples imitação do cérebro e abrir caminhos para novas formas de computação.

REFERÊNCIAS

CHUA, L. O.; KANG, S. M. Memristive devices and systems. **Proceedings of the IEEE**, v. 64, n. 2, p. 209–223, 1976.

DENG, L. *et al*. Energy consumption analysis for various memristive networks under different learning strategies. **Physics Letters A**, v. 380, n. 7–8, p. 903–909, 2016.

GERSTNER, W.; KISTLER, W. M. **Spiking neuron models:** single neurons, populations, plasticity. Cambridge: Cambridge University Press, 2002.

HODGKIN, A. L.; HUXLEY, A. F. A quantitative description of membrane current and its application to conduction and excitation in nerve. **The Journal of Physiology**, v. 117, n. 4, p. 500–544, 1952.

KHAN ACADEMY. Potencial de membrana neuronal. **Khanacademy.org**, 2023. Disponível em: <https://pt.khanacademy.org/science/biology/human-biology/neuron-nervous-system/a/the-membrane-potential>. Acesso em: 10 jun. 2025.

STRUKOV, D. B. *et al*. The missing memristor found. **Nature**, v. 453, n. 7191, p. 80–83, 2008.

VALOV, I. Interfacial interactions and their impact on redox-based resistive switching memories (ReRAMs). **Semiconductor Science and Technology**, v. 32, n. 9, p. 093006, 2017.

ZANONA, Querusche Klippel. **Modelo do tipo integra-e-dispara de neurônios procurando estabelecer parâmetros para modelagem de integração hipocampo-cortical**. 2009. Monografia (Graduação em Ciências Biológicas) – Universidade Federal do Rio Grande do Sul, Porto Alegre, 2009.

CHEN, J. *et al*. Multiply accumulate operations in memristor crossbar arrays for analog computing. **Journal of Semiconductors**, v. 42, n. 1, p. 13104, 2021.