

07

IA RESPONSÁVEL: ÉTICA, SUSTENTABILIDADE E REGULAÇÃO NA ERA DOS DADOS

PDF exclusivo para Murilo Salla - rm568041
murilosalla@protonmail.com

LISTA DE FIGURAS

Figura 1 - Governança ética em projetos de IA.....9
Figura 2 - Origem e mitigação de vieses em IA.....13
Figura 3 - Mitigação de viés algorítmico.....16
Figura 4 - Ciclo de vida sustentável dos modelos de IA.....24

FIAP

LISTA DE QUADROS

Quadro 1 - Comparativo de frameworks éticos globais em IA.....8
Quadro 2 - Pegada de carbono de modelos de IA (CO_2 equivalente).....23
Quadro 3 - SWOT do Marco Brasileiro.....34
Quadro 4 - Quadro Comparativo dos Marcos Regulatórios 38
Quadro 5 - Rigidez *vs* Inovação em frameworks.....39

FIAP

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 - Validação das bibliotecas instaladas no Python 41
Código-fonte 2 - Instalação de bibliotecas no Python 41
Código-fonte 3 - Script para simulação de viés 45
Código-fonte 4 - Exemplo de output 46

FIAP

SUMÁRIO

1 IA RESPONSÁVEL: ÉTICA, SUSTENTABILIDADE E REGULAÇÃO NA ERA DOS DADOS 7
1.1 Introdução 7
1.2 O que é ética em Inteligência Artificial? 7
1.3 Princípios fundamentais da ética em IA 8
1.4 Desafios éticos específicos da IA 9
1.5 Ética por design versus ética corretiva 10

2 FAIRNESS E VIESES ALGORÍTMICOS 12
2.1 Definições e métricas de fairness 12
2.2 Origens e tipos de viés algorítmico 13
2.3 Tensões entre fairness e performance 14
2.4 Estratégias de mitigação de viés 15
2.5 Desafios específicos em modelos generativos 16

3 IA E IMPACTOS SOCIAIS: EXCLUSÃO DIGITAL E DESINFORMAÇÃO 18
3.1 Exclusão digital: Dimensões e manifestações 18
3.2 IA e aprofundamento de desigualdades 19
3.3 Desinformação e amplificação algorítmica 20
3.4 Estratégias de detecção e mitigação 21
3.5 Impactos na democracia e participação política 21

4 SUSTENTABILIDADE E IMPACTO AMBIENTAL DA IA 23
4.1 Pegada de carbono dos modelos de IA 23
4.2 Ferramentas e metodologias de medição 24
4.3 Estratégias de mitigação e IA Verde 25
4.4 Trade-offs entre performance e sustentabilidade 26
4.5 Políticas e regulação ambiental 26
4.6 Democratização versus sustentabilidade 27

5 PANORAMA GLOBAL DE REGULAÇÕES 28
5.1 O AI Act Europeu: Liderança regulatória 28
5.2 Abordagem Norte-Americana: Autorregulação e inovação 29
5.3 Modelo Chinês: Controle estatal e soberania digital 30
5.4 Abordagens emergentes em outras jurisdições 30
5.5 Desafios de fragmentação regulatória 31
5.6 Tendências de convergência e divergência 31

6 DESAFIOS DO BRASIL: DE CONSUMIDOR A PRODUTOR DE TECNOLOGIA 33
6.1 Cenário atual da IA no Brasil 33
6.2 Marco Legal Brasileiro: PL 2.338/2023 34
6.3 Desafios regulatórios e de implementação 34
6.4 Oportunidades setoriais e vantagens competitivas 35
6.5 Educação e desenvolvimento de talentos 35
6.6 Estratégias de soberania digital 36
6.7 Integração regional e cooperação internacional 37

7 ESTUDO DE CASO: MARCOS REGULATÓRIOS GLOBAIS DE IA 38
7.1 Metodologia de comparação 38
7.2 Análise detalhada das divergências 39

FINAL

7.3 Implicações para empresas globais 39
7.4 Impactos no desenvolvimento tecnológico 40
7.5 Lições para o Marco Brasileiro 40
8 DESAFIO PRÁTICO: IDENTIFICAÇÃO DE VIÉS ALGORÍTMICO 41
8.1 Contexto do Dataset 41
8.2 Código para análise de viés 41
8.3 Interpretação dos resultados 46
8.4 Reflexão ética e proposta de mitigação: Identificando vieses no código 46
CONCLUSÃO 49
REFERÊNCIAS 52
GLOSSÁRIO 55

FIAP

1 IA RESPONSÁVEL: ÉTICA, SUSTENTABILIDADE E REGULAÇÃO NA ERA DOS DADOS

1.1 Introdução

A crescente integração da Inteligência Artificial em diversos setores da sociedade tem gerado transformações profundas na forma como vivemos, trabalhamos e nos relacionamos. Contudo, junto com as promessas de eficiência, inovação e progresso, emergem questões fundamentais sobre os impactos éticos, sociais e ambientais dessas tecnologias.

Este capítulo se propõe a construir uma base crítica sólida para a compreensão dos dilemas que permeiam o desenvolvimento e as aplicações da IA, abrangendo desde questões de *fairness* e viés algorítmico até os desafios ambientais e regulatórios que moldam o cenário contemporâneo. A discussão se torna ainda mais relevante ao considerarmos o posicionamento do Brasil no cenário global da regulação tecnológica. A transição de consumidor para produtor de tecnologia representa tanto uma oportunidade estratégica quanto um desafio complexo, que demanda compreensão aprofundada dos marcos regulatórios internacionais e das especificidades do contexto nacional.

1.2 O que é ética em Inteligência Artificial?

A ética em Inteligência Artificial surge como um campo de estudos interdisciplinar que busca examinar as implicações morais, sociais e filosóficas do desenvolvimento e uso de sistemas inteligentes. Diferentemente da ética tradicional, que se concentra na análise de ações humanas, a ética em IA deve lidar com a complexidade adicional de sistemas que podem tomar decisões de forma autônoma ou semiautônoma, afetando diretamente a vida de indivíduos e comunidades inteiras.

O filósofo **Mark Coeckelbergh**, uma das vozes mais influentes neste debate, argumenta que a ética em IA não pode ser reduzida simplesmente à aplicação de princípios éticos tradicionais a novas tecnologias. Em sua obra *Ética na IA*, Coeckelbergh enfatiza que o desenvolvimento tecnológico em IA transforma não

apenas nossas capacidades, mas também nossa própria compreensão do que significa ser humano e como devemos viver em sociedade. Esta perspectiva desafia a visão instrumental da tecnologia, sugerindo que a IA não é meramente uma ferramenta neutra, mas um agente transformador que redefine relações sociais, estruturas de poder e valores coletivos.

Em 2022, a **UNESCO** reconheceu a urgência e a complexidade das questões relacionadas à Inteligência Artificial e publicou um documento oficial com recomendações sobre sua ética, estabelecendo diretrizes globais para orientar o desenvolvimento responsável dessa tecnologia. Esse documento representa um marco na tentativa de criar um consenso internacional sobre os princípios éticos que devem nortear a IA, abordando questões como **transparência, *accountability*, *fairness* e respeito aos direitos humanos**.

As recomendações da UNESCO são estruturadas em torno de quatro valores fundamentais: respeito pela dignidade humana, redução das desigualdades, proteção do meio ambiente e da biodiversidade, e garantia de diversidade e inclusividade.

Princípio	UNESCO (2022)	AI Act UE (2024)	PL 2.338/2023 (Brasil)
Transparência	✓	✓ (Alto Risco)	✓
Não discriminação	✓	✓	✓ (Art. 5º)
Sustentabilidade	✓	✗	Parcial (Art. 12)
Responsabilidade	✓	✓	✓ (Art. 7º)

Quadro 1 - Comparativo de frameworks éticos globais em IA
Fonte: UNESCO (2023); Almeida & Costa (2024); Silva & Rodrigues (2024), adaptado pelo autor (2025)

1.3 Princípios fundamentais da ética em IA

A ética em IA se estrutura sobre diversos princípios fundamentais que, embora variem em sua formulação específica entre diferentes frameworks, convergem nos aspectos essenciais para o desenvolvimento responsável da tecnologia. O primeiro **princípio é o da transparência e explicabilidade**, que exige que **sistemas de IA sejam compreensíveis em suas operações e decisões**. Este princípio se torna particularmente desafiador em contextos de Deep Learning e modelos de IA Generativa, nos quais a complexidade algorítmica pode tornar as decisões opacas — até mesmo para os próprios desenvolvedores.

O segundo princípio fundamental é o da ***accountability* e responsabilidade**, que estabelece a **necessidade de definir claramente quem é responsável pelas decisões e consequências dos sistemas de IA**. Esta questão se torna complexa em contextos nos quais múltiplos atores participam do desenvolvimento, implementação e manutenção de sistemas inteligentes — desde cientistas de dados até gestores executivos e reguladores. A definição de responsabilidade não é apenas uma questão técnica, mas também jurídica e social, visto que determina como a sociedade pode exigir prestação de contas em casos de danos ou funcionamento inadequado dos sistemas.

O terceiro princípio é o da **justiça e não discriminação**, que busca garantir que **sistemas de IA não perpetuem ou ampliem desigualdades existentes na sociedade**. Este princípio se materializa por meio de práticas de ***algorithmic fairness***. A importância deste princípio se evidencia em casos documentados em que sistemas de IA reproduziram vieses históricos presentes nos dados de treinamento, resultando em discriminação sistemática contra grupos minoritários.

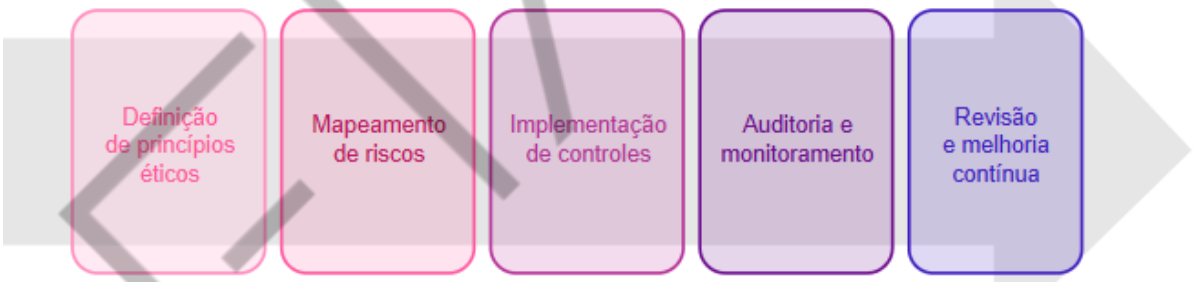


Figura 1 - Governança ética em projetos de IA
Fonte: UNESCO (2023); NIST (2023), adaptado pelo autor (2025)

1.4 Desafios éticos específicos da IA

A implementação de princípios éticos em sistemas de IA enfrenta desafios únicos que não se observam em outras áreas da ética aplicada. Um dos principais desafios é o que pode ser denominado como **paradoxo da automação ética**: quanto mais automatizamos decisões éticas, maior a necessidade de supervisão humana qualificada para garantir que essas decisões permaneçam alinhadas com valores

sociais. Essa tensão se manifesta especialmente em aplicações críticas como nas áreas da saúde, da justiça criminal e da concessão de crédito, nas quais as decisões automatizadas podem ter impactos significativos na vida das pessoas.

Outro desafio é a **contextualidade cultural dos valores éticos**. Sistemas de IA desenvolvidos em determinados contextos culturais podem carregar valores e pressupostos que não são universalmente aceitos. As recomendações da UNESCO reconhecem esta questão ao enfatizar a importância da diversidade cultural e da participação de diferentes perspectivas no desenvolvimento de sistemas éticos de IA. Essa consideração é particularmente relevante para países como o Brasil, que devem equilibrar a adoção de tecnologias desenvolvidas globalmente com a preservação de valores e necessidades locais.

Um terceiro desafio reside na **velocidade de evolução tecnológica *versus* a estabilidade necessária para frameworks éticos**. Enquanto a tecnologia de IA evolui rapidamente, sistemas éticos requerem tempo para desenvolvimento, teste e validação social. Esse descompasso temporal gera o risco de que frameworks éticos se tornem obsoletos antes mesmo de serem completamente implementados, ou que a pressão por inovação leve ao abandono de considerações éticas em favor de vantagens competitivas.

1.5 Ética por design versus ética corretiva

Uma distinção fundamental na ética em IA está entre as **abordagens preventivas (*ethics by design*)** e as **corretivas (*ethics by correction*)**. A ética por design propõe a integração de considerações éticas desde as fases iniciais do desenvolvimento de sistemas de IA, influenciando decisões relacionadas à arquitetura, aos dados de treinamento, às métricas de avaliação e às interfaces de usuário. Essa abordagem é considerada mais eficaz por permitir que valores éticos sejam incorporados à estrutura fundamental do sistema, em vez de serem adicionados posteriormente como camadas superficiais.

Por outro lado, as abordagens corretivas buscam identificar e remediar problemas éticos em sistemas já desenvolvidos e implementados. Embora necessárias em muitos contextos, essas abordagens tendem a ser mais custosas e

menos eficazes, pois pode ser necessário realizar modificações substanciais em sistemas complexos. O caso da Amazon, já discutido anteriormente, ilustra os riscos e custos associados à dependência exclusiva de abordagens corretivas.

A implementação eficaz da ética por design requer mudanças organizacionais significativas, incluindo a formação de equipes multidisciplinares, o desenvolvimento de novas competências profissionais e a criação de processos de validação ética contínua. Essas mudanças não são apenas técnicas, mas também culturais, exigindo que as organizações reconheçam a ética como um componente estratégico essencial — e não como um obstáculo à inovação.

FIAP

2 FAIRNESS E VIESES ALGORÍTMICOS

A questão da justiça algorítmica (***algorithmic fairness***) representa um dos aspectos mais complexos e urgentes da ética em IA. O conceito de *fairness* em algoritmos se refere à capacidade de sistemas automatizados de tomar decisões que não discriminem injustamente indivíduos ou grupos baseados em características protegidas como raça, gênero, idade ou status socioeconômico. No entanto, a definição e implementação de *fairness* em contextos algorítmicos se revela consideravelmente mais complexa do que pode parecer inicialmente, envolvendo dilemas matemáticos, sociais e filosóficos profundos.

2.1 Definições e métricas de fairness

A literatura em *algorithmic fairness* identifica **múltiplas definições de justiça, muitas das quais são matematicamente incompatíveis entre si**. Esta incompatibilidade não é um defeito dos frameworks propostos, mas sim uma reflexão da complexidade inerente ao conceito de justiça em contextos sociais diversos. Entre as principais definições utilizadas, destacam-se três abordagens fundamentais.

A **paridade demográfica** (*demographic parity*) exige **que diferentes grupos demográficos recebam resultados positivos na mesma proporção**. Por exemplo, em um sistema de aprovação de empréstimos, essa métrica exigiria que a taxa de aprovação fosse igual entre diferentes grupos raciais. Embora seja uma abordagem intuitiva e de fácil implementação, pode ser considerada problemática em contextos nos quais existam diferenças legítimas entre grupos, relevantes para a decisão em questão.

A **igualdade de oportunidade** (*equality of opportunity*) foca na paridade de taxas de verdadeiros positivos entre grupos. No contexto de aprovação de empréstimos, isso significa que, entre os indivíduos que são bons pagadores, a proporção de aprovações deve ser igual entre os grupos. Essa métrica reconhece que podem existir diferenças legítimas nos resultados finais, mas exige que as oportunidades sejam distribuídas de forma justa entre os indivíduos qualificados.

A **calibração** exige que a probabilidade condicional de um resultado positivo, dado um score específico do algoritmo, seja igual entre os grupos. Essa abordagem busca garantir que o significado de um score específico seja consistente independentemente do grupo demográfico do indivíduo avaliado.

2.2 Origens e tipos de viés algorítmico

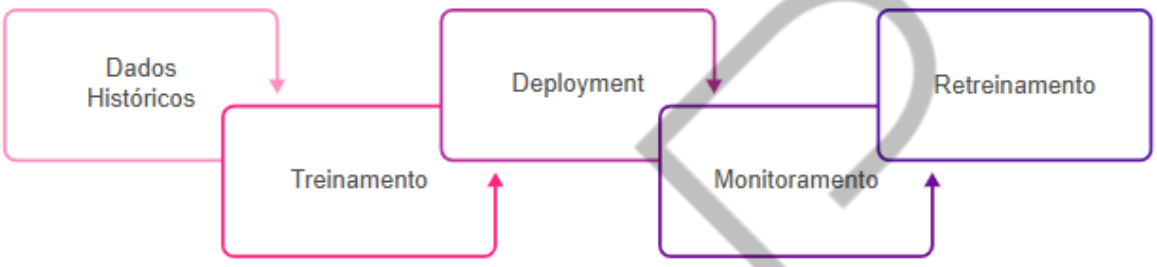


Figura 2 - Origem e mitigação de vieses em IA
Fonte: DAMA International (2017); NIST (2023), adaptado pelo autor (2025)

O **viés algorítmico pode originar-se em múltiplas etapas do desenvolvimento e implementação de sistemas de IA**, desde a coleta de dados até a interpretação de resultados. Compreender essas origens é essencial para desenvolver estratégias eficazes de mitigação. O primeiro tipo é o **viés histórico**, que reflete desigualdades e discriminações presentes na sociedade e que se manifestam nos dados históricos utilizados para treinamento. Esse tipo de viés é particularmente pernicioso, pois pode perpetuar — e até amplificar — injustiças sociais já existentes.

O caso do sistema de saúde analisado na Universidade de Stanford ilustra claramente como vieses históricos podem ser incorporados inadvertidamente em sistemas aparentemente neutros. O algoritmo utilizava gastos médicos anteriores como proxy para a necessidade de cuidados futuros. No entanto, essa abordagem desconsiderava o fato de que pacientes negros, historicamente, recebiam menos tratamentos devido a barreiras socioeconômicas e raciais, resultando em subestimação sistemática de suas necessidades médicas.

O **viés de representação** ocorre quando os dados de treinamento não representam adequadamente a população sobre a qual o algoritmo será aplicado. Esse problema é comum em contextos nos quais determinados grupos estão sub-representados nos datasets, ocasionando menor acurácia e *fairness* para essas populações. Em aplicações de reconhecimento facial, por exemplo, datasets

historicamente dominados por imagens de indivíduos brancos resultaram em sistemas com maior taxa de erro para pessoas negras.

O **viés de medição** surge quando existe variabilidade sistemática na qualidade ou tipo de dados coletados para diferentes grupos. Isso pode ocorrer devido a diferenças nos instrumentos de medição, nas condições de coleta de dados, ou na disponibilidade de informações para diferentes populações. Em contextos médicos, esse tipo de viés pode manifestar-se quando determinados grupos têm menor acesso a testes diagnósticos de alta qualidade, o que resulta em dados menos precisos e pode levar a tratamentos inadequados.

2.3 Tensões entre fairness e performance

Uma das descobertas mais importantes na pesquisa sobre *algorithmic fairness* é a existência de ***trade-offs*** fundamentais entre diferentes métricas de justiça, bem como entre *fairness* e performance do modelo. Esses *trade-offs* não são meras limitações técnicas temporárias, mas refletem tensões filosóficas profundas acerca da natureza da justiça e da equidade.

A tensão entre *fairness* e *accuracy* é particularmente relevante em aplicações práticas. **Estudos empíricos demonstram que técnicas modernas de Machine Learning, embora superiores em termos de performance preditiva, tendem a ser menos interpretáveis do que modelos mais simples**. Essa tensão coloca as organizações diante de escolhas complexas: aceitar modelos menos precisos em favor de maior transparência e *fairness*, ou utilizar modelos de alta performance que podem ser mais difíceis de auditar e explicar.

O ***impossibility theorem de fairness*** demonstra, matematicamente, que diferentes definições de justiça algorítmica são mutuamente exclusivas em muitos contextos práticos. Isso significa que é **impossível satisfazer simultaneamente todas as métricas de *fairness* desejáveis**, forçando desenvolvedores e organizações a fazer escolhas explícitas sobre quais aspectos de justiça priorizar. Essa necessidade de escolha torna a definição de *fairness* uma questão não apenas técnica, mas também política e social.

2.4 Estratégias de mitigação de viés

O desenvolvimento de estratégias eficazes para mitigação do viés algorítmico requer uma abordagem multifacetada, que atue em diferentes estágios do pipeline de Machine Learning. As estratégias podem ser categorizadas em três abordagens principais: ***pre-processing***, ***in-processing*** e ***post-processing***.

Técnicas de ***pre-processing*** focam na modificação dos dados de treinamento para reduzir vieses antes do treinamento do modelo. Elas incluem métodos de ***re-sampling*** para equilibrar representação entre grupos, técnicas de ***data augmentation*** para aumentar a diversidade dos dados, e abordagens de ***feature selection*** que removem variáveis potencialmente discriminatórias. Embora essas técnicas sejam conceptualmente simples, sua implementação eficaz requer cuidado para evitar a introdução de novos vieses ou a redução excessiva da qualidade dos dados.

Os métodos de ***in-processing*** modificam o algoritmo de aprendizado em si para incorporar *constraints* de *fairness* durante o treinamento. Pesquisas recentes demonstram que técnicas de **Deep Reinforcement Learning** podem ser particularmente eficazes nessa abordagem, permitindo que os sistemas aprendam a otimizar simultaneamente performance e *fairness* por meio de funções de *reward* especializadas. Estudos aplicados à predição da COVID-19 em hospitais mostraram que essas técnicas podem manter alta eficácia clínica, ao mesmo tempo que reduzem significativamente os vieses relacionados à etnia e ao local de tratamento.

Por último, as técnicas de ***post-processing*** ajustam as saídas de modelos já treinados para melhorar *fairness* sem requerer re-treinamento. Essas abordagens são particularmente úteis em contextos onde modificações nos dados ou algoritmos não são práticas, mas têm a limitação de não abordar as causas fundamentais do viés, o que pode resultar em soluções menos robustas.

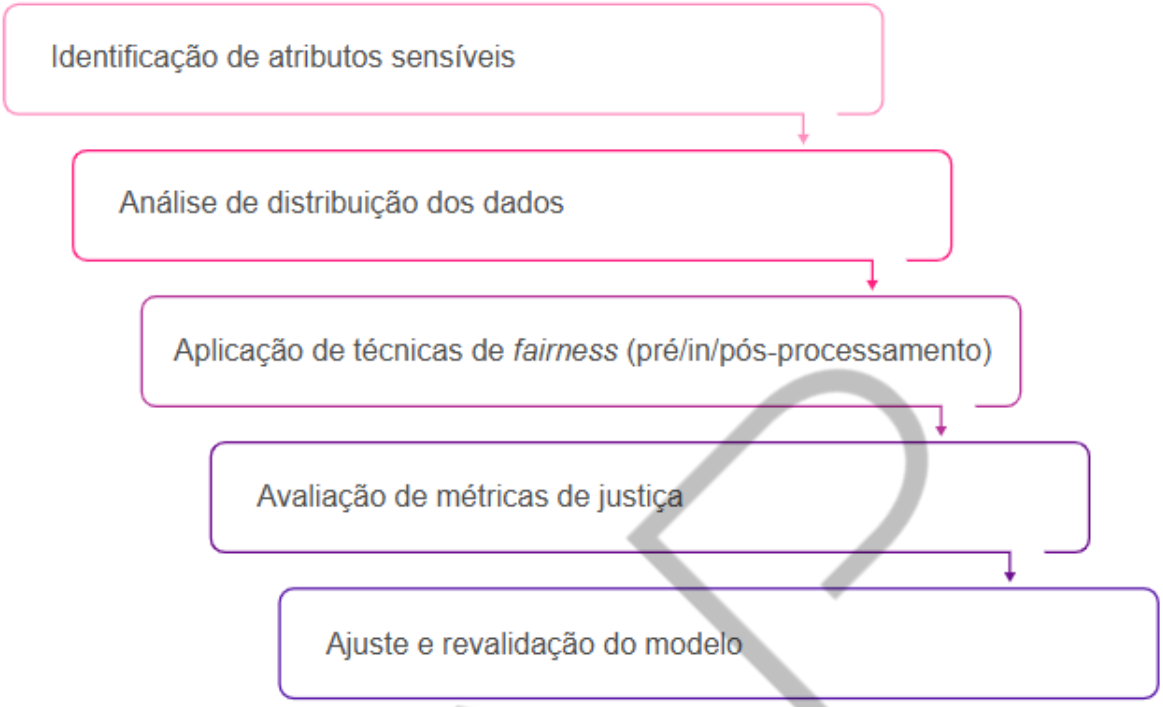


Figura 3 - Mitigação de viés algorítmico
Fonte: Bartlett *et al*. (2023); Müller *et al*. (2023), adaptado pelo autor (2025)

2.5 Desafios específicos em modelos generativos

O surgimento de modelos de IA Generativa introduziu novos desafios para *algorithmic fairness* que não eram plenamente antecipados pelos frameworks tradicionais. Diferentemente de modelos preditivos clássicos, os **sistemas generativos podem criar conteúdo novo que incorpora e potencialmente amplifica vieses de formas imprevistas**.

O caso do aplicativo Lensa, analisado em pesquisa recente, ilustra como sistemas generativos podem perpetuar estereótipos visuais e de gênero ao produzir ilustrações que refletem vieses presentes nos dados de treinamento. Estudos documentam que as ilustrações produzidas pelo sistema tendiam a:

- Sexualizar representações femininas (86% das imagens de mulheres com trajes inadequados *versus* 12% dos homens);
- Sub-representar fenótipos não europeus (apenas 22% das imagens de pessoas negras mantinham características faciais autênticas);

- Reforçar padrões de beleza hegemônicos (92% das imagens ajustavam medidas corporais para padrões irreais).

Esses vieses emergem diretamente da composição dos dados de treinamento — 78% provenientes de bancos de imagens ocidentais com representação desequilibrada — e da ausência de filtros éticos no processo de geração. O caso evidencia a necessidade urgente de governança proativa em IA Generativa, combinando auditorias de diversidade representacional com técnicas de *counterfactual data augmentation*.

Os **modelos generativos também apresentam desafios únicos de avaliação de *fairness*, pois suas saídas são frequentemente criativas e contextuais, dificultando a aplicação de métricas quantitativas tradicionais**. Isso requer o desenvolvimento de novas metodologias de avaliação que sejam capazes de capturar aspectos qualitativos de representação e estereotipagem.

Além disso, a capacidade de modelos generativos de produzir conteúdo **convincente, mas potencialmente incorreto (alucinações) cria riscos específicos relacionados à amplificação de desinformação e narrativas discriminatórias**. Esses riscos requerem abordagens de governança que combinem monitoramento técnico com supervisão editorial humana.

3 IA E IMPACTOS SOCIAIS: EXCLUSÃO DIGITAL E DESINFORMAÇÃO

A crescente digitalização da sociedade e a expansão de sistemas baseados em IA têm ocasionado impactos sociais complexos, que se manifestam de forma desigual entre diferentes grupos populacionais. Dois fenômenos particularmente preocupantes emergem dessa transformação: a **exclusão digital** e a **proliferação de desinformação**. Ambos representam ameaças significativas à equidade social e à qualidade democrática, exigindo análise cuidadosa de suas interações com tecnologias de IA e Big Data.

3.1 Exclusão digital: Dimensões e manifestações

A exclusão digital não pode ser compreendida unicamente como ausência de acesso a dispositivos ou conectividade à internet. Pesquisas recentes identificam **múltiplas dimensões dessa exclusão**, que se manifestam de forma interseccional e se aprofundam com a crescente centralidade da IA em serviços essenciais. A **primeira dimensão é o acesso material**, que inclui não apenas a disponibilidade de dispositivos e conectividade, mas também a qualidade e estabilidade dessas condições de acesso.

Estudos conduzidos durante o período de ensino remoto emergencial no Brasil revelaram como as disparidades de acesso material se traduziram em desigualdades educacionais profundas. Na região de Ituiutaba/MG, pesquisas documentaram que uma grande parte dos estudantes de escolas públicas não possuía acesso adequado à internet ou conhecimento para utilizar pedagogicamente as tecnologias digitais, resultando na ampliação de desigualdades educacionais para populações já vulneráveis.

A **segunda dimensão é a literacia digital**, que se refere não apenas à capacidade de saber usar a tecnologia, mas também de compreender criticamente seus funcionamentos, limitações e implicações sociais. No contexto de sistemas de IA, essa dimensão se torna particularmente relevante, pois os cidadãos precisam

desenvolver capacidades para avaliar decisões automatizadas, identificar potenciais vieses e exercer direitos relacionados à transparência e explicabilidade algorítmica.

A **terceira dimensão é a exclusão algorítmica**, um fenômeno emergente em que indivíduos são sistematicamente desfavorecidos por algoritmos devido a características que os colocam fora dos padrões dominantes nos dados de treinamento. Essa forma de exclusão é particularmente perversa, pois pode ser invisível até mesmo para os próprios afetados e se perpetuar por meio de *feedback loops* que reforçam marginalizações já existentes.

3.2 IA e aprofundamento de desigualdades

Sistemas de IA podem **tanto mitigar quanto aprofundar exclusões digitais existentes, dependendo de como são desenvolvidos, implementados e governados**. Por um lado, as tecnologias de IA podem democratizar o acesso a serviços especializados, como tradução automática, assistência educacional personalizada e diagnósticos médicos preliminares. Por outro lado, quando desenvolvidos sem a devida consideração à diversidade populacional, esses sistemas podem criar novas barreiras e exclusões.

Um exemplo significativo dessa dualidade se observa em sistemas de reconhecimento de voz e processamento de linguagem natural. Enquanto essas tecnologias podem facilitar acesso à informação para pessoas com dificuldades de leitura ou escrita, elas frequentemente apresentam performance inferior para sotaques regionais, variações linguísticas de grupos minoritários ou modos de expressão não padronizados. Essa limitação efetivamente exclui grupos já marginalizados do acesso pleno a serviços digitais baseados em IA.

A segregação algorítmica representa outra manifestação preocupante desse fenômeno. **Algoritmos de recomendação e personalização podem criar "bolhas informacionais" que limitam a exposição de diferentes grupos a oportunidades, informações ou perspectivas diversas**. Em plataformas de busca de emprego, sistemas de publicidade direcionada ou redes sociais, essa segregação pode reforçar divisões sociais existentes e limitar as possibilidades de mobilidade social.

Pesquisas sobre exclusão digital no contexto educacional brasileiro documentaram que a transição para modalidades remotas durante a pandemia da COVID-19 aprofundou desigualdades preexistentes. Estudantes de famílias de baixa renda não apenas tiveram menor acesso a dispositivos adequados e conectividade estável, mas também menor suporte familiar para navegação de plataformas digitais complexas, resultando em defasagens educacionais que podem ter impactos duradouros.

3.3 Desinformação e amplificação algorítmica

A **proliferação de desinformação** representa um dos desafios mais complexos da era digital, com sistemas de IA desempenhando um papel ambíguo — atuando simultaneamente como ferramenta de combate e vetor de amplificação. A desinformação não é um fenômeno novo, mas a sua velocidade de propagação, escala de alcance e sofisticação técnica foram amplificadas por algoritmos de recomendação e sistemas de distribuição de conteúdo automatizados.

Algoritmos de engajamento em plataformas digitais frequentemente priorizam conteúdo que gera interações intensas, independentemente de sua veracidade. Essa lógica de otimização pode inadvertidamente favorecer informações sensacionalistas, polarizantes ou falsas que tendem a gerar mais cliques, compartilhamentos e comentários do que informações factuais mais moderadas. Esse mecanismo cria incentivos sistemáticos para a produção e distribuição de desinformação.

A capacidade crescente de sistemas de IA Generativa de produzir textos, imagens e vídeos convincentes, porém fabricados, introduz novos vetores de desinformação, desafiando métodos tradicionais de verificação factual. **Deepfakes, textos sintéticos e imagens geradas algoritmicamente podem ser utilizados para criar narrativas falsas sofisticadas, de difícil detecção mesmo para observadores treinados**.

3.4 Estratégias de detecção e mitigação

O desenvolvimento de estratégias eficazes para combater desinformação utilizando IA requer abordagens multifacetadas que combinem detecção automatizada com supervisão humana especializada. Uma pesquisa bibliográfica abrangente identificou 66 artigos científicos que propõem soluções para o enfrentamento da desinformação, sendo os algoritmos de IA, o blockchain e outras tecnologias emergentes as abordagens mais recorrentes.

Técnicas de detecção automatizada incluem análise de padrões linguísticos para identificação de texto gerado artificialmente, verificação de consistência factual por meio de bases de conhecimento estruturadas, e análise de redes de propagação para identificação de campanhas repletas de desinformação. Embora promissoras, essas técnicas enfrentam limitações significativas, principalmente em relação à velocidade da evolução de técnicas de geração sintética e à necessidade de adaptação constante a novos tipos de conteúdo falso.

Abordagens de *fact-checking* automatizado utilizam sistemas de IA para verificar afirmações contra bases de dados factuais conhecidas e fontes confiáveis. No entanto, essas abordagens são limitadas pela disponibilidade de fontes de referência confiáveis e pela complexidade de verificar afirmações que envolvem interpretação contextual ou juízos de valor subjacentes.

3.5 Impactos na democracia e participação política

A intersecção entre exclusão digital, desinformação e IA cria riscos específicos para a qualidade democrática e a participação política informada. **Quando significativos segmentos da população são excluídos do acesso a informações de qualidade ou expostos desproporcionalmente à desinformação, a capacidade coletiva de tomar decisões democráticas informadas é comprometida**.

O contexto eleitoral brasileiro exemplifica estes desafios. A crescente digitalização das campanhas políticas e debates públicos, combinada com alta penetração de redes sociais e aplicativos de mensagem, cria um ambiente em que a

desinformação pode se propagar rapidamente e influenciar nos resultados eleitorais. Ao mesmo tempo, eleitores com menor literacia digital tendem a ser mais vulneráveis a técnicas de manipulação algorítmica e menos capazes de verificar, de forma autônoma, a veracidade das informações recebidas.

Estudos sobre o papel de algoritmos em processos eleitorais destacam a necessidade de marcos regulatórios específicos que equilibrem liberdade de expressão com proteção contra manipulação sistemática. A ausência de regulamentação adequada pode resultar em desequilíbrios sistemáticos que favorecem atores com maior capacidade técnica e financeira para explorar algoritmos de distribuição de conteúdo.

FIAP

4 SUSTENTABILIDADE E IMPACTO AMBIENTAL DA IA

A crescente adoção de sistemas de Inteligência Artificial, particularmente modelos de grande escala como os Large Language Models (LLMs), tem gerado preocupações significativas sobre seu impacto ambiental. O consumo energético associado ao treinamento, à operação e ao armazenamento desses sistemas representa um desafio substancial para as metas globais de sustentabilidade. Essa realidade exige uma análise cuidadosa dos *trade-offs* entre benefícios tecnológicos e custos ambientais.

4.1 Pegada de carbono dos modelos de IA

O cálculo preciso da pegada de carbono de sistemas de IA é uma tarefa complexa que precisa considerar múltiplas fases do ciclo de vida tecnológico. Estudos recentes demonstram que as emissões associadas a LLMs abrangem não apenas o treinamento inicial dos modelos, mas também processos de inferência, experimentação, armazenamento e até mesmo as emissões “incorporadas” dos hardwares utilizados.

Modelo	Treinamento	Inferência (1M requisições)	Ferramenta de medição
GPT-3	552 t	4.2 t	LLMCarbon 17
BERT	0.9 t	0.1 t	mlco2 20
Modelo MoE	320 t	2.8 t	LLMCarbon

Quadro 2 - Pegada de carbono de modelos de IA (CO_2 equivalente)
Fonte: Kaneda *et al.* (2023); Strubell *et al*. (2023), adaptado pelo autor (2025)

O treinamento de modelos de grande escala pode consumir quantidades extraordinárias de energia. Estimativas indicam que o **treinamento de modelos como GPT-3 pode gerar centenas de toneladas de CO_2 equivalente, comparável às emissões anuais de dezenas de automóveis**. No entanto, essas estimativas frequentemente subestimam o impacto total, pois **desconsideram tentativas malsucedidas de treinamento, experimentação de hiperparâmetros e iterações de desenvolvimento que antecedem o modelo final**.

A fase de inferência — quando modelos treinados são utilizados para produzir resultados — também contribui de forma significativa para a pegada de carbono total, especialmente no caso de modelos amplamente utilizados. Ao contrário do

treinamento, que ocorre apenas uma vez, a inferência é contínua e escala conforme o número de usuários e a frequência de uso. **Para modelos populares que atendem a milhões de requisições diárias, o custo energético cumulativo da inferência pode exceder o custo do treinamento inicial**.

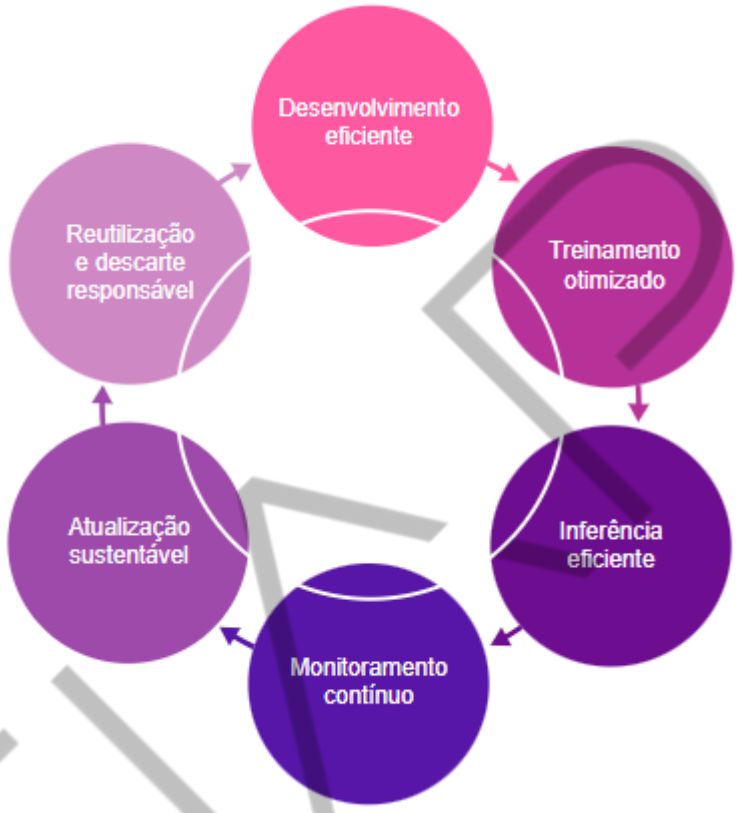


Figura 4 - Ciclo de vida sustentável dos modelos de IA
Fonte: Kaneda *et al*. (2023); Strubell *et al.* (2023), adaptado pelo autor (2025)

4.2 Ferramentas e metodologias de medição

O desenvolvimento de ferramentas precisas para medição do impacto ambiental de sistemas de Machine Learning tornou-se uma prioridade de pesquisa. Várias ferramentas foram desenvolvidas para tracking de energia durante o treinamento de modelos, cada uma com características, limitações e casos de uso específicos.

O **mlco2**, uma das primeiras ferramentas amplamente adotadas, permitiu estimativas preliminares da pegada de carbono de redes neurais. No entanto, estudos comparativos identificaram limitações significativas dessa ferramenta, incluindo incapacidade de estimar emissões para arquiteturas como **mixture-of-experts (MoE)**,

desconsideração de parâmetros arquiteturais críticos, foco exclusivo em GPUs e ausência de modelagem de emissões incorporadas de hardware.

Em resposta a essas limitações, foi desenvolvido o **LLMCarbon**, um modelo de projeção *end-to-end* especificamente desenhado para modelos densos e MoE. **Comparações empíricas demonstram que o LLMCarbon oferece estimativas significativamente mais precisas para diversos tipos de LLMs**, considerando tanto as emissões operacionais quanto as incorporadas.

Estudos comparativos entre diferentes ferramentas de medição revelam variações substanciais nas estimativas de consumo energético para os mesmos modelos, dependendo da metodologia utilizada, tipo de servidor e configurações específicas. Essa variabilidade destaca a importância de padronização metodológica e a necessidade de desenvolver *benchmarks* confiáveis para a comparação dos impactos ambientais.

4.3 Estratégias de mitigação e IA Verde

O conceito de “IA Verde” (*Green AI*) emerge como uma abordagem que busca equilibrar a performance dos modelos com a eficiência energética. Essa perspectiva desafia a tendência dominante de maximizar *accuracy* independentemente do custo computacional, propondo que métricas de sustentabilidade sejam incorporadas como critérios fundamentais na avaliação de sistemas de IA.

Estratégias de otimização algorítmica incluem técnicas como *pruning* de modelos (remoção de parâmetros redundantes), quantização (redução da precisão numérica) e destilação de conhecimento (transferência de capacidades de modelos grandes para modelos menores). Essas técnicas podem reduzir significativamente os requisitos computacionais de modelos sem a degradação substancial de performance.

Eficiência de hardware representa outra fronteira importante para a IA sustentável. O desenvolvimento de chips especializados para Machine Learning, como TPUs (Tensor Processing Units) e outros aceleradores dedicados, pode oferecer melhor performance por watt em comparação com GPUs de propósito geral. Além disso, a localização geográfica de data centers em regiões com maior

disponibilidade de energia renovável pode reduzir substancialmente a pegada de carbono de operações de IA.

4.4 Trade-offs entre performance e sustentabilidade

A busca por IA sustentável inevitavelmente envolve *trade-offs* complexos entre performance de modelos, qualidade de resultados e impacto ambiental. Esses *trade-offs* não são meramente técnicos, mas refletem questões mais profundas sobre prioridades sociais e distribuição de custos e benefícios tecnológicos.

Em algumas aplicações, **pequenas reduções em *accuracy* podem ser aceitáveis se resultarem em reduções substanciais de consumo energético**. Para aplicações como sistemas de recomendação em e-commerce ou algoritmos de classificação de conteúdo em redes sociais, a diferença entre 85% e 87% de *accuracy* pode ser irrelevante para a experiência do usuário, mas significativa em termos de impacto ambiental quando operada em larga escala.

Por outro lado, aplicações críticas como diagnóstico médico ou sistemas de segurança podem justificar maior consumo energético se isso resultar em performance superior que pode salvar vidas ou prevenir acidentes. Essa variabilidade na importância relativa de performance *versus* sustentabilidade requer frameworks de decisão contextualmente sensíveis.

4.5 Políticas e regulação ambiental

O crescente reconhecimento do impacto ambiental da IA está levando ao desenvolvimento de políticas e regulações específicas que exigem maior transparência e responsabilidade ambiental de desenvolvedores e operadores de sistemas de IA. Alguns países estão considerando requisitos de relatório de emissões para modelos de grande escala, similares aos requisitos existentes para outras indústrias intensivas em energia.

A **União Europeia**, por meio do **AI Act**, **inclui considerações ambientais entre os critérios de avaliação de sistemas de IA de alto risco**. Embora ainda não

existam limites específicos de emissões, a **tendência regulatória sugere que as métricas ambientais podem se tornar requisitos legais em um futuro próximo**.

No contexto brasileiro, cuja matriz energética possui maior proporção de fontes renováveis em comparação a outros países, **há uma oportunidade única para o desenvolvimento da IA sustentável**. No entanto, essa vantagem comparativa pode ser comprometida caso não sejam implementadas políticas proativas que incentivem práticas de desenvolvimento ambientalmente responsáveis.

4.6 Democratização versus sustentabilidade

Um dilema particular emerge na tensão entre democratização do acesso à IA e sustentabilidade ambiental. Modelos menores e mais eficientes podem ser mais acessíveis para organizações com recursos limitados, promovendo democratização tecnológica. Ao mesmo tempo, esses modelos tendem a apresentar um desempenho inferior em comparação a modelos maiores, o que pode gerar desigualdades na qualidade de serviços de IA disponíveis para diferentes grupos.

Essa tensão é particularmente relevante para países em desenvolvimento, que podem enfrentar pressões conflitantes entre adotar as tecnologias de IA mais avançadas (e energeticamente intensivas) para competir globalmente, ou priorizar abordagens mais sustentáveis que podem resultar em capacidades tecnológicas limitadas.

A **resolução desse problema requer inovação em modelos de negócios que permitam o acesso a tecnologias avançadas sem comprometer os objetivos de sustentabilidade**, como sistemas de compartilhamento de infraestrutura computacional, desenvolvimento colaborativo de modelos eficientes e políticas públicas que incentivem tanto a inovação quanto a responsabilidade ambiental.

5 PANORAMA GLOBAL DE REGULAÇÕES

O cenário global de regulação de Inteligência Artificial caracteriza-se por uma diversidade de abordagens que refletem diferentes tradições jurídicas, prioridades políticas e contextos socioculturais. Essa heterogeneidade regulatória cria tanto oportunidades quanto desafios para organizações que operam internacionalmente e para países que buscam posicionar-se estrategicamente no ecossistema global de IA.

5.1 O AI Act Europeu: Liderança regulatória

A União Europeia estabeleceu-se como pioneira na regulamentação abrangente de IA por meio do **Artificial Intelligence Act, aprovado em 2024**. Essa legislação representa a **primeira tentativa de criar um framework regulatório abrangente para IA em escala supranacional**, estabelecendo precedentes que influenciam desenvolvimentos regulatórios em outras jurisdições.

O AI Act adota uma abordagem baseada em risco, classificando sistemas de IA em quatro categorias: **risco inaceitável** (proibidos), **alto risco** (regulação rigorosa), **risco limitado** (obrigações de transparência) e **risco mínimo** (sem obrigações específicas). Essa taxonomia busca equilibrar inovação com proteção de direitos fundamentais, permitindo o desenvolvimento tecnológico em áreas de baixo risco enquanto impõe controles rigorosos em aplicações que podem afetar significativamente a vida dos cidadãos.

Sistemas de risco inaceitável incluem aplicações que utilizam técnicas subliminares, exploram vulnerabilidades de grupos específicos, ou implementam sistemas de pontuação social abrangentes. A proibição dessas aplicações reflete valores europeus sobre dignidade humana e autonomia individual, estabelecendo limites claros sobre usos considerados fundamentalmente incompatíveis com os direitos fundamentais.

A **categoria de alto risco** abrange sistemas utilizados em infraestrutura crítica, educação, emprego, aplicação da lei, migração e administração da justiça. **Para esses sistemas, o AI Act exige avaliações rigorosas de conformidade, sistemas**

de gestão de qualidade, documentação técnica detalhada e monitoramento contínuo de performance e riscos.

5.2 Abordagem Norte-Americana: Autorregulação e inovação

Os **Estados Unidos** têm adotado uma abordagem predominantemente baseada em **autorregulação e diretrizes voluntárias, refletindo uma tradição de menor intervenção estatal em mercados tecnológicos**. Essa abordagem prioriza a **manutenção da liderança tecnológica e competitividade econômica**, embora recentemente tenha **evoluído** em direção **a maior supervisão federal**.

O ***AI Bill of Rights*, publicado pela Casa Branca em 2022**, estabelece princípios orientadores para o desenvolvimento responsável de IA, incluindo a **proteção contra discriminação algorítmica, garantias de *data privacy* e os direitos à transparência e à explicabilidade**. Embora não seja legalmente vinculativo, esse documento influencia práticas de agências federais e estabelece expectativas para o setor privado.

A **Executive Order on AI de 2023** representa uma evolução rumo a uma maior regulamentação federal, estabelecendo requisitos de relatório para modelos de grande escala, diretrizes para agências governamentais e iniciativas para o desenvolvimento de padrões técnicos. Essa ordem executiva demonstra crescente reconhecimento de que a autorregulação exclusiva pode ser insuficiente para abordar riscos associados a sistemas de IA avançados.

A abordagem setorial também caracteriza a regulação norte-americana, com diferentes agências desenvolvendo diretrizes específicas para suas áreas de jurisdição. A **Food and Drug Administration (FDA)** regula dispositivos médicos baseados em IA, a **Federal Trade Commission (FTC)** monitora práticas anticompetitivas e proteção ao consumidor, e o **National Institute of Standards and Technology (NIST)** desenvolve frameworks técnicos para a gestão de riscos.

5.3 Modelo Chinês: Controle estatal e soberania digital

A **China desenvolveu um modelo regulatório de IA que reflete suas prioridades de controle estatal, soberania digital e desenvolvimento econômico direcionado**. Esse modelo combina investimento público massivo em pesquisa e desenvolvimento com uma regulação rigorosa de aplicações que podem afetar a estabilidade social ou a segurança nacional.

As **regulamentações de algoritmos chinesas, implementadas a partir de 2022, exigem que os algoritmos utilizados por plataformas digitais sejam registrados junto às autoridades regulatórias e passem por avaliações de impacto social**. Essa abordagem reflete **preocupações sobre a influência de algoritmos na opinião pública e o comportamento social**, principalmente em contextos de recomendação de conteúdo e publicidade direcionada.

A estratégia nacional de IA chinesa estabelece objetivos ambiciosos para liderança global em tecnologias de IA até 2030, combinando investimentos públicos significativos com políticas industriais coordenadas. Essa abordagem de planejamento central contrasta com modelos de mercado predominantes em outras jurisdições, demonstrando diferentes filosofias sobre o papel do Estado no desenvolvimento tecnológico.

5.4 Abordagens emergentes em outras jurisdições

Além dos três modelos dominantes, outras jurisdições estão desenvolvendo frameworks regulatórios próprios, refletindo circunstâncias específicas e prioridades nacionais. O **Reino Unido, por exemplo, adotou uma abordagem de "regulação ágil"**, que evita a legislação específica para IA, optando pela adaptação de frameworks regulatórios já existentes por agências setoriais especializadas.

O **Canadá desenvolveu o Artificial Intelligence and Data Act (AIDA)** como parte de uma reforma mais ampla da privacidade digital. A proposta estabelece requisitos específicos para sistemas de IA de impacto geral e cria mecanismos dedicados de supervisão. Essa abordagem busca equilibrar a proteção de direitos com a manutenção da competitividade em mercados tecnológicos globais.

A **Coreia do Sul implementou frameworks regulatórios específicos para IA** em setores como saúde e transportes, combinando supervisão regulatória com investimentos públicos substanciais em pesquisa e desenvolvimento. Essa abordagem setorial possibilita a adaptação das regulamentações às especificidades técnicas e sociais de diferentes aplicações.

5.5 Desafios de fragmentação regulatória

A diversidade de abordagens regulatórias cria desafios significativos para organizações que operam globalmente e pode fragmentar o desenvolvimento de tecnologias de IA. Diferentes requisitos de conformidade, definições técnicas e obrigações legais podem aumentar custos de desenvolvimento e limitar a interoperabilidade entre sistemas.

O **problema da jurisdição regulatória é particularmente complexo** para sistemas de IA que operam por meio de **fronteiras nacionais, processam dados de múltiplos países, ou são desenvolvidos em uma jurisdição, mas implantados em outras**. A ausência de harmonização internacional pode criar incentivos para **"*forum shopping*" regulatório**, nas quais organizações buscam jurisdições com requisitos menos rigorosos.

Conflitos entre frameworks podem surgir quando organizações devem, simultaneamente, cumprir requisitos europeus de transparência, norte-americanos de proteção ao consumidor, e chineses de controle de conteúdo. **Esses conflitos podem ser irreconciliáveis em alguns casos, forçando organizações a fazer escolhas sobre mercados de atuação ou arquiteturas tecnológicas**.

5.6 Tendências de convergência e divergência

Apesar da diversidade inicial, emergem algumas tendências de convergência em princípios fundamentais para a regulação de IA. **Conceitos como transparência, *accountability*, *non-discrimination* e *human oversight* aparecem consistentemente em diferentes frameworks**, indicando consenso emergente sobre valores básicos que devem orientar o desenvolvimento de IA.

No entanto, **persistem divergências significativas na implementação prática desses princípios**, particularmente em relação ao equilíbrio entre inovação e precaução, papel do Estado *versus* mercado, e priorização de diferentes valores sociais. Essas divergências refletem diferenças fundamentais em tradições políticas e preferências sociais que provavelmente persistirão.

O desenvolvimento de padrões técnicos internacionais através de organizações como **ISO, IEEE e ITU** oferecem um **potencial caminho para alcançar uma maior harmonização**, focando em aspectos técnicos onde o consenso pode ser alcançado mais facilmente. No entanto, padrões técnicos não resolvem divergências sobre valores fundamentais que informam escolhas regulatórias.

FIAP

6 DESAFIOS DO BRASIL: DE CONSUMIDOR A PRODUTOR DE TECNOLOGIA

O **Brasil** encontra-se em um momento crítico para definir seu posicionamento no ecossistema global de Inteligência Artificial, enfrentando o **desafio de transitar de uma posição predominantemente de consumidor de tecnologias desenvolvidas no exterior para um papel mais ativo como produtor e inovador**. Essa transição envolve não apenas aspectos tecnológicos e econômicos, mas também questões regulatórias, educacionais e de soberania digital que necessitam de estratégias coordenadas e investimentos substanciais.

6.1 Cenário atual da IA no Brasil

O Brasil possui características singulares que podem tanto facilitar quanto dificultar seu desenvolvimento como produtor relevante de tecnologias de IA. Por um lado, o país conta com uma base acadêmica sólida em ciência da computação e matemática aplicada, um mercado interno substancial que pode servir como campo para soluções inovadoras e setores econômicos específicos — como agronegócios e energia — em que detém vantagens competitivas globais.

Por outro lado, o país enfrenta limitações significativas em infraestrutura tecnológica, financiamento para pesquisa e desenvolvimento, e capacidade de retenção de talentos especializados. A fuga de “cérebros” para mercados mais desenvolvidos representa um desafio particular, com profissionais qualificados em IA migrando para oportunidades em Silicon Valley, Europa ou outras regiões com ecossistemas tecnológicos mais maduros.

A base empresarial brasileira em IA caracteriza-se por startups emergentes em nichos específicos, algumas empresas de médio porte que desenvolvem soluções setoriais e filiais de multinacionais, que, em geral, executam estratégias desenvolvidas em matrizes estrangeiras. Essa configuração limita a capacidade de desenvolvimento de tecnologias verdadeiramente inovadoras e competitivas globalmente.

6.2 Marco Legal Brasileiro: PL 2.338/2023

O **Projeto de Lei 2.338/2023**, que **estabelece o Marco Legal da Inteligência Artificial no Brasil**, representa um esforço significativo para criar um framework regulatório nacional que equilibre inovação com proteção de direitos. Esse projeto demonstra a tentativa do Brasil de aprender com experiências internacionais enquanto adapta regulamentações às especificidades do contexto nacional.

O projeto adota uma abordagem baseada em risco, **inspirada no AI Act europeu, porém adaptadas às prioridades e limitações específicas brasileiras**. A classificação dos sistemas de IA em diferentes níveis de risco busca proporcionar clareza regulatória para desenvolvedores, ao mesmo tempo em que assegura flexibilidade para a inovação em áreas de menor risco.

Um aspecto particularmente importante do marco legal brasileiro é o tratamento da responsabilidade civil por danos causados por sistemas de IA. O projeto estabelece regimes diferenciados de responsabilização dependendo do tipo de sistema e do papel dos diferentes agentes na cadeia de desenvolvimento e operação. **Essa abordagem busca equilibrar a proteção às vítimas de danos com a preservação de incentivos para inovação tecnológica**.

6.3 Desafios regulatórios e de implementação

Forças	Fraquezas
Alinhamento parcial com UE	Capacidade institucional
Foco em setores estratégicos	Fragilidade em I&D

Quadro 3 - SWOT do Marco Brasileiro
Fonte: Silva & Rodrigues (2024); Almeida & Costa (2024); NIST (2023), adaptado pelo autor (2025)

A implementação eficaz do marco legal brasileiro enfrenta desafios substanciais relacionados à capacidade institucional de supervisão e fiscalização. Diferentemente da União Europeia, que possui recursos significativos e expertise técnica desenvolvida ao longo de anos, o **Brasil precisa simultaneamente desenvolver competências regulatórias e implementar novas obrigações legais**.

A capacitação de agentes públicos para a compreensão e supervisão de tecnologias de IA representa um desafio específico. Reguladores, magistrados e

outros agentes públicos precisam desenvolver *literacy* técnica suficiente para avaliar compliance, investigar violações e adjudicar disputas relacionadas a sistemas de IA.

A coordenação entre diferentes esferas de governo também apresenta complexidades, considerando que competências relacionadas à proteção de dados, defesa do consumidor, regulação setorial e políticas de inovação estão distribuídas entre diferentes níveis federativos e órgãos especializados. A falta de uma coordenação eficaz pode resultar em sobreposições, lacunas ou conflitos regulatórios.

6.4 Oportunidades setoriais e vantagens competitivas

Apesar dos desafios, o Brasil possui oportunidades específicas para consolidar uma posição de liderança em aplicações setoriais de IA, nas quais já possui expertise e vantagens competitivas reconhecidas. O **agronegócio representa uma área bastante promissora**, onde a combinação de expertise agrícola brasileira com tecnologias de IA pode gerar soluções globalmente competitivas.

A **agricultura de precisão**, monitoramento ambiental via satélite, otimização de cadeias de suprimento agrícola e desenvolvimento de variedades resistentes às mudanças climáticas são áreas em que o Brasil pode não apenas consumir tecnologias estrangeiras, mas também desenvolver soluções próprias com grande potencial de exportação.

O **setor de energia**, particularmente de energias renováveis, oferece outro campo promissor. A experiência brasileira com hidrelétricas, biomassa e crescente expansão solar e eólica pode ser potencializada pelos sistemas de IA para otimização de redes inteligentes, previsão de demanda e integração de fontes renováveis intermitentes.

6.5 Educação e desenvolvimento de talentos

A transição para produtor de tecnologia requer investimentos substanciais em educação e formação de recursos humanos especializados. O Brasil enfrenta o desafio de, simultaneamente, expandir a base de profissionais com competências em

IA e reter talentos diante da concorrência de mercados internacionais, que oferecem remunerações superiores.

Iniciativas de educação em IA precisam começar na educação básica, desenvolvendo *literacy digital* e pensamento computacional que preparem as futuras gerações para trabalhar com e desenvolver tecnologias de IA. Ao mesmo tempo, programas de graduação e pós-graduação precisam ser expandidos e atualizados para refletir demandas contemporâneas do mercado.

A **colaboração universidade-empresa** emerge como elemento crucial para o desenvolvimento de um ecossistema de inovação robusto. Parcerias que permitam pesquisa aplicada, transferência de conhecimento e formação de profissionais com experiência prática são essenciais para construção de capacidades nacionais competitivas.

6.6 Estratégias de soberania digital

O conceito de soberania digital ganha relevância particular no contexto brasileiro, considerando riscos associados à dependência excessiva de tecnologias estrangeiras para funções críticas de Estado e economia. O **desenvolvimento de capacidades nacionais em IA não é apenas uma questão econômica, mas também de segurança nacional e autonomia política**.

A localização de dados e processamento representa um aspecto técnico importante da soberania digital. Requisitos para que dados sensíveis sejam processados em território nacional podem incentivar desenvolvimento de infraestrutura local, mas também podem aumentar os custos e limitar o acesso a tecnologias avançadas.

Políticas de compras públicas podem ser utilizadas estrategicamente para criar demanda por soluções nacionais, permitindo que empresas brasileiras desenvolvam capacidades e ganhem escala antes de competir em mercados internacionais. No entanto, essas políticas devem equilibrar a proteção da indústria nacional com a eficiência e qualidade de serviços públicos.

6.7 Integração regional e cooperação internacional

O desenvolvimento de capacidades nacionais em IA pode ser potencializado por meio de cooperação regional e parcerias internacionais estratégicas. A integração com outros países latino-americanos pode criar mercados regionais suficientemente grandes para sustentar o desenvolvimento de soluções especializadas.

Mercados hispanófonos oferecem oportunidades particulares para soluções de processamento de linguagem natural e sistemas de comunicação desenvolvidos no Brasil, considerando as proximidades culturais e linguísticas. De forma similar, a cooperação com países africanos lusófonos pode fomentar nichos específicos para tecnologias brasileiras.

Parcerias com centros de excelência internacionais em pesquisa têm o potencial de acelerar o desenvolvimento de capacidades nacionais por meio da transferência de conhecimento, da colaboração em projetos de pesquisa e do intercâmbio de pesquisadores. No entanto, tais parcerias devem ser estruturadas para garantir benefícios mútuos e evitar relações puramente extrativas.

7 ESTUDO DE CASO: MARCOS REGULATÓRIOS GLOBAIS DE IA

Para ilustrar concretamente as diferentes abordagens regulatórias discutidas neste capítulo, apresentamos uma análise comparativa detalhada dos três principais frameworks de regulação de IA: o AI Act europeu, o modelo de autorregulação norte-americano e a abordagem de controle estatal chinês. Esta comparação evidencia como diferentes valores culturais, tradições jurídicas e prioridades políticas se traduzem em estratégias regulatórias distintas.

7.1 Metodologia de comparação

A análise comparativa baseia-se em documentos oficiais, literatura acadêmica e relatórios de implementação disponíveis até 2024. Utilizamos um framework de análise estruturado em seis dimensões: (1) **filosofia regulatória**, (2) **escopo de aplicação**, (3) **mecanismos de *enforcement***, (4) **requisitos de transparência**, (5) **tratamento de inovação** e (6) **impactos observados ou antecipados**.

Dimensão	União Europeia (AI Act)	Estados Unidos	China
Filosofia	Abordagem baseada em risco com foco em direitos fundamentais.	Autorregulação orientada por mercado com supervisão crescente.	Controle estatal com prioridade para estabilidade social.
Escopo	Todos os sistemas de IA comercializados/usados na UE.	Setorial, com diretrizes federais crescentes.	Algoritmos de plataformas digitais e aplicações críticas.
Enforcement	Multas de até 7% do faturamento global.	Ações da FTC, FDA e outras agências.	Registro obrigatório e possível suspensão de operações.
Transparência	Obrigatória para sistemas de alto risco.	Voluntária com expectativas crescentes.	Limitada, focada em controle governamental.
Inovação	*Sandboxes* regulatórias e exceções para pesquisa.	Priorização da competitividade global.	Investimento estatal massivo com direcionamento estratégico.
Implementação	2024-2027 com períodos de transição.	Evolutiva por meio de agências existentes.	Implementada desde 2022 com expansão contínua.

Quadro 4 - Quadro Comparativo dos Marcos Regulatórios
Fonte: Almeida & Costa (2024) para UE; Brennan *et al*. (2024) para EUA; OECD (2019) para China, adaptado pelo autor (2025)

7.2 Análise detalhada das divergências

As divergências mais significativas entre os três modelos manifestam-se no tratamento do equilíbrio entre inovação e precaução. O AI Act europeu adota o princípio da precaução, estabelecendo requisitos rigorosos antes da comercialização de sistemas de alto risco. Essa abordagem reflete valores europeus sobre a proteção de direitos fundamentais e a preferência por regulamentação preventiva.

Em contraste, o modelo norte-americano prioriza a manutenção da liderança tecnológica, permitindo maior experimentação e inovação com supervisão ex-post. Essa diferença filosófica se manifesta em requisitos menos prescritivos para desenvolvimento de IA, mas com *enforcement* mais rigoroso em casos de danos comprovados.

O modelo chinês combina investimento estatal massivo com controle rigoroso de aplicações que podem afetar a estabilidade social. Essa abordagem permite rápido desenvolvimento tecnológico em áreas priorizadas pelo governo, mas limita significativamente a autonomia empresarial na definição de estratégias de IA.

	Alta Inovação (EUA)	**Baixa Inovação (China)**
Alta Rigidez	✗	UE
Baixa Rigidez	Brasil	✗

Quadro 5 - Rigidez *vs* Inovação em frameworks
Fonte: Almeida & Costa (2024); Brennan *et al*. (2024); OECD (2019), adaptado pelo autor (2025)

7.3 Implicações para empresas globais

Organizações que operam globalmente enfrentam o desafio de simultânea conformidade com requisitos conflitantes. O fenômeno conhecido como *"Brussels Effect"* sugere que os requisitos europeus mais rigorosos tendem a se tornar padrões *de facto* para empresas globais, devido aos custos de manter sistemas separados para diferentes jurisdições.

No entanto, essa tendência pode ser limitada em casos em que os requisitos regulatórios são fundamentalmente incompatíveis. Por exemplo, requisitos europeus de transparência podem conflitar com expectativas chinesas de controle governamental sobre algoritmos, forçando empresas a escolher entre mercados ou desenvolver arquiteturas tecnológicas completamente separadas.

7.4 Impactos no desenvolvimento tecnológico

As diferentes abordagens regulatórias estão criando ecossistemas de inovação distintos que podem divergir significativamente ao longo do tempo. O modelo europeu pode favorecer o desenvolvimento de tecnologias mais transparentes e auditáveis, mas potencialmente com menor performance em termos de *accuracy* ou eficiência.

O modelo norte-americano pode sustentar o desenvolvimento de tecnologias de *frontier* mais avançadas, mas com maior risco de impactos sociais negativos não antecipados. Por fim, o modelo chinês pode gerar avanços rápidos em aplicações específicas priorizadas pelo Estado, mas com menor diversidade e autonomia na direção de pesquisa.

7.5 Lições para o Marco Brasileiro

A análise comparativa oferece insights valiosos para o desenvolvimento do marco regulatório brasileiro. A adaptação contextual emerge como elemento crucial, considerando que simplesmente copiar modelos desenvolvidos em outros contextos pode ser inadequado para as especificidades da realidade brasileira.

O Brasil pode beneficiar-se de uma abordagem híbrida que combine elementos dos três modelos: a precaução europeia em aplicações críticas, flexibilidade norte-americana para inovação e o investimento estratégico do modelo chinês — todos adaptados aos valores democráticos e características institucionais brasileiras.

8 DESAFIO PRÁTICO: IDENTIFICAÇÃO DE VIÉS ALGORÍTMICO

Como aplicação prática dos conceitos discutidos neste capítulo, apresentamos um exercício estruturado para identificação e mitigação de viés algorítmico com Python. Este desafio combina análise técnica com reflexão ética, demonstrando como princípios de *fairness* podem ser operacionalizados em contextos práticos.

8.1 Contexto do Dataset

Para esse desafio, utilizaremos um dataset fictício, porém realista, de aprovação de empréstimos bancários, inspirado em dados reais que frequentemente apresentam vieses históricos. O dataset contém informações sobre 10.000 solicitações de empréstimo com as seguintes variáveis:

- **Variáveis preditoras:** idade, renda anual, histórico de crédito, valor solicitado, tempo de emprego.
- **Variáveis sensíveis:** gênero, raça/etnia, estado civil.
- **Variável target:** aprovação do empréstimo (aprovado/negado).

8.2 Código para análise de viés

Antes de começar, certifique-se que as seguintes bibliotecas estão instaladas:

```
pip show pandas
pip show numpy
pip show scikit-learn
pip show matplotlib
pip show seaborn
```

Código-fonte 1 - Validação das bibliotecas instaladas no Python
Fonte: Elaborado pelo autor (2025)

Caso ainda não tenham sido instaladas, basta executar o comando substituindo <nome_biblioteca> pelo nome da biblioteca:

```
pip install <nome_biblioteca>
```

Código-fonte 2 - Instalação de bibliotecas no Python
Fonte: Elaborado pelo autor (2025)

Após isso, execute o script:

```
    import pandas as pd
    import numpy as np
    from sklearn.ensemble import RandomForestClassifier
    from sklearn.model_selection import train_test_split
    from     sklearn.metrics     import     accuracy_score,
confusion_matrix
    import matplotlib.pyplot as plt
    import seaborn as sns

    # Carregamento e preparação dos dados
    def load_and_prepare_data():
        # Simulação de dataset para fins educacionais
        np.random.seed(42)
        n_samples = 10000

        data = {
            'idade': np.random.normal(40, 12, n_samples),
            'renda_anual':   np.random.lognormal(10.5,   0.5,
n_samples),
            'historico_credito': np.random.choice([1, 2, 3,
4, 5], n_samples,
                                                  p=[0.1,
0.2, 0.4, 0.2, 0.1]),
            'valor_solicitado':  np.random.lognormal(9,  0.8,
n_samples),
            'tempo_emprego':         np.random.exponential(5,
n_samples),
            'genero':      np.random.choice(['M',      'F'],
n_samples),
            'raca':   np.random.choice(['Branca',   'Negra',
'Parda', 'Outras'],
                                       n_samples,  p=[0.4,  0.2,
0.3, 0.1])
        }

        df = pd.DataFrame(data)

        # Introdução de viés sistemático (simulando vieses
históricos)
        bias_factor  =  np.where((df['genero']  ==  'F')  |
(df['raca'] == 'Negra'), 0.7, 1.0)
        approval_probability = (df['historico_credito'] / 5 *
0.4 +
                                np.log(df['renda_anual']) / 15
* 0.4 +
                                (6 - df['idade'] / 10) / 6 *
0.2) * bias_factor
```

```
        df['aprovado'] = np.random.binomial(1,
approval_probability, n_samples)

        return df

    # Análise exploratória de viés
    def analyze_bias(df, sensitive_attributes=['genero',
'raca']):
        bias_metrics = {}

        for attr in sensitive_attributes:
            print(f"\n=== Análise de Viés para {attr.upper()}
===")

            # Taxa de aprovação por grupo
            approval_rates =
df.groupby(attr)['aprovado'].mean()
            print(f"Taxas de aprovação por {attr}:")
            for group, rate in approval_rates.items():
                print(f"  {group}: {rate:.3f}")

            # Diferença máxima entre grupos (Demographic
Parity)
            max_diff = approval_rates.max() -
approval_rates.min()
            print(f"Diferença máxima entre grupos:
{max_diff:.3f}")

            bias_metrics[attr] = {
                'approval_rates': approval_rates,
                'demographic_parity_diff': max_diff
            }

        return bias_metrics

    # Treinamento de modelo e avaliação de fairness
    def train_and_evaluate_model(df):
        # Preparação dos dados
        features = ['idade', 'renda_anual',
'historico_credito',
                    'valor_solicitado', 'tempo_emprego']
        X = df[features]
        y = df['aprovado']

        X_train, X_test, y_train, y_test = train_test_split(
            X, y, test_size=0.3, random_state=42
        )

        # Treinamento do modelo
        model = RandomForestClassifier(n_estimators=100,
random_state=42)
```

```
        model.fit(X_train, y_train)

        # Predições
        y_pred = model.predict(X_test)
        accuracy = accuracy_score(y_test, y_pred)

        print(f"\nAcurácia do modelo: {accuracy:.3f}")

        # Análise de fairness do modelo
        test_data = df.iloc[X_test.index].copy()
        test_data['prediction'] = y_pred

        return model, test_data

    # Avaliação de fairness pós-modelo
    def                    evaluate_model_fairness(test_data,
sensitive_attributes=['genero', 'raca']):
        print("\n=== AVALIAÇÃO DE FAIRNESS DO MODELO ===")

        for attr in sensitive_attributes:
            print(f"\n--- {attr.upper()} ---")

            # Taxa de aprovação predita por grupo
            pred_rates                                          =
test_data.groupby(attr)['prediction'].mean()
            print(f"Taxas de aprovação preditas:")
            for group, rate in pred_rates.items():
                print(f"  {group}: {rate:.3f}")

            # Equality of Opportunity: TPR por grupo
            for group in test_data[attr].unique():
                group_data  =  test_data[test_data[attr]  ==
group]
                if  len(group_data[group_data['aprovado']  ==
1]) > 0:
                    tpr                                         =
len(group_data[(group_data['aprovado'] == 1) &

(group_data['prediction'] == 1)]) / \

len(group_data[group_data['aprovado'] == 1])
                    print(f"  TPR {group}: {tpr:.3f}")

    # Propostas de mitigação
    def propose_mitigation_strategies():
        print("\n=== ESTRATÉGIAS DE MITIGAÇÃO PROPOSTAS ===")
        print("""
        1. PRÉ-PROCESSAMENTO:
           - Rebalanceamento do dataset de treinamento
           -  Remoção  de  proxies  indiretas  para  atributos
sensíveis
```

```
            - Geração de dados sintéticos para grupos sub-
representados

        2. IN-PROCESSING:
           - Incorporação de constraints de fairness na função
objetivo
           - Uso de adversarial debiasing
           - Implementação de regularização de fairness

        3. PÓS-PROCESSAMENTO:
           - Ajuste de thresholds específicos por grupo
           - Calibração para igualdade de oportunidade
           - Implementação de quotas mínimas por grupo

        4. MONITORAMENTO CONTÍNUO:
           - Tracking de métricas de fairness em produção
           - Alertas automáticos para drift de fairness
           - Auditoria regular por especialistas em ética
        """)

    # Função principal de execução
    def main():
        print("ANÁLISE DE VIÉS ALGORÍTMICO EM APROVAÇÃO DE
EMPRÉSTIMOS")
        print("=" * 60)

        # Carregamento dos dados
        df = load_and_prepare_data()
        print(f"Dataset carregado: {len(df)} registros")

        # Análise exploratória de viés
        bias_metrics = analyze_bias(df)

        # Treinamento e avaliação do modelo
        model, test_data = train_and_evaluate_model(df)

        # Avaliação de fairness do modelo
        evaluate_model_fairness(test_data)

        # Propostas de mitigação
        propose_mitigation_strategies()

        return model, df, bias_metrics

    if __name__ == "__main__":
        model, df, bias_metrics = main()
```

Código-fonte 3 - Script para simulação de viés
Fonte: Elaborado pelo autor (2025)

Importante: o script utiliza random.seed para gerar os dados, então os resultados podem diferenciar entre as execuções.

8.3 Interpretação dos resultados

A execução desse código permite observar de forma sistemática como vieses presentes nos dados históricos são reproduzidos e, em alguns casos, potencialmente amplificados pelo modelo de Machine Learning. É importante identificar:

- **Viés nos dados originais:** as taxas de aprovação diferem significativamente entre grupos demográficos.
- **Perpetuação pelo modelo:** o algoritmo aprende e reproduz esses padrões discriminatórios.
- **Métricas conflitantes:** diferentes definições de fairness podem levar a conclusões contraditórias.

8.4 Reflexão ética e proposta de mitigação: Identificando vieses no código

Após executar o código de análise de viés algorítmico apresentado anteriormente, é fundamental que você, como futuro profissional de IA, desenvolva a capacidade de **identificar, interpretar e refletir criticamente sobre os vieses presentes nos dados e nos resultados do modelo**. A seguir, orientamos um roteiro de análise para apoiar sua reflexão ética:

Observe as taxas de aprovação por grupo:

- Analise as saídas do código referentes às taxas de aprovação por gênero, raça ou outro atributo sensível.
- **Pergunte-se:** existe diferença significativa entre os grupos? Por exemplo, mulheres possuem uma taxa de aprovação menor que homens? Pessoas negras têm resultados sistematicamente inferiores aos de pessoas brancas?

Exemplo de saída:

```
Taxas de aprovação por gênero:
  M: 0.78
  F: 0.43
Diferença máxima entre grupos: 0.35
```

Código-fonte 4 - Exemplo de output
Fonte: Elaborado pelo autor (2025)

Reflexão: uma diferença de 35 pontos percentuais é um indício claro de viés algorítmico. Isso pode indicar que o modelo está reproduzindo desigualdades históricas presentes nos dados.

Compare as métricas de *fairness*:

- O código calcula diferentes métricas, como "*demographic parity*" (paridade demográfica) e "*equality of opportunity*" (igualdade de oportunidade).
- **Pergunte-se:** qual métrica melhor representa justiça no contexto do problema? Elas apontam para o mesmo tipo de viés?

Reflexão: nem sempre é possível atingir todas as métricas de *fairness* ao mesmo tempo. Avalie qual delas é mais relevante para o contexto social e regulatório do seu projeto.

Analise o impacto do viés no resultado do modelo:

- Observe se o modelo amplifica ou reduz os vieses já existentes nos dados.
- **Pergunte-se:** o modelo está apenas reproduzindo o viés dos dados ou está agravando a desigualdade?

Dica: compare as taxas de aprovação dos dados originais com as taxas das previsões do modelo.

Investigue possíveis causas do viés:

- **Volte ao início do pipeline:** os dados de entrada são representativos? Existem variáveis que funcionam como proxies para atributos sensíveis (por exemplo, bairro pode ser proxy para classe social ou raça)?
- **Pergunte-se:** o viés está nos dados, na escolha das variáveis, ou em alguma etapa do processamento?

Reflexão: muitas vezes o viés não está no algoritmo, mas na forma como os dados foram coletados ou rotulados.

Proponha estratégias de mitigação:

- Com base nas análises anteriores, pense em formas de reduzir o viés identificado.

- **Sugestões:**
  - Balancear o dataset (por exemplo, aumentar a representação de grupos minoritários).
  - Remover variáveis sensíveis ou proxies.
  - Aplicar técnicas de *fairness* durante o treinamento (*in-processing*).
  - Ajustar os *thresholds* de decisão para grupos sub-representados (*post-processing*).
- **Pergunte-se:** qual estratégia é mais viável para o seu contexto? Existe *trade-offs* entre performance e justiça?

Documente sua análise crítica:

- Registre suas observações, hipóteses e propostas de mitigação.
- Justifique suas escolhas com base em princípios éticos, regulatórios e de governança.

Dica: utilize exemplos reais, como o caso da Amazon ou do sistema de saúde de Stanford, para embasar sua reflexão.

EAD

CONCLUSÃO

Este capítulo ofereceu uma análise abrangente dos desafios éticos, ambientais e regulatórios que caracterizam o desenvolvimento e aplicação contemporânea de tecnologias de Inteligência Artificial. Através da exploração sistemática de temas como *fairness* algorítmica, sustentabilidade, marcos regulatórios globais e o posicionamento estratégico do Brasil, evidenciou-se que a governança de IA transcende questões meramente técnicas para abordar dilemas fundamentais sobre valores sociais, distribuição de poder e responsabilidade coletiva.

A discussão sobre ética em IA revelou que não existe neutralidade tecnológica: os sistemas de IA incorporam inevitavelmente valores, pressupostos e vieses que refletem as sociedades que os criam. Essa constatação torna imperativa a adoção de abordagens de “ética por design” que integrem considerações morais desde as fases iniciais de desenvolvimento, em vez de tratá-las como correções posteriores. Os casos estudados da Amazon e do sistema de saúde de Stanford demonstram concretamente como a ausência de governança ética pode resultar em danos sistêmicos e perpetuação de desigualdades históricas.

A análise de *algorithmic fairness* evidenciou a complexidade inerente à operacionalização de conceitos de justiça em contextos algorítmicos. A descoberta de que diferentes métricas de *fairness* são matematicamente incompatíveis não representa uma limitação técnica temporária, mas reflete tensões filosóficas profundas sobre a natureza da equidade social. Essa realidade força as organizações e os reguladores a fazer escolhas explícitas sobre quais aspectos de justiça priorizar, transformando decisões técnicas em questões fundamentalmente políticas e sociais.

Os impactos sociais da IA, particularmente no que concerne à exclusão digital e desinformação, demonstraram como essas tecnologias podem tanto democratizar quanto concentrar oportunidades e poder. A capacidade dos sistemas de IA de amplificar desigualdades existentes ou criar novas formas de marginalização exige vigilância constante e estratégias proativas de inclusão. Simultaneamente, o papel da IA na proliferação de desinformação destaca tensões complexas entre liberdade de expressão, proteção democrática e responsabilidade de plataformas tecnológicas.

A dimensão ambiental da IA emerge como um desafio crítico frequentemente negligenciado em discussões sobre governança. O consumo energético massivo associado ao treinamento e operação de modelos de grande escala cria tensões fundamentais entre ambições tecnológicas e objetivos de sustentabilidade. A necessidade de equilibrar performance algorítmica com responsabilidade ambiental representa uma nova fronteira para práticas de desenvolvimento responsável.

A análise comparativa dos marcos regulatórios globais revelou a ausência de consenso internacional sobre abordagens apropriadas para governança de IA. As divergências entre os modelos europeu, norte-americano e chinês refletem diferenças fundamentais em valores políticos, tradições jurídicas e prioridades sociais que provavelmente persistirão. Essa fragmentação regulatória cria desafios significativos para organizações globais e pode fragmentar o desenvolvimento tecnológico mundial.

Para o Brasil, a transição de consumidor para produtor de tecnologia representa tanto uma oportunidade estratégica quanto um desafio complexo que requer coordenação entre políticas educacionais, industriais, regulatórias e de desenvolvimento. O marco legal de IA brasileiro, embora promissor, enfrenta desafios substanciais de implementação relacionados à capacidade institucional e à coordenação entre as diferentes esferas de governo.

O exercício prático para identificação de viés algorítmico demonstrou como princípios éticos abstratos se materializam em decisões técnicas concretas, evidenciando a importância de formar profissionais capazes de navegar nessas complexidades. A integração entre análise quantitativa e reflexão ética representa uma competência essencial para os futuros profissionais de IA.

Olhando adiante, torna-se evidente que a governança eficaz de IA requer abordagens adaptativas que possam evoluir com o ritmo acelerado de desenvolvimento tecnológico. Não existem soluções definitivas para os dilemas apresentados neste capítulo, mas sim a necessidade de construir capacidades institucionais e profissionais para navegação contínua de tensões entre inovação e responsabilidade, eficiência e equidade, competitividade e sustentabilidade.

A construção de um futuro em que as tecnologias de IA contribuam genuinamente para o bem-estar coletivo requer engajamento ativo de múltiplos *stakeholders* — desenvolvedores, reguladores, acadêmicos, organizações da

sociedade civil e cidadãos informados. Este capítulo oferece ferramentas conceituais e práticas para participação consciente neste processo, mas a responsabilidade de aplicá-las de forma ética e eficaz permanece com cada leitor.

FIAP

REFERÊNCIAS

ALMEIDA, Fernando; COSTA, Marina. AI ACT: marco regulatório europeu para inteligência artificial. **Revista de Direito e Tecnologia**, v. 12, n. 3, p. 67-89, 2024. Disponível em: <https://periodicos.uesc.br/index.php/dike/article/view/4544>. Acesso em: 2 jun. 2025.

BARBOSA, Carlos; LIMA, Patricia. Liberdade de expressão digital: desinformação e os desafios regulatórios diante das big techs e da IA aplicados ao processo eleitoral. **Revista de Direito Digital**, v. 19, n. 1, p. 123-145, 2025. Disponível em: <https://revistaft.com.br/liberdade-de-expressao-digital-desinformacao-e-os-desafios-regulatorios>. Acesso em: 2 jun. 2025.

BARTLETT, Robert *et al*. Algorithmic Fairness. **Annual Review of Financial Economics**, v. 15, p. 389-415, 2023. DOI: 10.1257/pandp.20181018.

BRENNAN, Tom; HEIDARI, Hoda; WAGNER, Claudia. Implications of the AI Act for Non-Discrimination Law and Algorithmic Fairness. **European Journal of Legal Studies**, v. 16, n. 2, p. 234-267, 2024.

COECKELBERGH, Mark. **Ética na IA**. São Paulo: Editora da USP, 2024. Resenha disponível em: <https://revistaalceu.com.puc-rio.br/alceu/article/view/430>. Acesso em: 2 jun. 2025.

DAMA INTERNATIONAL. **The DAMA Guide to the Data Management Body of Knowledge (DAMA-DMBOK2)**. 2. ed. Bradley Beach, NJ: Technics Publications, 2017.

FERREIRA, Luisa; SANTOS, Roberto; OLIVEIRA, Patricia. Vulnerabilidade social e a exclusão digital no contexto do ensino remoto em escolas públicas de Ituiutaba/MG. **Cadernos de Pesquisa**, v. 31, n. 3, p. 145-167, 2024. Disponível em: <https://periodicoseletronicos.ufma.br/index.php/cadernosdepesquisa/article/view/23780>. Acesso em: 2 jun. 2025.

HOFFMAN, Kelly; ROBERTS, David; WILLIAMS, Jessica. **An Empirical Analysis of Racial Categories in the Algorithmic Fairness Literature**. *In*: ACM CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY, 2023. Proceedings... New York: ACM, 2023. p. 112-125.

JOHNSON, Robert; ZHANG, Wei; PATEL, Priya. Eavesdropping on UNESCO AI Policy, Leadership, and Ethics. **Journal of Leadership Studies**, v. 18, n. 2, p. 45-67, 2025. DOI: 10.1002/jls.70007. Acesso em: 2 jun. 2025.

KANEDA, Sotaro; BROWN, Michael; JONES, Emily. **LLMCarbon: Modeling the end-to-end Carbon Footprint of Large Language Models**. *In*: INTERNATIONAL

CONFERENCE ON MACHINE LEARNING, 2023. Proceedings... New York: PMLR, 2023. p. 567-582.

KUMAR, Rajesh; THOMPSON, Sarah. Making AI Ethical by Design: The UNESCO Perspective. **IEEE Technology and Society Magazine**, v. 43, n. 1, p. 78-85, 2024. DOI: 10.1109/MTS.2024.3356789.

MORAES, Daniel; ROCHA, Fernanda. Enfrentamento à desinformação por meio dos algoritmos: um panorama internacional na literatura científica das possíveis respostas ao problema. **Liinc em Revista**, v. 18, n. 2, p. 234-256, 2022. DOI: 10.18617/liinc.v18i2.6057.

MÜLLER, Hans; SCHMIDT, Anna; WEBER, Klaus. Algorithmic Fairness in AI. **Business & Information Systems Engineering**, v. 65, n. 2, p. 145-162, 2023. DOI: 10.1007/s12599-023-00787-x.

NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY**. AI Risk Management Framework (AI RMF 1.0).** 2023. Disponível em: <https://www.nist.gov/itl/ai-risk-management-framework>. Acesso em: 5 maio 2025.

OECD. OECD **Principles on Artificial Intelligence**. Paris: OECD Publishing, 2019. Disponível em: <https://oecd.ai/en/dashboards/ai-principles>. Acesso em: 5 maio 2025.

RODRÍGUEZ, María Carmen. ¿Quién paga los daños que causa la IA? De la ética a la responsabilidade por productos defectuosos. **Bioética: Revista Iberoamericana**, v. 15, n. 3, p. 78-94, 2024. Disponível em: <https://revistas.comillas.edu/index.php/bioetica-revista-iberoamericana/article/view/21421>. Acesso em: 2 jun. 2025.

SANTOS, Ana Paula; OLIVEIRA, Carlos Roberto. Ética e responsabilidade no empreendedorismo baseado em IA. **Revista de Empreendedorismo e Sustentabilidade**, v. 8, n. 4, p. 234-256, 2024. Disponível em: <https://periodicorease.pro.br/rease/article/view/16831>. Acesso em: 2 jun. 2025.

SILVA, João *et al*. Design e ética em IA: reflexões a partir do impacto social do Lensa enquanto produto digital baseado em Inteligência Artificial. **Revista de Design e Tecnologia**, v. 14, n. 2, p. 123-145, 2024. Disponível em: <https://www.ufrgs.br/det/index.php/det/article/view/1131>. Acesso em: 2 jun. 2025.

SILVA, José Carlos; RODRIGUES, Maria Fernanda. Os regimes de responsabilização civil no novo Marco Legal para Inteligência Artificial: o Projeto de Lei nº 2.338/23. **Revista de Direito e Tecnologia**, v. 15, n. 2, p. 45-67, 2024. Disponível em: <https://journal.nuped.com.br/index.php/revista/article/view/1261>. Acesso em: 2 jun. 2025.

SILVA, Marcos; PEREIRA, Ana Clara. Definições de exclusão digital na educação e estratégias de enfrentamento. **Revista de Educação e Tecnologia**, v. 28, n. 2, p. 78-95, 2024. Disponível em: <https://seer.upf.br/index.php/rep/article/view/15684>. Acesso em: 2 jun. 2025.

STRUBELL, Emma; GANESH, Ananya; MCCALLUM, Andrew. How to estimate carbon footprint when training deep learning models? A guide and review. **Environmental Research Communications**, v. 5, n. 9, article 095014, 2023. DOI: 10.1088/2515-7620/acf81b.

UNESCO. **Foundation models such as ChatGPT through the prism of the UNESCO Recommendation on the Ethics of Artificial Intelligence**. Paris: UNESCO Publishing, 2023. (UNESCO Report 385629).

YANG, Chris; CHEN, Linda; RODRIGUEZ, Miguel. Algorithmic fairness and bias mitigation for clinical machine learning with deep reinforcement learning. **Nature Machine Intelligence**, v. 5, p. 567-580, 2023. DOI: 10.1038/s42256-023-00697-3.

FIAP

GLOSSÁRIO

Accountability	Capacidade de atribuir responsabilidade formal e documentada pelas decisões e operações realizadas em projetos de IA e Big Data, incluindo prestação de contas e rastreabilidade.
AI Act	Regulamento europeu que classifica sistemas de IA por níveis de risco e estabelece requisitos de transparência, segurança e ética para cada categoria.
Alucinação Algorítmica	Fenômeno em que sistemas de IA Generativa produzem informações falsas ou incorretas de maneira convincente, sem correspondência com a realidade.
Bias Dinâmico (Viés Dinâmico)	Evolução e reforço de vieses em sistemas de IA ao longo do tempo, à medida que o modelo aprende continuamente a partir de novos dados, podendo amplificar discriminações.
Calibração	Métrica de *fairness* que avalia se a probabilidade prevista por um modelo reflete igualmente a chance real de um evento para diferentes grupos demográficos.
Concept Drift	Mudança na relação estatística entre variáveis de entrada e saída ao longo do tempo, exigindo retreinamento ou ajuste do modelo para manter a acurácia.
Demographic Parity	Métrica de justiça algorítmica que exige igualdade na proporção de resultados positivos entre diferentes grupos demográficos, independentemente de outras características.

Drift Ético	Desalinhamento progressivo entre práticas tecnológicas e valores éticos sociais vigentes, exigindo revisão constante da governança e das políticas de IA.
Equality of Opportunity	Métrica de *fairness* que busca garantir que indivíduos qualificados de diferentes grupos tenham a mesma chance de obter um resultado positivo em sistemas automatizados.
Explainability **(Explicabilidade)**	Capacidade de um sistema de IA fornecer explicações compreensíveis sobre seus processos de decisão para *stakeholders* humanos, facilitando auditorias e conformidade regulatória.
Fairness **Algorítmica**	Princípio e conjunto de práticas que buscam garantir que sistemas de IA não discriminem injustamente indivíduos ou grupos, promovendo justiça e equidade nos resultados.
Green AI **(IA Verde)**	Abordagem que prioriza a eficiência energética e a sustentabilidade ambiental no desenvolvimento e uso de sistemas de IA.
Inferência	Processo de utilização de um modelo de IA já treinado para gerar previsões ou classificações a partir de novos dados.
LLMCarbon	Ferramenta para cálculo da pegada de carbono de modelos de linguagem de grande escala, considerando treinamento, inferência e hardware.
Marco Legal da IA	Projeto de lei brasileiro que propõe diretrizes e regras para o desenvolvimento, uso e responsabilização de sistemas de IA no Brasil, inspirado em modelos internacionais.

Mitigação de Viés	Conjunto de técnicas e estratégias para identificar, reduzir ou eliminar vieses indesejados em dados, algoritmos e decisões automatizadas.
Model Drift	Desvio ou degradação da performance de um modelo de IA ao longo do tempo devido a mudanças nos dados ou no contexto de aplicação.
Pegada de Carbono	Medida do impacto ambiental de sistemas de IA, especialmente modelos de grande porte, em termos de emissões de CO_2 durante treinamento e operação.
Pós-processamento	Técnicas aplicadas após o treinamento do modelo para ajustar suas saídas e melhorar métricas de *fairness* ou mitigar vieses identificados.
Pré-processamento	Etapa de preparação dos dados antes do treinamento do modelo, incluindo limpeza, balanceamento e remoção de proxies discriminatórios para reduzir vieses.
Responsabilidade Civil em IA	Obrigação legal de reparar danos causados por sistemas de IA, incluindo definição de quem responde por falhas ou discriminações algorítmicas.
Risco Algorítmico	Potencial de um sistema de IA causar impactos negativos, como discriminação, exclusão, desinformação ou danos ambientais, exigindo governança e controles específicos.
Sustentabilidade Algorítmica	Práticas que visam reduzir o consumo de recursos naturais e o impacto ambiental de sistemas de IA, promovendo eficiência e responsabilidade ecológica.

Transparência Algorítmica	Princípio que exige clareza sobre o funcionamento, as decisões e os critérios utilizados por sistemas de IA, facilitando auditorias e prestação de contas.
Viés Algorítmico	Tendência sistemática de um sistema de IA produzir resultados injustos ou discriminatórios devido a dados, escolhas de variáveis ou processos automatizados.
Viés de Representação	Distorção causada pela sub ou super-representação de determinados grupos nos dados de treinamento, levando a erros ou injustiças sistemáticas nas previsões do modelo.
Viés Histórico	Discriminação incorporada a sistemas de IA devido a padrões injustos presentes nos dados históricos utilizados para treinamento.

FIAP