

03

CÉREBROS DE SILÍCIO NA ERA DOS CHIPS NEUROMÓRFICOS

PDF exclusivo para Murilo Salla - rm568041
murilosalla@protonmail.com

LISTA DE FIGURAS

Figura 1 - Comparação de rede neural bipartida (esquerda) e lógica de um núcleo TrueNorth (direita) 6
Figura 2 - Cantos de dois chips TrueNorth, com trajetórias de spikes dentro do chip e entre chips 7
Figura 3 - Handshake assíncrono de quatro fases 8
Figura 4 - Chip TrueNorth (esquerda) com malha 2D de 64×64 núcleos neurossinápticos; na borda (centro), interface com bloco mesclador-divisor e pads de I/O; à direita, sobreposição do layout físico e diagrama funcional de um núcleo 9
Figura 5 - Diagrama de blocos da arquitetura interna do chip Loihi 2 14
Figura 6 - Comparativo entre o Loihi e o Loihi 2 em termos de desempenho e recursos 16
Figura 7 - Hala Point 19
Figura 8 - Espectro Eletromagnético 23
Figura 9 - Tendências de publicações e citações em fotônica 29
Figura 10 - Estrutura de uma fibra ótica 33
Figura 11 - Fenômeno de reflexão total 36
Figura 12 - Comparação entre (a) sensores extrínsecos e (b) sensores intrínsecos 39
Figura 13 - Estrutura da topologia das redes SNN e ANN 43
Figura 14 - Consumo de corrente dos microcontroladores ATMEGA328 e Tensilica Xtensa LX106 45

LISTA DE QUADROS

Quadro 1 - Comparação entre chips neuromórficos TrueNorth e Loihi 21

FIAP

SUMÁRIO

1 CÉREBROS DE SILÍCIO NA ERA DOS CHIPS NEUROMÓRFICOS 5
1.1 Introdução 5
1.2 IBM TrueNorth.....5
1.3 Intel Loihi.....12

2 INTRODUÇÃO À FOTÔNICA: O QUE É E COMO FUNCIONA 22
2.1 Fundamentos da fotônica.....22
2.2 Aplicações da fotônica.....26
2.3 Avanços na fotônica 28
2.4 Estruturas, tipos e aplicações de fibras óticas.....31
2.5 Classificação de sensores de fibra ótica 37

3 EFICIÊNCIA ENERGÉTICA EM IOT – COMPARAÇÃO ENTRE ALGORITMOS SNN E ANN EM ARQUITETURAS VON NEUMANN.....40
3.1 O contexto energético da IoT e o desafio computacional.....41
3.2 Metodologia experimental e comparação arquitetural.....42
3.3 Resultados obtidos e análise crítica.....44

REFERÊNCIAS.....49

FIXAR

1 CÉREBROS DE SILÍCIO NA ERA DOS CHIPS NEUROMÓRFICOS

1.1 Introdução

O avanço das arquiteturas neuromórficas viabilizou o desenvolvimento de chips especializados que integram processamento e memória em estruturas paralelas, inspiradas no cérebro humano. Este capítulo apresenta as principais tecnologias de chips neuromórficos disponíveis atualmente, com foco nos modelos IBM TrueNorth e Intel Loihi, ambos projetados para simular redes neurais spiking (SNN) com alta eficiência energética.

O IBM TrueNorth se destaca por sua arquitetura baseada em milhões de neurônios e sinapses digitais, organizados em núcleos neuro sinápticos que operam de forma assíncrona e altamente paralela. Essa estrutura permite executar tarefas cognitivas complexas com consumo mínimo de energia, sendo ideal para aplicações que exigem reconhecimento de padrões e processamento de sinais em tempo real.

Já o Intel Loihi introduz avanços significativos ao incorporar mecanismos de aprendizado on-chip e plasticidade sináptica em tempo real. Sua arquitetura orientada por eventos (*event-driven*) faz com que os neurônios só entrem em atividade quando necessário, otimizando ainda mais o consumo energético. O Loihi oferece um ambiente flexível para o desenvolvimento e teste de algoritmos neuromórficos, sendo especialmente indicado para aplicações embarcadas e sistemas autônomos.

Ao longo do capítulo, discutiremos essas tecnologias em maior profundidade, destacando suas características estruturais, capacidades computacionais e potencial de aplicação em sistemas que demandam processamento eficiente e de baixo consumo energético.

1.2 IBM TrueNorth

A arquitetura TrueNorth, desenvolvida pela IBM em parceria com a DARPA no contexto do projeto SyNAPSE, representa uma ruptura com os modelos tradicionais baseados na arquitetura de von Neumann. Em vez de separar memória e processamento, o TrueNorth adota uma estrutura inspirada na organização do

cérebro, com núcleos que integram ambos em uma mesma unidade funcional. A proposta é aproximar o comportamento computacional ao de redes neurais biológicas, buscando uma maior eficiência energética e paralelismo.

A base do TrueNorth são os chamados núcleos neurossinápticos, elementos que unem memória (sinapses), computação (neurônios) e comunicação (axônios/dendritos). A arquitetura completa é composta por 4.096 núcleos dispostos em uma malha 2D de 64 x 64, totalizando 1 milhão de neurônios e 256 milhões de sinapses. Essa organização é inspirada diretamente na estrutura das colunas corticais do cérebro humano.

Cada núcleo neuro sináptico contém 256 axônios de entrada e 256 neurônios, conectados por uma matriz sináptica de 64 mil conexões. Essa estrutura é visualizada na figura “Comparação de rede neural bipartida (esquerda) e lógica de um núcleo TrueNorth (direita)”, que mostra o mapeamento entre uma rede neural bipartida e o núcleo físico.

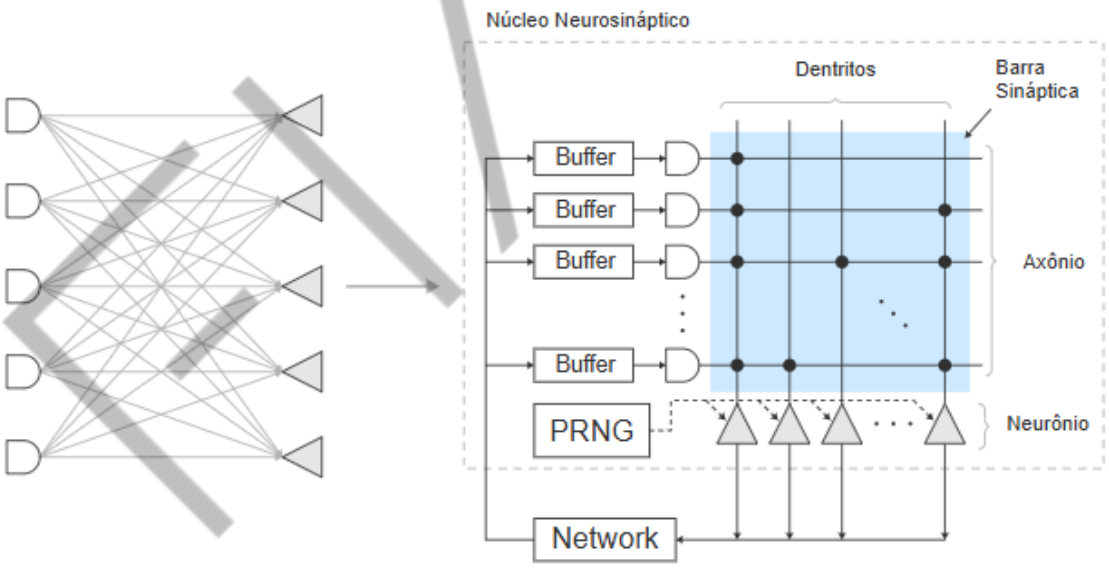


Figura 1 - Comparação de rede neural bipartida (esquerda) e lógica de um núcleo TrueNorth (direita)
Fonte: Yadav *et al.* (2023), adaptado pelo autor (2025)

A computação ocorre em ciclos de 1 milissegundo (tick), com atualização dos estados neurais sincronizada por eventos, o que permite operação em tempo real com baixo consumo energético.

Os spikes — pulsos binários que representam os disparos neuronais — são armazenados em buffers de entrada e, quando o tick é acionado, são roteados para os neurônios correspondentes por meio da matriz sináptica. A atualização do potencial

de membrana, com aplicação de vazamento (leak), comparação com limiar e eventual disparo, segue regras simples implementadas diretamente em hardware.

A equação básica utilizada para o cálculo do potencial será apresentada no terceiro tópico deste capítulo. O fato de o modelo evitar multiplicações e divisões ajuda a reduzir o consumo energético e a simplificar o design lógico, tornando o chip viável para implementação em silício com área reduzida.

A comunicação entre os núcleos utiliza um sistema em malha chamado rede-mesh, que permite a propagação dos spikes de forma assíncrona e eficiente. A figura “Cantos de dois chips TrueNorth, com trajetórias de spikes dentro do chip e entre chips” ilustra esse processo, incluindo trajetórias de pacotes tanto dentro do mesmo chip quanto entre chips diferentes. Para viabilizar a escalabilidade além de um único chip, foram desenvolvidos circuitos periféricos que realizam a multiplexação e demultiplexação dos dados — possibilitando a construção de sistemas multichip, onde diversos chips TrueNorth são interligados para tarefas mais complexas.

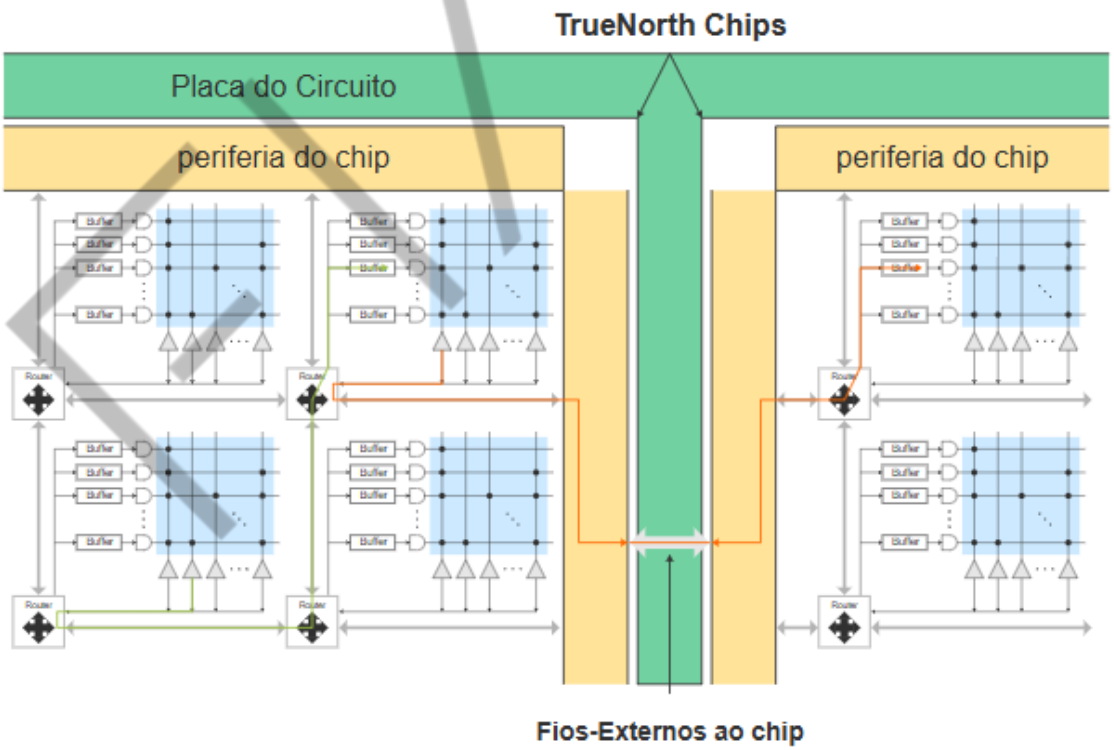


Figura 2 - Cantos de dois chips TrueNorth, com trajetórias de spikes dentro do chip e entre chips
Fonte: Akopyan *et al*. (2015), adaptado pelo autor (2025)

Internamente, a lógica de controle e comunicação é implementada com circuitos assíncronos, enquanto o processamento dos neurônios usa lógica síncrona.

Essa abordagem híbrida permite o uso eficiente de energia, pois evita clocks globais e reduz o consumo quando o chip está inativo.

Esse design assíncrono é esquematizado na figura “Handshake assíncrono de quatro fases”, que ilustra o protocolo de handshake de quatro fases utilizado para sincronizar a transferência de dados entre blocos. Nela, o bloco “Enviar” transmite sinais binários (“dados 0” ou “dados 1”) ao bloco “Receber” e aguarda o sinal de confirmação (“conf”) antes de seguir para o próximo bit. O diagrama de tempo à direita ilustra como, ao enviar “0” ou “1”, o receptor primeiro detecta a transição de dados e então retorna o “conf”, garantindo que ambos os lados estejam sincronizados antes de prosseguir.

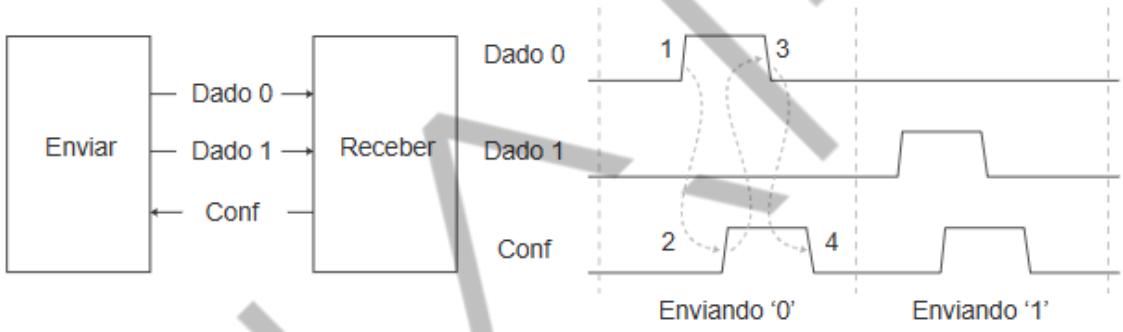


Figura 3 - Handshake assíncrono de quatro fases
Fonte: Akopyan *et al.* (2015), adaptado pelo autor (2025)

A estrutura física do chip é apresentada na figura “Chip TrueNorth (esquerda) com malha 2D de 64 x 64 núcleos neurossinápticos; na borda (centro), interface com bloco mesclador-divisor e pads de I/O; à direita, sobreposição do layout físico e diagrama funcional de um núcleo”, e revela três níveis de organização espacial distintos que ajudam a entender como o TrueNorth é capaz de integrar alta densidade computacional com eficiência energética.

Na parte (esquerda), é possível observar a malha bidimensional (2D) de 64 x 64 núcleos neurossinápticos que compõem o TrueNorth. Essa malha cobre quase toda a área central do chip e representa o núcleo de processamento do sistema, simulando 1 milhão de neurônios. Cada núcleo individual ocupa uma pequena região do silício, otimizando o espaço sem comprometer a conectividade.

A parte (centro) mostra a periferia do chip, onde ficam os blocos de interface conhecidos como "mesclador-divisor" (merge-split) e os pads de entrada/saída (I/O). Esses elementos desempenham um papel crucial no agrupamento e roteamento dos

dados, conectando os núcleos internos com o ambiente externo ou com outros chips em arquiteturas maiores.

Por fim, a parte (direita) fornece uma visão ampliada de um único núcleo neurossináptico. Nessa representação, os blocos funcionais são sobrepostos ao layout físico real, revelando a localização e o papel de cada componente: o roteador, responsável pelo tráfego de spikes; o agendador, scheduler que organiza os eventos temporais; o controlador de tokens, que ativa os neurônios em sequência; a memória SRAM, que armazena parâmetros e estados neurais; e, por fim, o bloco de neurônio, que realiza a computação propriamente dita.

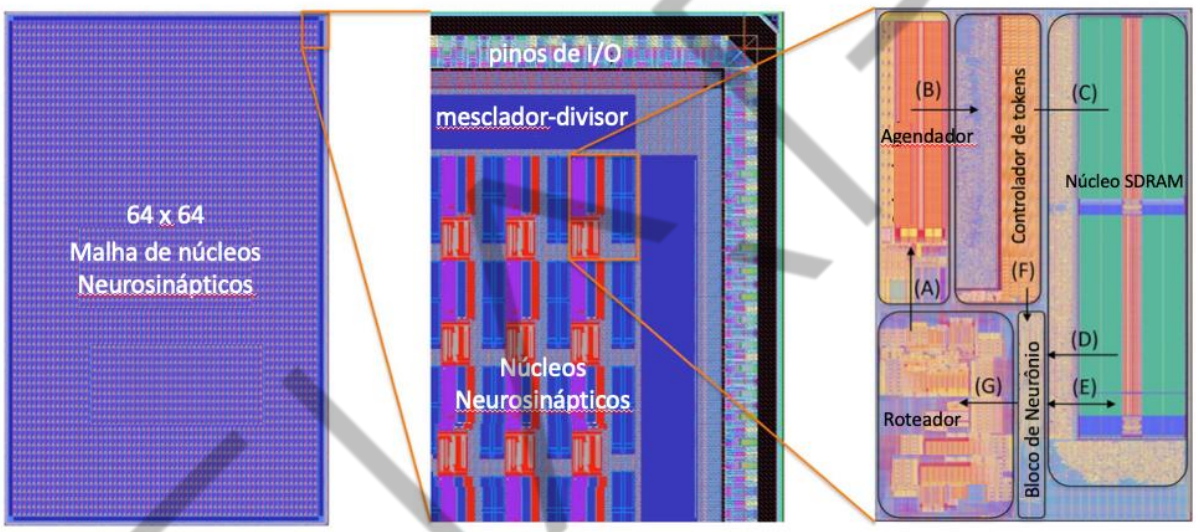


Figura 4 - Chip TrueNorth (esquerda) com malha 2D de 64×64 núcleos neurossinápticos; na borda (centro), interface com bloco mesclador-divisor e pads de I/O; à direita, sobreposição do layout físico e diagrama funcional de um núcleo
Fonte: Akopyan *et al.* (2015), adaptado pelo autor (2025)

O bloco de neurônio do TrueNorth é responsável por realizar os cálculos centrais de cada unidade neural, seguindo o modelo de integração e disparo. Ele acumula os sinais de entrada recebidos de diferentes axônios e os compara com um limiar. Se esse limiar for superado, um spike é gerado e o estado do neurônio é redefinido. Esse mecanismo permite a simulação eficiente de múltiplos padrões de disparo, inclusive aqueles observados em sistemas biológicos.

Cada núcleo conta com um circuito único que é multiplexado para simular até 256 neurônios. Isso significa que o mesmo circuito realiza a operação de todos os neurônios do núcleo, um por vez, o que reduz significativamente a área ocupada e o consumo energético. Embora essa abordagem sacrifique parte da simultaneidade na

simulação, ela se mostra adequada para aplicações em tempo real, uma vez que o ciclo de operação é sincronizado com o tick global de 1 milissegundo.

Além disso, o processamento de spikes é coordenado por outros blocos internos, como o roteador e o agendador. O roteador encaminha cada spike recebido para o destino apropriado dentro do chip ou para outro chip conectado, utilizando regras de prioridade e buffers para evitar congestionamentos. Já o agendador organiza os eventos de entrada e garante que sejam processados no momento correto, mantendo a coerência temporal entre os neurônios simulados. Esses elementos trabalham em conjunto com o controlador de tokens, que determina a ordem de execução dos neurônios e otimiza o uso dos recursos computacionais disponíveis.

A expansão do sistema TrueNorth depende de uma infraestrutura de comunicação eficiente entre os núcleos e com o mundo externo. Ao redor da malha de núcleos, os blocos de interface funcionam como mediadores que agrupam, roteiam e distribuem os sinais elétricos de entrada e saída. Esses blocos foram projetados para otimizar a interligação entre diferentes seções do chip e permitir que múltiplos chips operem em conjunto, formando sistemas neuromórficos maiores e distribuídos.

Esses blocos periféricos atuam junto aos pads de entrada e saída (I/O), conectando o chip à placa de circuito e a outros componentes externos. Eles garantem que os dados circulem com sincronização e robustez, preservando a integridade da informação mesmo em ambientes com ruído elétrico. Para isso, o protocolo de comunicação utilizado tira proveito das bordas de sinal, aproveitando ao máximo o canal de transmissão sem necessidade de frequências elevadas.

O processo de configuração e verificação de cada componente é essencial para garantir que todos os núcleos estejam corretamente programados e sincronizados. Isso é realizado por meio de cadeias de varredura (*scan chains*), que permitem carregar os parâmetros de sinapses e neurônios de maneira controlada. Essa abordagem facilita a depuração, a detecção de falhas e a programação personalizada de diferentes regiões do chip, sem interferir na operação geral do sistema.

O chip é suportado por um ecossistema de software que inclui compiladores de redes neurais, simuladores e visualizadores. Essas ferramentas convertem modelos

de rede treinados externamente para o formato compatível com o hardware TrueNorth.

Vale destacar que o TrueNorth é voltado apenas para inferência, ou seja, não possui mecanismos internos de aprendizado. O treinamento das redes deve ser feito previamente em plataformas convencionais, como GPUs.

Apesar dessa limitação, a eficiência energética do TrueNorth é impressionante. O consumo médio durante tarefas visuais é de apenas 65 mW, o que é aproximadamente 100 vezes inferior ao de CPUs tradicionais para tarefas equivalentes.

O desempenho do TrueNorth foi validado em diversas aplicações reais. Em 2017, foi utilizado em um sistema de reconhecimento de gestos com câmeras DVS, alcançando 96,5% de precisão com apenas 0.18 watts de consumo.

Outra aplicação relevante ocorreu em 2018, com um sistema de visão estéreo que utilizava oito chips TrueNorth para gerar até 2.000 mapas de profundidade por segundo — uma taxa muito superior a abordagens tradicionais.

Em 2019, a tecnologia foi adaptada para análise de vídeo aéreo em tempo real, com resultados promissores na identificação de objetos e eventos em cenas dinâmicas. Isso demonstrou a viabilidade do uso em drones e sistemas embarcados.

O chip também se mostrou adequado para aplicações biomédicas, como implantes de retina artificial ou interfaces neurais, graças ao seu baixo consumo e arquitetura compatível com sinais discretos.

Além disso, o modelo TrueNorth apresenta robustez frente a falhas temporárias de comunicação, o que o torna interessante para ambientes com ruído elétrico, como satélites ou sistemas autônomos.

Por fim, o TrueNorth reforça o potencial da computação neuromórfica como alternativa viável para sistemas de Inteligência Artificial com restrições energéticas e de latência, consolidando-se como uma das maiores inovações da última década.

Além das aplicações científicas e experimentais, o TrueNorth também começa a ser explorado em contextos comerciais. Sua arquitetura altamente paralela, eficiente e responsiva é particularmente promissora em aplicações de visão computacional, como reconhecimento de objetos, análise de comportamento e identificação de

padrões visuais em tempo real. Essas capacidades vêm sendo integradas em ambientes com tráfego intenso de pessoas, como centros comerciais, aeroportos e feiras tecnológicas, onde o chip pode atuar como uma unidade embarcada de baixo consumo para interpretar imagens captadas por câmeras.

Combinado a câmeras baseadas em eventos (DVS), o chip TrueNorth permite o desenvolvimento de soluções de monitoramento que detectam e reagem a movimentos com mínima latência e sem a necessidade de processadores convencionais de alto desempenho. Além disso, sua integração com redes neurais treinadas para reconhecer ações humanas possibilita o uso em contextos de assistência, segurança e interação homem-máquina. Essa abordagem amplia o uso da Inteligência Artificial para além da nuvem, aproximando o processamento dos sensores e promovendo sistemas adaptativos e energeticamente sustentáveis.

1.3 Intel Loihi

Em 2018, a Intel apresentou ao mundo o chip Loihi, um processador neuromórfico desenvolvido para explorar os benefícios de uma nova abordagem computacional bioinspirada. Ao integrar computação e memória em uma única unidade de processamento, o Loihi tornou-se pioneiro na criação de sistemas capazes de aprender em tempo real e operar com impressionante eficiência energética.

O Loihi 1 oferecia suporte a regras de aprendizado local, comunicação baseada em spikes e modelos neuronais inspirados em neurônios biológicos. Durante seus primeiros anos de uso, o chip demonstrou desempenho promissor em aplicações como controle adaptativo de braços robóticos, percepção sensorial visual-tátil, reconhecimento de odores e gestos, e resolução de problemas de otimização como escalonamento de trens.

A eficiência energética sempre foi um dos destaques do Loihi. Em diversas aplicações, seu consumo energético manteve-se abaixo de 1 watt, algo notável quando comparado às dezenas ou até centenas de watts consumidos por soluções convencionais baseadas em CPUs e GPUs.

Apesar desses avanços, o Loihi 1 apresentava limitações. Seu suporte restrito a certos modelos neuronais e a dificuldade de integração com sensores e formatos de

dados tradicionais motivaram o desenvolvimento de uma nova geração. Assim surgiu o Loihi 2.

A nova geração trouxe avanços substanciais. Uma das melhorias centrais foi a introdução de spikes graduados, com payloads inteiros de até 32 bits. Isso aumentou significativamente a expressividade da comunicação neural dentro do chip, permitindo representar informações com maior precisão.

Além disso, os modelos de neurônios no Loihi 2 passaram a ser programáveis por meio de microcódigos, o que abriu caminho para uma ampla gama de comportamentos neuronais personalizados. Essa característica possibilita a implementação de algoritmos de aprendizado complexos, como variações do backpropagation supervisionado.

O Loihi 2 também aprimorou o suporte a regras de aprendizado com três fatores, em vez das tradicionais regras baseadas em pré e pós-sinapses. Atualmente, os fatores moduladores locais podem ser atribuídos a sinapses específicas, expandindo a gama de algoritmos neuroinspirados compatíveis com o chip.

A arquitetura física do Loihi 2 manteve o conceito da malha neuromórfica, com até 128 núcleos neuronais interligados por uma rede-em-chip (NoC). Cada núcleo suporta até 8192 neurônios e 128 KB de memória sináptica.

Com esses avanços, o Loihi 2 passou a atender não apenas pesquisadores em neurociência computacional, mas também desenvolvedores de aplicações industriais que demandam inferência e aprendizado local em dispositivos embarcados. Essa flexibilidade tornou o chip uma ferramenta valiosa em contextos como veículos autônomos, robótica colaborativa e sistemas sensoriais integrados.

Outro destaque importante está na escalabilidade do sistema. A Intel viabilizou o uso de múltiplos chips Loihi 2 operando em conjunto, mantendo a comunicação neuromórfica entre eles. Isso permitiu simular redes neurais com centenas de milhares de neurônios em tempo real, com um consumo energético ainda inferior ao de GPUs tradicionais executando Redes Profundas Artificiais (ANNs).

Por fim, a compatibilidade com ambientes de desenvolvimento abertos, como o Lava — framework neuromórfico desenvolvido pela Intel —, facilitou a adoção do Loihi 2 pela comunidade científica e industrial. O ecossistema de ferramentas,

documentação e simulações tornou-se um diferencial estratégico para acelerar testes, modelagem e integração em sistemas embarcados reais.

Na figura “Diagrama de blocos da arquitetura interna do chip Loihi 2”, observa-se o arranjo em malha 2D dos núcleos neuronais interligados, responsáveis pelo processamento distribuído dos spikes. Os microprocessadores embarcados coordenam a codificação de dados e o gerenciamento da rede, enquanto as interfaces paralelas de entrada/saída permitem a comunicação entre múltiplos chips. Também está presente uma estrutura de rede-em-chip com suporte a handshakes e roteamento eficiente.

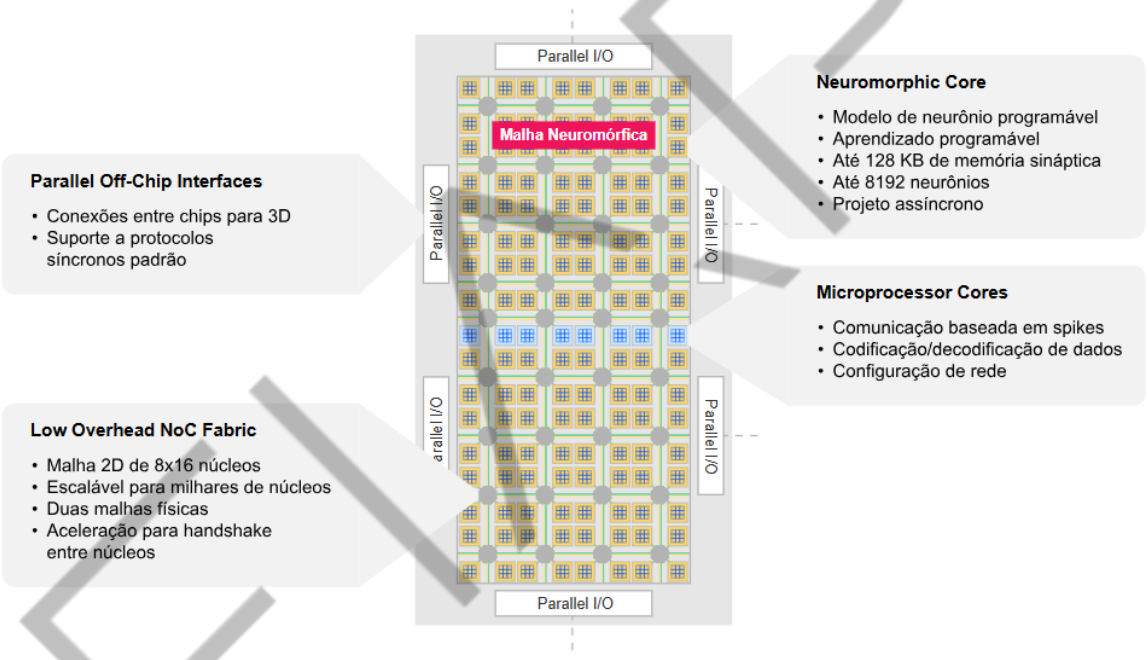


Figura 5 - Diagrama de blocos da arquitetura interna do chip Loihi 2
Fonte: Intel Loihi (2021a), adaptado pelo autor (2025)

Esses avanços possibilitaram uma aceleração significativa nas operações básicas. O Loihi 2 é até 10 vezes mais rápido na geração de spikes e até 5 vezes mais eficiente em atualizações sinápticas quando comparado ao Loihi 1.

Os circuitos assíncronos do Loihi 2 foram completamente redesenhados, alcançando uma resolução temporal inferior a 200 nanossegundos. Isso permite a simulação de redes neurais spiking com desempenho até 5000 vezes superior ao dos neurônios biológicos.

A arquitetura de memória também foi significativamente otimizada. O Loihi 2 utiliza uma abordagem de alocação dinâmica, ajustando a distribuição de memória

entre neurônios e sinapses conforme a necessidade de cada núcleo. Isso permite implementar até quatro vezes mais neurônios no mesmo espaço físico.

Recursos adicionais como conectividade fatorada, convolucional e estocástica permitem compressão de dados sinápticos. A compressão pode alcançar até 80 vezes mais eficiência em modelos com características apropriadas.

A estrutura de compressão e partição de memória no núcleo neuronal do Loihi 2 mostra como o chip emprega técnicas avançadas para maximizar o uso eficiente da memória.

A figura “Comparativo entre o Loihi e o Loihi 2 em termos de desempenho e recursos” destaca três abordagens principais de compactação sináptica: **convolucional**, **estocástica** e **fatorada**. A abordagem convolucional permite economizar memória ao armazenar apenas o kernel convolucional, sendo ideal para redes que exploram padrões espaciais como as aplicadas ao processamento de imagem.

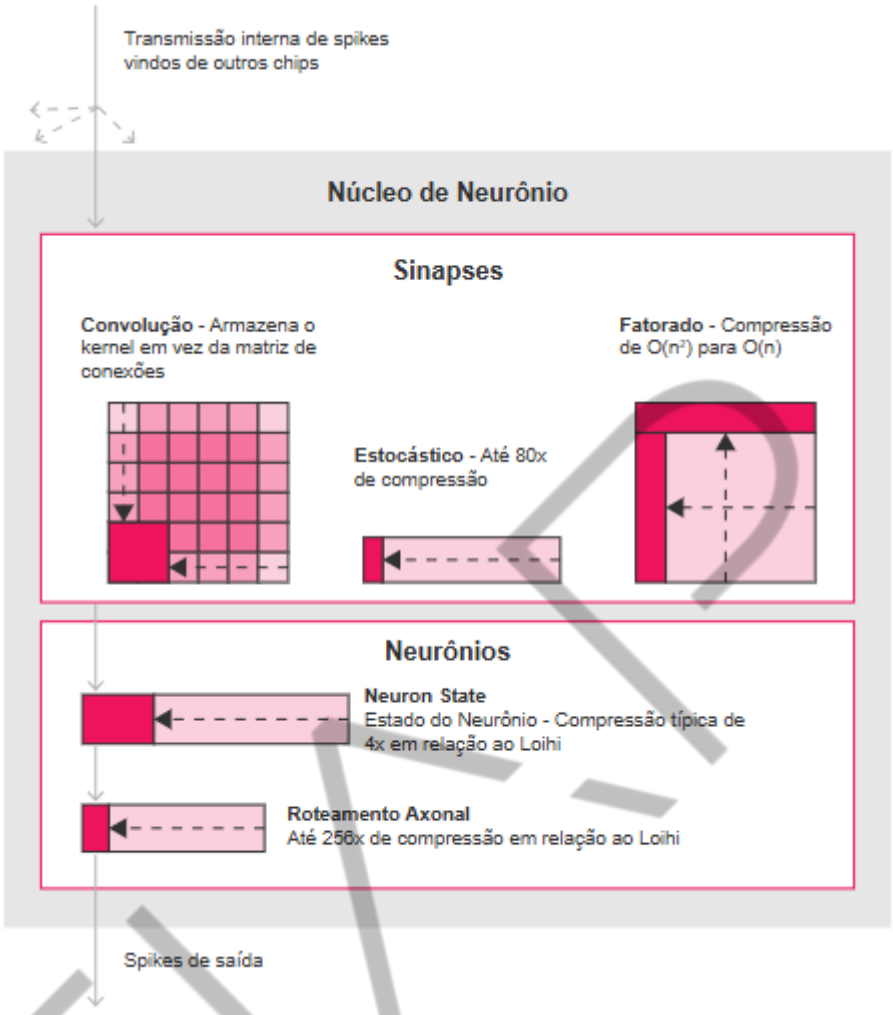


Figura 6 - Comparativo entre o Loihi e o Loihi 2 em termos de desempenho e recursos
Fonte: Intel Loihi (2021a), adaptado pelo autor (2025)

Já a compactação estocástica gera sinapses a partir de sementes aleatórias, dispensando a necessidade de armazenar cada peso individualmente e permitindo compressões superiores a 80 vezes em contextos tolerantes à variabilidade. A técnica fatorada, por sua vez, representa matrizes de conexão como produtos vetoriais, reduzindo a complexidade de armazenamento de $O(n^2)$ para $O(n)$, o que favorece tanto o uso eficiente da memória quanto a velocidade de processamento.

Além das sinapses, a estrutura interna dos neurônios também foi otimizada. O estado do neurônio, que inclui parâmetros como potencial de membrana e histórico de disparos, é armazenado em formatos compactos que reduzem em até quatro vezes o uso de memória em comparação com o Loihi original.

O roteamento de axônios, antes baseado em tabelas explícitas de destino, foi substituído por um sistema de endereçamento comprimido, possibilitando uma

compressão de até 256 vezes. Isso viabiliza um número significativamente maior de conexões por unidade de área.

Essa engenharia de compactação permite que o Loihi 2 acomode milhões de sinapses e dezenas de milhares de neurônios em um único chip, mantendo baixo consumo energético. Essa densidade funcional, combinada a técnicas avançadas de comunicação assíncrona e processamento local, oferece escalabilidade e flexibilidade excepcionais para a construção de redes neurais artificiais inspiradas em sistemas biológicos.

O conjunto dessas estratégias de compressão é fundamental para o uso do Loihi 2 em dispositivos de borda com restrições de energia e espaço, como sensores inteligentes, robôs autônomos e sistemas embarcados de tempo real também destaca os ganhos de eficiência na área de neurônios.

O estado interno dos neurônios — incluindo variáveis como potencial de membrana, estado de repouso e histórico de spikes — é compactado em estruturas de dados otimizadas que reduzem o uso de memória em até quatro vezes, sem sacrificar a precisão da dinâmica neural.

Outra inovação relevante está no roteamento dos axônios. O mecanismo tradicional, que exige armazenamento explícito para cada conexão de saída, foi substituído por um sistema de endereçamento comprimido. Esse novo sistema permite compressões de até 256 vezes, aumentando drasticamente o número de conexões possíveis por unidade de área no chip.

Esses avanços tornam possível criar redes com milhões de sinapses e dezenas de milhares de neurônios em um único chip, mantendo um consumo energético extremamente baixo. O resultado é uma plataforma que oferece não apenas desempenho escalável, mas também flexibilidade para acomodar uma ampla quantidade de modelos computacionais inspirados no cérebro.

Em suma, a combinação de engenharia eficiente de hardware com princípios computacionais avançados, destacando como o Loihi 2 atinge alta densidade de computação neuromórfica ao mesmo tempo que reduz os requisitos de energia e armazenamento. Essa capacidade é fundamental para tornar a Inteligência Artificial Embarcada viável em dispositivos com restrições severas de recursos, como sensores autônomos e sistemas robóticos móveis.

Um dos avanços mais notáveis do Loihi 2 está na compatibilidade com SDNNs (Sigma-Delta Neural Networks). Esses modelos combinam os princípios das redes profundas tradicionais com comunicação baseada em eventos, proporcionando um aumento superior a 10x em eficiência e velocidade de inferência em comparação com abordagens anteriores.

Complementando a plataforma de hardware, a Intel lançou o Lava, um ecossistema de software open-source projetado para programar e simular redes neuromórficas. Modular e extensível, o Lava oferece ferramentas de simulação, mapeamento e execução em plataformas convencionais (CPU/GPU) antes da transferência para o hardware Loihi.

O Lava opera com base em um paradigma baseado em comunicação assíncrona entre processos, inspirado no modelo de atores. Isso permite a construção de sistemas complexos com alto grau de paralelismo e escalabilidade.

No aspecto de hardware de acesso, o Loihi 2 está disponível em duas plataformas principais: Oheo Gulch e Kapoho Point. A primeira é voltada para experimentação em laboratório e combina um único chip Loihi 2 com um FPGA Intel Arria 10.

Já o Kapoho Point traz oito chips Loihi 2 empilhados verticalmente, em uma placa compacta com conectividade GPIO e Ethernet. Ideal para aplicações embarcadas, essa plataforma visa atender projetos em robótica, drones e dispositivos autônomos.

Essas plataformas estão acessíveis por meio da Neuromorphic Research Cloud, um ambiente colaborativo que reúne mais de 140 instituições. A iniciativa fomenta a pesquisa e acelera a adoção da tecnologia neuromórfica, fornecendo hardware, suporte e intercâmbio técnico.

O Loihi 2 destaca-se como plataforma promissora para Inteligência Artificial Embarcada. Suas capacidades de aprendizado local, resposta em tempo real e baixo consumo o tornam ideal para aplicações em ambientes dinâmicos e imprevisíveis.

Entre os casos de uso possíveis estão veículos autônomos, dispositivos IoT inteligentes, sistemas neurais assistivos, e interfaces homem-máquina responsivas. Sua independência de conexões com a nuvem reduz a latência e aumenta a privacidade dos dados processados.

A arquitetura programável, combinada com os recursos de aprendizado adaptativo, posiciona o Loihi 2 como um elo entre a computação inspirada no cérebro e as aplicações comerciais de IA.

A expectativa é que futuras versões da linha Loihi expandam ainda mais os recursos de aprendizado online e a integração com sensores inteligentes, potencializando aplicações em cidades inteligentes e sistemas ciberfísicos.

Combinando avanços em hardware, software e colaboração científica, a Intel estabelece as bases para uma nova era de computação, aproximando os limites da Inteligência Artificial dos processos naturais de cognição.

O chip neuromórfico Loihi, da Intel, representa um avanço significativo na computação inspirada no cérebro humano, possibilitando aplicações em áreas onde a IA precisa operar com eficiência energética, resposta em tempo real e grande capacidade de aprendizado adaptativo. A figura “Hala Point” apresenta o maior sistema neuromórfico do mundo.



Figura 7 - Hala Point
Fonte: Intel Loihi (2021b), adaptado pelo autor (2025)

Essa impressionante estrutura, desenvolvida pela Intel, foi projetada com base na segunda geração dos processadores Loihi e é capaz de simular mais de um bilhão de neurônios e centenas de bilhões de sinapses artificiais. Sua capacidade computacional é expressa em números que remetem ao funcionamento do próprio cérebro: são 380 trilhões de operações sinápticas por segundo e 240 trilhões de operações neuronais no mesmo intervalo de tempo. Trata-se de uma plataforma poderosa voltada à pesquisa e ao desenvolvimento de soluções reais baseadas em Inteligência Artificial Neuromórfica.

O Hala Point não é apenas um experimento de laboratório. Ele é parte de uma estratégia da Intel para expandir o acesso e a aplicação dos chips Loihi em contextos comerciais. A estrutura é altamente escalável, utilizando mais de mil processadores Loihi 2 conectados a centenas de milhares de núcleos neuromórficos e processadores x86. Isso permite que diferentes usuários executem, de forma paralela e eficiente, modelos neurais complexos — algo fundamental para tarefas que exigem processamento em tempo real e economia de energia, como veremos adiante.

Para facilitar o uso dessa infraestrutura por empresas e instituições de pesquisa, a Intel criou a Intel Neuromorphic Research Community (INRC). Por meio dela, é possível obter acesso em nuvem aos sistemas Loihi, o que significa que não é necessário possuir fisicamente os chips para desenvolver soluções com base neles. O processo de acesso envolve a filiação à comunidade, com aprovação prévia. Uma vez aceitos, os membros podem utilizar os sistemas hospedados remotamente ou, em alguns casos, solicitar dispositivos físicos por empréstimo.

Essas facilidades têm incentivado uma série de aplicações comerciais, principalmente na área da robótica inteligente. Empresas que desenvolvem braços robóticos, por exemplo, têm se beneficiado da arquitetura do Loihi para desenvolver sistemas capazes de aprender com a experiência. Um braço robótico equipado com algoritmos neuromórficos pode ajustar seus movimentos, adaptar-se a diferentes tarefas e até melhorar seu desempenho com o tempo — algo que os chips tradicionais, como CPUs ou GPUs, não conseguem fazer com a mesma eficiência energética.

Outra frente de aplicação são os sensores inteligentes, como os sensores olfativos, que precisam identificar e classificar odores com rapidez e precisão. A capacidade do Loihi de reconhecer padrões e aprender continuamente faz dele um componente ideal para sensores utilizados em ambientes industriais, agrícolas, médicos ou até mesmo na segurança. Graças à sua eficiência computacional, ele pode operar esses sistemas de maneira contínua, sem exigir grandes quantidades de energia ou hardware dedicado.

Por fim, vale destacar que empresas como Accenture, Airbus, GE e Hitachi já estão explorando ativamente as capacidades do Loihi, desenvolvendo soluções comerciais com base nessa tecnologia. Essas parcerias reforçam que a computação neuromórfica não é apenas uma tendência acadêmica, mas uma ferramenta real para a inovação em produtos e serviços.

Para encerrar esta seção, apresentaremos um quadro comparativo detalhado entre os chips neuromórficos TrueNorth, desenvolvido pela IBM, e Loihi, criado pela Intel. Este comparativo fornecerá uma visão clara das vantagens e limitações de cada chip, contribuindo para uma melhor compreensão das tendências e desafios dessa área emergente. Com isso, encerramos o tópico com uma análise crítica que serve de base para futuras discussões sobre aplicações e desenvolvimento de sistemas neuromórficos.

Característica	IBM TrueNorth	Intel Loihi (1 e 2)
Ano de lançamento	2014	2017 (Loihi 1), 2021 (Loihi 2)
Fabricante	IBM	Intel
Tecnologia	28 nm CMOS	14 nm (Loihi 1); Intel 4 (Loihi 2)
Número de neurônios	1 milhão	~130 mil (Loihi 1); semelhante no Loihi 2
Número de sinapses	256 milhões	130 milhões
Número de núcleos	4.096	128 (Loihi 1); 192 (Loihi 2)
Arquitetura de	Estática, modelo LIF simplificado	Programável, com suporte a diferentes tipos neuronais
Plasticidade sináptica	Não suporta	Suporta (STDP, Hebb, aprendizado local)
Aprendizado em tempo real	Não	Sim
Eficiência energética	Até 400 GigaSynopses/s/W	15 TOPS/W (Loihi 2)
Consumo de energia (idle)	~70 mW	<30 mW (Loihi 1); ainda menor no Loihi 2
Interconectividade	Rede mesh bidimensional fixa	Rede escalável com roteamento adaptativo
Memória integrada por núcleo	256 kB	192 kB (Loihi 1); aprimorado no Loihi 2
Tipo de comunicação	Pacotes de spikes	Spikes com roteamento dinâmico
Objetivo do projeto	Execução eficiente de redes treinadas	Aprendizado adaptativo e aplicações em IA dinâmica
Acesso para pesquisadores	Restrito, sob parceria com IBM	Amplo, via Intel Neuromorphic Research Community (INRC)
Escalabilidade de sistema	Limitada a arquitetura de interconexão	Altamente escalável (vide Hala Point com >1.000 chips)
Aplicações típicas	Classificação de padrões estáticos, reconhecimento de imagens	Robótica, sensores inteligentes, controle adaptativo
Disponibilidade comercial	Não disponível para uso amplo	Acesso remoto e colaborações comerciais ativas

Quadro 1 - Comparação entre chips neuromórficos TrueNorth e Loihi
Fonte: Roy; Jaiswal; Panda (2019), adaptado pelo autor (2025)

2 INTRODUÇÃO À FOTÔNICA: O QUE É E COMO FUNCIONA

Desde a invenção da lâmpada até as fibras ópticas que sustentam a internet global, a luz sempre foi uma ferramenta essencial para o progresso humano. A fotônica surge como a ciência que domina esse recurso, transformando fótons em soluções para desafios modernos — de cirurgias de precisão a comunicações ultrarrápidas. Se no século XX a eletrônica revolucionou a sociedade com elétrons, no século XXI a fotônica repete essa façanha com luz, oferecendo vantagens únicas: imunidade a interferências, largura de banda sem precedentes e aplicações que vão do cotidiano à exploração espacial.

Nesta seção, exploraremos os princípios físicos que tornam essa revolução possível, desde a dualidade onda-partícula da luz até as tecnologias que a transformam em informação, energia e inovação.

2.1 Fundamentos da fotônica

A fotônica é o campo da ciência e tecnologia que estuda e explora a geração, transmissão, modulação, detecção e conversão da luz em diversos contextos. Nas últimas décadas, essa área ganhou destaque por oferecer soluções avançadas em telecomunicações, sensores, computação e medicina. A luz, neste contexto, é tratada como uma forma de radiação eletromagnética que pode ser manipulada com alto grau de precisão, permitindo inovações antes limitadas pela eletrônica convencional.

O termo “fotônica” deriva do conceito de fóton — a menor unidade de energia luminosa, que representa o quantum da radiação eletromagnética. Assim como a eletrônica se baseia na manipulação de elétrons, a fotônica se baseia no controle de fótons. Essa analogia é fundamental para compreender por que a fotônica é vista como uma extensão ou evolução complementar à eletrônica, especialmente em aplicações onde o transporte de informação com alta velocidade e baixa perda é essencial.

Diferenciando-se da óptica clássica, que tradicionalmente trabalha com sistemas macroscópicos como lentes, espelhos e prismas, a fotônica foca no controle da luz em escalas microscópicas ou nanométricas. Isso inclui o uso de guias de onda

ópticos, cavidades ressonantes, lasers semicondutores, fibras ópticas e materiais fotônicos estruturados. Esses elementos permitem o desenvolvimento de circuitos fotônicos integrados, cuja função é análoga à de circuitos eletrônicos, porém baseados na propagação e processamento da luz.

Entre os fenômenos físicos explorados pela fotônica, destaca-se a dualidade onda-partícula da luz. A luz pode se comportar como uma onda eletromagnética — caracterizada por frequência, comprimento de onda e polarização — ou como um fluxo de partículas, os fótons, dependendo do contexto experimental ou tecnológico. Essa característica é essencial para aplicações que vão desde a interferometria óptica até a geração de fótons individuais para uso em comunicação quântica e criptografia segura.

A luz ocupa uma faixa específica do espectro eletromagnético, que vai das ondas de rádio (com comprimentos de onda muito longos) até os raios gama (de altíssima frequência). A fotônica opera principalmente nas faixas do infravermelho, visível e ultravioleta, sendo o espectro visível um dos mais explorados devido à sua compatibilidade com sensores e fontes de luz convencionais. A figura “Espectro Eletromagnético” ilustra essas diferentes faixas e destaca a região visível, que corresponde aproximadamente aos comprimentos de onda entre 400 e 700 nanômetros — uma região utilizada em aplicações fotônicas.

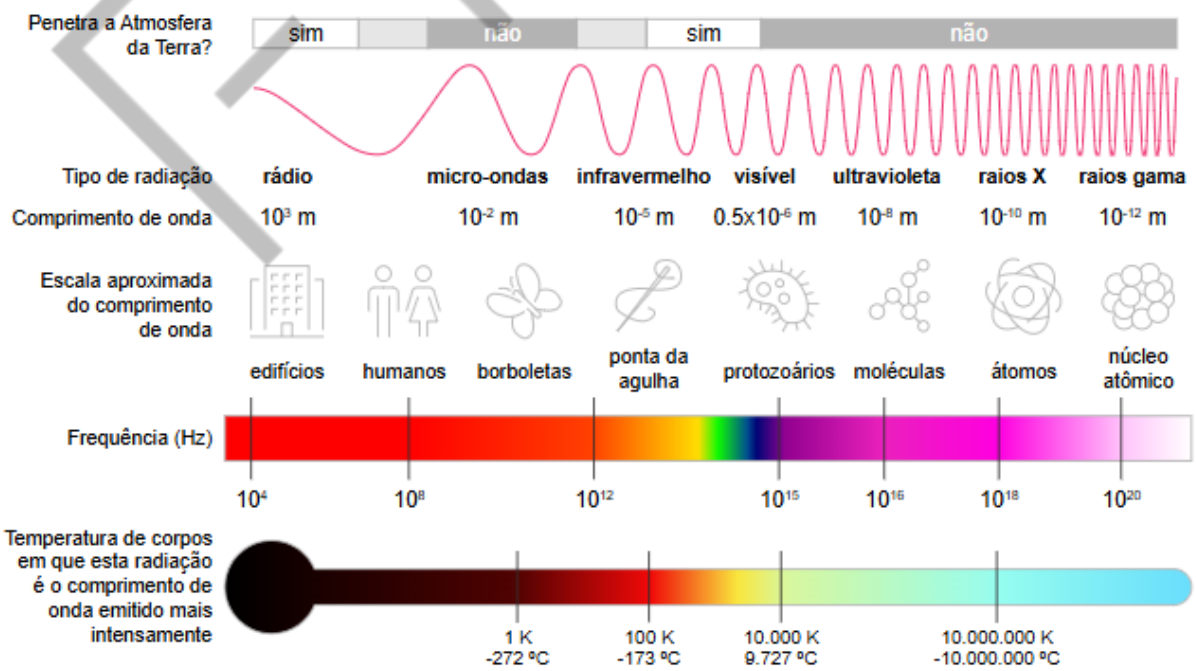


Figura 8 - Espectro Eletromagnético
Fonte: Khan Academy (2025), adaptado pelo autor (2025)

Do ponto de vista ondulatório, a luz é caracterizada por seu comprimento de onda λ, sua frequência *f* e sua velocidade de propagação *c*, relacionadas pela equação fundamental da ondulatória eletromagnética:

$$C = \lambda \cdot f \qquad (1)$$

Em que:

- $C = 3 \times 10^8$m/s é a velocidade da luz no vácuo;
- λ é o comprimento de onda (em metros);
- f é a frequência da onda (em hertz).

A natureza corpuscular da luz é evidenciada por sua interação com a matéria, como no efeito fotoelétrico. Nessa perspectiva, cada fóton possui uma energia associada, dada pela relação de Planck:

$$E = h \cdot f \qquad (2)$$

Em que:

- E é a energia do fóton (em joules);
- h = 6,626×10^{-34} J.s é a constante de Planck;
- f é a frequência da luz.

Com base nesses conceitos, a fotônica lida com fenômenos como transmissão, modulação, detecção e amplificação óptica. Isso inclui dispositivos como lasers, LEDs, moduladores, detectores e guias de onda, todos baseados em interações específicas entre a luz e os materiais.

A origem da fotônica moderna remonta à invenção do laser em 1960. Desde então, marcos importantes incluíram a introdução da fibra óptica para comunicações, o desenvolvimento de amplificadores ópticos com íons de érbio (EDFA) e o surgimento de materiais com índice de refração controlável. A década de 1980 foi decisiva, quando o termo “fotônica” foi amplamente adotado com o surgimento da revista *Photonics Technology Letters* do IEEE.

O impacto tecnológico da fotônica pode ser comparado ao da eletrônica no século XX. Com a diferença fundamental de que a luz não sofre interferência eletromagnética, como ocorre com os sinais eletrônicos, e pode se propagar em fibras ópticas com baixíssima atenuação, a fotônica oferece larguras de banda significativamente maiores para a transmissão de dados.

Outro fator fundamental para o avanço da fotônica está na utilização de fenômenos de reflexão total interna (TIR), em que a luz se propaga confinada dentro de um meio com maior índice de refração, como nas fibras ópticas. Esse princípio será explorado mais adiante com base na Lei de Snell:

$$\frac{sin\alpha}{sin\beta} = \frac{n_2}{n_1} \qquad (3)$$

A partir dessa relação, pode-se definir o ângulo crítico para reflexão total:

$$sin\alpha_{crítico} = \frac{n_2}{n_1} \qquad (4)$$

Em que $n_1 > n_2$ e $\alpha_{crítico}$ é o ângulo mínimo de incidência para que a luz permaneça confinada.

As tecnologias fotônicas também estão na vanguarda da computação quântica e da comunicação segura via criptografia quântica, pois os fótons permitem a codificação de informação em estados quânticos como polarização e fase.

Importante destacar também que fotônica não é sinônimo de óptica. Enquanto a óptica abrange fenômenos mais amplos, incluindo lentes e formação de imagens, a fotônica foca em aplicações onde a manipulação da luz ocorre em nível eletrônico e estrutural, como em guias de onda, sensores e sistemas integrados.

A interdisciplinaridade da fotônica é evidente: ela se relaciona com diversos campos, como a eletrônica (optoeletrônica), mecânica (optomecânica), química (espectroscopia), computação (computação óptica e quântica), entre outros. Essa natureza ampla é refletida nas microestruturas que serão estudadas ao longo deste capítulo.

Portanto, esta seção introdutória estabelece a base conceitual e histórica necessária para compreender as tecnologias fotônicas modernas, especialmente no contexto das microestruturas, que serão exploradas com profundidade nas seções seguintes.

2.2 Aplicações da fotônica

A fotônica encontra aplicações em quase todos os domínios da vida moderna, desde as atividades rotineiras até os limites da ciência de ponta. Essa onipresença é fruto de sua capacidade de controlar a luz para realizar tarefas que, anteriormente, dependiam de meios eletrônicos, mecânicos ou químicos. Atualmente, os sistemas fotônicos estão presentes em diversas áreas, como telecomunicações, medicina, manufatura, defesa, agricultura e computação.

Uma das aplicações mais conhecidas da fotônica está nas telecomunicações ópticas, em que dados são transmitidos por fibras ópticas com alta largura de banda e baixíssima atenuação. Isso é possível graças à capacidade das fibras de guiar a luz utilizando o princípio da reflexão total interna. Em sistemas modernos, a multiplexação por divisão de comprimento de onda (WDM) permite que vários canais de dados sejam transmitidos simultaneamente na mesma fibra, aumentando exponencialmente a capacidade de transmissão.

Na área médica, a fotônica é essencial para procedimentos de diagnóstico e terapêuticos. Exemplos incluem cirurgias com laser, correções visuais com excimer lasers, endoscopias com fibras ópticas flexíveis e o monitoramento de sinais fisiológicos por meio de sensores ópticos. A capacidade da luz de penetrar tecidos e fornecer informação espectral ou estrutural é particularmente valiosa em diagnósticos não invasivos.

Outra aplicação de destaque é na metrologia, onde a precisão extrema dos sistemas ópticos permite medições de distância, tempo, frequência e velocidade com exatidão nanométrica. Interferômetros baseados em lasers são utilizados para calibrar padrões de comprimento e em sistemas de posicionamento de alta resolução. O uso de relógios atômicos ópticos, por exemplo, permite medições de tempo com desvios inferiores a um segundo em milhões de anos.

Na indústria, os lasers são empregados em processos de corte, soldagem, perfuração e marcação de materiais, com vantagens como precisão elevada, controle térmico e flexibilidade de materiais. Além disso, a fotônica permite o desenvolvimento de sistemas inteligentes para construção civil, como alinhadores a laser, sensores para estruturas inteligentes (*smart structures*) e niveladores automáticos de precisão.

Na defesa e segurança, a fotônica é aplicada em sistemas de navegação, imageamento infravermelho (IR), sensores de vigilância, sistemas de mira e telecomunicação criptografada por fótons. O uso de fibras ópticas também é estratégico em ambientes com interferência eletromagnética elevada, onde sistemas eletrônicos convencionais seriam inutilizados.

Outro campo emergente é o da computação fotônica, na qual se substituem elétrons por fótons em circuitos para realizar operações lógicas ou processamentos paralelos. As vantagens incluem maior velocidade de propagação, menor geração de calor e maior largura de banda. Um componente essencial nesta área são os circuitos integrados fotônicos (PICs), que combinam múltiplos elementos ópticos em uma única pastilha.

No contexto da nanofotônica e biopotônica, dispositivos miniaturizados baseados em guias de onda, cristais fotônicos e microcavidades são utilizados para detectar, manipular e identificar moléculas com altíssima sensibilidade. Isso tem aplicações em biossensores, espectroscopia Raman amplificada por superfície (SERS) e em chips laborais (lab-on-chip).

A fotônica também contribui para a área de energia, especialmente no desenvolvimento de células solares de terceira geração, que utilizam materiais e arquiteturas otimizadas para conversão fotovoltaica mais eficiente. Além disso, sensores ópticos são empregados para monitoramento e controle de processos em plantas de geração de energia, como em turbinas eólicos ou reatores nucleares.

No campo da arte e entretenimento, a fotônica está presente em projeções holográficas, iluminação LED controlada por espectro, sistemas de realidade aumentada e displays de alta resolução. A interação entre luz e materiais orgânicos também é explorada em telas flexíveis e impressas.

Por fim, existem aplicações inovadoras em agricultura de precisão, onde sensores fotônicos monitoram níveis de umidade, presença de patógenos ou

maturação de frutos com base em espectroscopia no infravermelho próximo (NIR). Esses sistemas permitem decisões rápidas e baseadas em dados, otimizando colheitas e reduzindo desperdícios.

Embora diversas dessas aplicações envolvam dispositivos distintos, todas compartilham princípios fotônicos fundamentais, como modulação de intensidade, fase e polarização, além do controle do comprimento de onda. A capacidade de integrar esses princípios em microestruturas está no cerne do desenvolvimento da próxima geração de tecnologias fotônicas.

A seguir, exploraremos os avanços recentes que permitiram a evolução dessas aplicações e possibilitaram novas fronteiras de atuação da fotônica.

2.3 Avanços na fotônica

A fotônica tem vivenciado um crescimento exponencial nas últimas décadas, tanto no âmbito da pesquisa acadêmica quanto no desenvolvimento de aplicações industriais e tecnológicas. Esse avanço é resultado da combinação entre maturidade científica e demanda crescente por soluções mais rápidas, eficientes e miniaturizadas em áreas como telecomunicações, sensoriamento e processamento de dados. A consolidação da fotônica como área estratégica tem impulsionado investimentos públicos e privados em centros de pesquisa, laboratórios e empresas de alta tecnologia.

Esse progresso pode ser quantificado a partir da análise de métricas bibliométricas, como número de publicações, fator de impacto e citações. Bases de dados científicas amplamente reconhecidas, como a *Web of Science*, indicam uma tendência de crescimento constante na quantidade de artigos científicos relacionados à fotônica. A figura a seguir ilustra esses dados e serve como representação visual do avanço no campo.

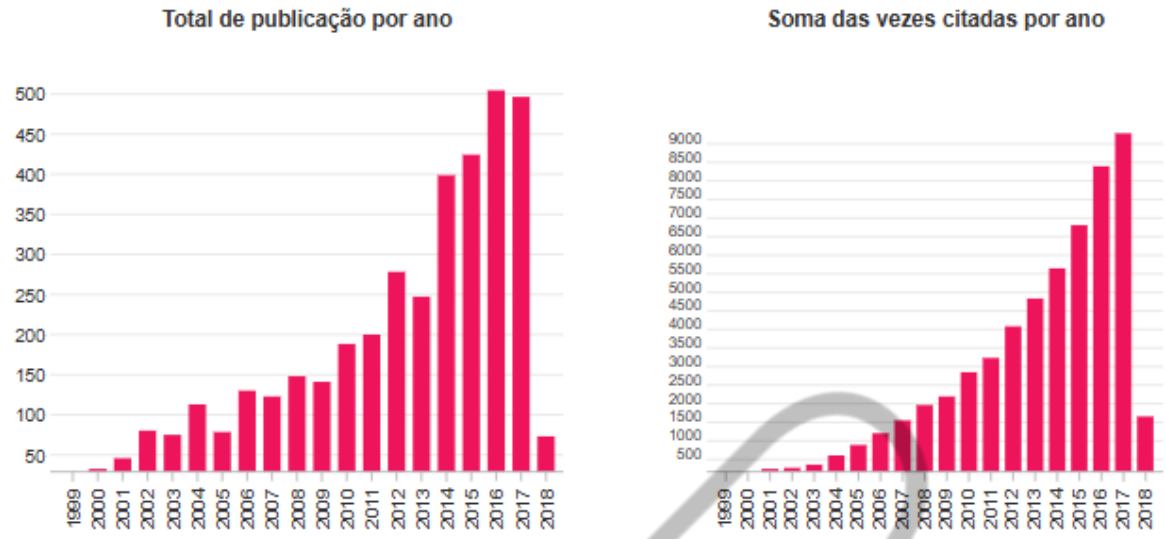


Figura 9 - Tendências de publicações e citações em fotônica
Fonte: Thomson Reuters Web of Science (2018), adaptado pelo autor (2025)

Além do crescimento quantitativo, observa-se também uma qualitativa ampliação do escopo temático da fotônica. A área não apenas evolui de forma autônoma, mas se interliga com outros campos estratégicos, como a eletrônica, a mecânica de precisão, a ciência dos materiais, a nanotecnologia e, mais recentemente, a computação quântica.

Essa convergência tecnológica possibilita o desenvolvimento de dispositivos híbridos e multifuncionais, como sensores ópticos integrados com circuitos eletrônicos ou chips fotônicos aplicados a algoritmos de Machine Learning.

Essas integrações interdisciplinares também permitem avanços em escalabilidade, portabilidade e custo, o que contribui para a popularização de soluções fotônicas em produtos de consumo, saúde, defesa e indústria. O uso de lasers compactos, guias de onda em silício e emissores de luz baseados em materiais 2D, por exemplo, são frutos diretos desse ambiente colaborativo entre diferentes áreas do conhecimento. A tendência é que, nos próximos anos, esses sistemas fotônicos avancem ainda mais, permitindo dispositivos cada vez menores, mais rápidos e energeticamente eficientes.

Portanto, os avanços na fotônica não são apenas reflexo de inovações isoladas, mas resultado de um ecossistema científico-tecnológico em constante interação. À medida que novas demandas surgem — como comunicações ultra-rápidas, computação baseada em luz ou biossensores de alta precisão —, a fotônica

se reposiciona e se reinventa, reafirmando seu papel essencial na revolução tecnológica contemporânea.

Uma das razões para esse crescimento é a convergência da fotônica com outras áreas de fronteira, como eletrônica, mecânica de precisão, nanotecnologia, ciência dos materiais e, mais recentemente, computação quântica. A integração de múltiplas tecnologias está permitindo o desenvolvimento de sistemas mais sofisticados, miniaturizados e de menor custo.

Entre os avanços mais significativos estão os detectores fotônicos, que variam de dispositivos lentos, como células solares, até fotodiodos ultrarrápidos utilizados em telecomunicações. Os detectores modernos são capazes de operar em faixas espectrais específicas e possuem uma alta eficiência quântica, permitindo a detecção precisa de sinais ópticos mesmo em ambientes ruidosos.

O desenvolvimento de sistemas fotônicos integrados também representa um marco importante. Assim como os circuitos integrados revolucionaram a eletrônica, os Photonic Integrated Circuits (PICs) estão possibilitando a integração de fontes de luz, moduladores, guias de onda e detectores em uma única pastilha. Isso reduz significativamente o consumo de energia, o custo e o volume dos sistemas.

Outro avanço notável é a área da fotônica de micro-ondas (*microwave photonics*), uma tecnologia emergente que possibilita a geração, modulação, detecção e processamento de sinais de micro-ondas utilizando dispositivos fotônicos. Esses sistemas oferecem vantagens como ampla largura de banda, imunidade a interferência eletromagnética (EMI) e baixas perdas dependentes da frequência.

Aplicações em opto-atomística têm ganhado destaque, integrando dispositivos atômicos com sistemas fotônicos. Essa combinação permite aplicações em metrologia de precisão, como relógios atômicos ópticos, que operam com base na transição eletrônica de átomos manipulados por lasers, atingindo precisão de ordem 10^{-18}.

Além disso, o campo da plasmonônica também vem progredindo rapidamente. Os *plasmon lasers* — ou lasers de plasmons de superfície — permitem o confinamento da luz em escalas abaixo do limite de difração, possibilitando a geração de radiação eletromagnética de alta intensidade e em escalas nanométricas. Isso é particularmente útil em aplicações como gravação de dados, bioimagem e litografia óptica.

Os *plasmon lasers* exploram os modos de superfície dos plasmons, que são oscilações coletivas de elétrons em superfícies metálicas. Tais lasers conseguem confinar campos elétricos intensos em regiões extremamente pequenas. Esse confinamento é fundamental para o desenvolvimento de dispositivos ultracompactos e sensores altamente sensíveis.

O avanço em técnicas de fotolitografia alimentadas por fontes fotônicas tem permitido fabricar estruturas em nanoescala com maior precisão e controle. Essas tecnologias são indispensáveis na produção de chips e dispositivos para fotônica integrada e computação óptica.

Um outro avanço técnico relevante é o uso de espectroscopia no infravermelho médio (mid-IR spectroscopy), que permite identificar estruturas moleculares e realizar medições não invasivas com alta sensibilidade. A largura de seção de absorção nesse espectro é suficientemente ampla para detectar traços de compostos em níveis de partes por trilhão (ppt).

Esses avanços refletem não apenas na performance dos dispositivos, mas também em sua aplicabilidade em ambientes industriais, médicos e de defesa. Por exemplo, sensores ópticos baseados em PICs estão sendo utilizados para monitorar ambientes extremos, como reatores nucleares, poços de petróleo e linhas de alta tensão.

Por fim, vale destacar que os avanços recentes estão fundamentando a próxima revolução tecnológica na computação quântica fotônica, que utiliza fótons como qubits em circuitos ópticos quânticos. A coerência, baixa interação com o ambiente e a facilidade de manipulação de estados ópticos fazem dos fótons candidatos ideais para esse novo paradigma computacional.

2.4 Estruturas, tipos e aplicações de fibras óticas

Esse tópico apresenta os principais aspectos estruturais e funcionais das fibras ópticas, abordando desde sua composição física até os tipos mais utilizados em aplicações práticas. O objetivo é oferecer uma visão clara sobre como essas estruturas atuam na condução da luz, destacando a importância de cada camada que compõe a fibra para garantir desempenho e robustez.

Além da estrutura, também são discutidas as variações tecnológicas das fibras ópticas — como fibras monomodo e multimodo — e suas aplicações em diferentes contextos, como telecomunicações, sensores industriais, sistemas médicos e redes de alta velocidade. A combinação de eficiência, leveza e imunidade a interferências eletromagnéticas torna essas fibras elementos-chave da infraestrutura digital moderna.

As fibras ópticas são filamentos extremamente finos e flexíveis, geralmente feitos de vidro de alta pureza (ou, em alguns casos, de polímeros), projetados para transmitir sinais de luz ao longo de grandes distâncias com mínima perda de energia.

Elas representam um dos pilares da tecnologia fotônica moderna, permitindo a propagação de informações com altíssima velocidade e confiabilidade. Seu diâmetro é comparável ao de um fio de cabelo humano, mas sua capacidade de transporte de dados é exponencialmente maior do que a de cabos elétricos convencionais.

Essas fibras são fabricadas a partir de uma peça inicial chamada pré-forma, uma haste de vidro cilíndrica que passa por um processo térmico de estiramento, transformando-se em um fio contínuo e extremamente fino. Durante esse processo, as propriedades ópticas da pré-forma são preservadas, e as camadas externas são cuidadosamente adicionadas para garantir proteção mecânica e resistência ambiental. O controle de temperatura e a precisão da geometria são fundamentais para assegurar o desempenho óptico da fibra resultante.

A figura “Estrutura de uma fibra ótica” ilustra a estrutura típica de uma fibra óptica, mostrando o núcleo, o revestimento e a camada protetora. Essa estrutura é essencial para garantir a eficiência na transmissão da luz e a durabilidade da fibra em ambientes adversos.

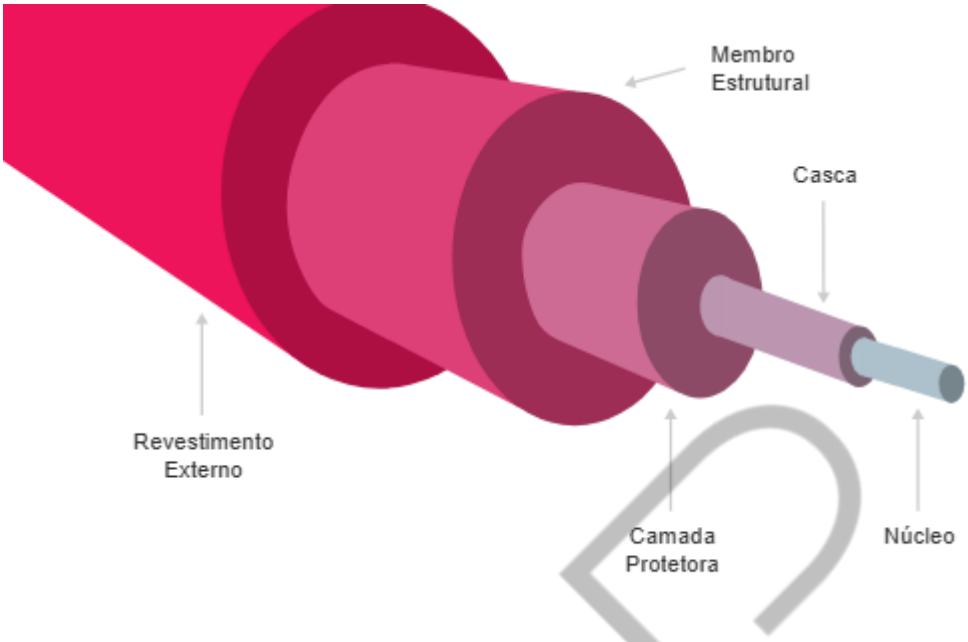


Figura 10 - Estrutura de uma fibra ótica
Fonte: Amiri *et al*. (2023), adaptado pelo autor (2025)

A estrutura de uma fibra óptica é composta por três camadas fundamentais: o **núcleo** (core), o **revestimento** (cladding) e a **camada externa protetora** (coating). O **núcleo**, por onde a luz se propaga, é feito de sílica dopada com elementos como germânio ou fósforo, o que permite ajustar seu índice de refração e influenciar diretamente propriedades como dispersão e atenuação do sinal. Em torno do núcleo, o **revestimento** — cuja composição também é baseada em sílica — é responsável por manter a luz confinada, mas com um índice de refração ligeiramente inferior. Essa diferença possibilita o fenômeno da reflexão interna total, essencial para guiar a luz ao longo da fibra com mínima perda.

A **camada mais externa da fibra**, conhecida como coating, é composta por materiais poliméricos aplicados ainda durante o processo de fabricação. Essa cobertura possui um papel fundamental na proteção mecânica, proporcionando resistência contra atrito, umidade e variações térmicas. Em contextos mais exigentes, como instalações submarinas, industriais ou subterrâneas, podem ser utilizados revestimentos adicionais, como jaquetas reforçadas, blindagens metálicas ou fibras de Kevlar, aumentando a durabilidade da fibra e garantindo sua integridade ao longo do tempo.

Graças a essa configuração, as fibras ópticas modernas apresentam altíssima eficiência de transmissão, com níveis de atenuação extremamente baixos — inferiores a 0,2 dB/km em determinadas faixas do espectro infravermelho. Isso permite que os

enlaces ópticos percorram grandes distâncias com mínima necessidade de amplificação ou repetição do sinal. Essa característica, somada à imunidade a interferências eletromagnéticas, faz das fibras ópticas uma escolha ideal para aplicações em redes de comunicação de alta capacidade.

As aplicações das fibras ópticas vão muito além das telecomunicações. Na área médica, são utilizadas em procedimentos minimamente invasivos, como endoscopias e cirurgias a laser, onde sua flexibilidade e precisão são essenciais. Em sistemas de sensoriamento distribuído, são capazes de medir temperatura, pressão, vibração e deformações estruturais em tempo real, sendo aplicadas em monitoramento de pontes, aviões, barragens e ambientes industriais. A sensibilidade da luz a variações ambientais torna as fibras uma plataforma versátil e poderosa para engenharia de detecção.

O papel das fibras ópticas também se expande para campos emergentes, como fotônica integrada, computação óptica e comunicação quântica, onde suas propriedades físicas — como estabilidade de fase, alta largura de banda e compatibilidade com circuitos integrados ópticos — tornam-se fundamentais. À medida que cresce a demanda por velocidade, segurança e eficiência energética, a presença das fibras ópticas tende a se consolidar como peça-chave das futuras infraestruturas tecnológicas.

O processo de fabricação das fibras envolve técnicas avançadas de engenharia de materiais, como deposição química em fase de vapor, utilizadas na construção da pré-forma — uma haste cilíndrica que, após o aquecimento e estiramento térmico, dá origem ao filamento final. Essa etapa exige controle preciso da geometria e da composição do vidro, o que garante pureza óptica, uniformidade do índice de refração e altíssima confiabilidade operacional, mesmo após décadas de uso.

Quanto à forma como a luz se propaga, as fibras ópticas são classificadas em dois tipos principais: **monomodo** e **multimodo**. As fibras multimodo, de núcleo mais largo (geralmente 50 ou 62,5 micrômetros), permitem que múltiplos modos de luz se propaguem simultaneamente, tornando seu acoplamento mais simples. Por essa razão, são indicadas para transmissões de curta a média distância, como em redes locais e data centers. Já as monomodo, com núcleo estreito (cerca de 8 a 10 micrômetros), limitam a propagação a um único modo, o que reduz a dispersão modal

e possibilita transmissões em altas velocidades por distâncias muito maiores — sendo ideais para backbones de internet e enlaces metropolitanos.

Dentro da categoria multimodo, ainda é possível distinguir entre fibras de índice degrau e de índice gradual. As primeiras apresentam uma transição abrupta entre o núcleo e o revestimento, o que tende a aumentar a dispersão e limitar a largura de banda. Já nas fibras de índice gradual, o índice de refração varia de forma contínua entre o centro do núcleo e as bordas, permitindo que diferentes caminhos ópticos sejam compensados, o que melhora a uniformidade do sinal na saída e resulta em maior desempenho para aplicações em curtas e médias distâncias.

A versatilidade, precisão e confiabilidade das fibras ópticas as transformam em uma tecnologia indispensável na era da informação. Seja em conexões de alta velocidade, sensores inteligentes ou circuitos integrados fotônicos, sua presença é cada vez mais estratégica. Para explorar todo seu potencial, é fundamental dominar os princípios ópticos, os processos de fabricação e as possibilidades de aplicação — o que torna seu estudo essencial nas engenharias e ciências aplicadas do século XXI.

As fibras ópticas são capazes de transmitir luz por longas distâncias com perdas mínimas graças a um fenômeno físico chamado reflexão interna total, ilustrado na figura “Fenômeno de reflexão total”.

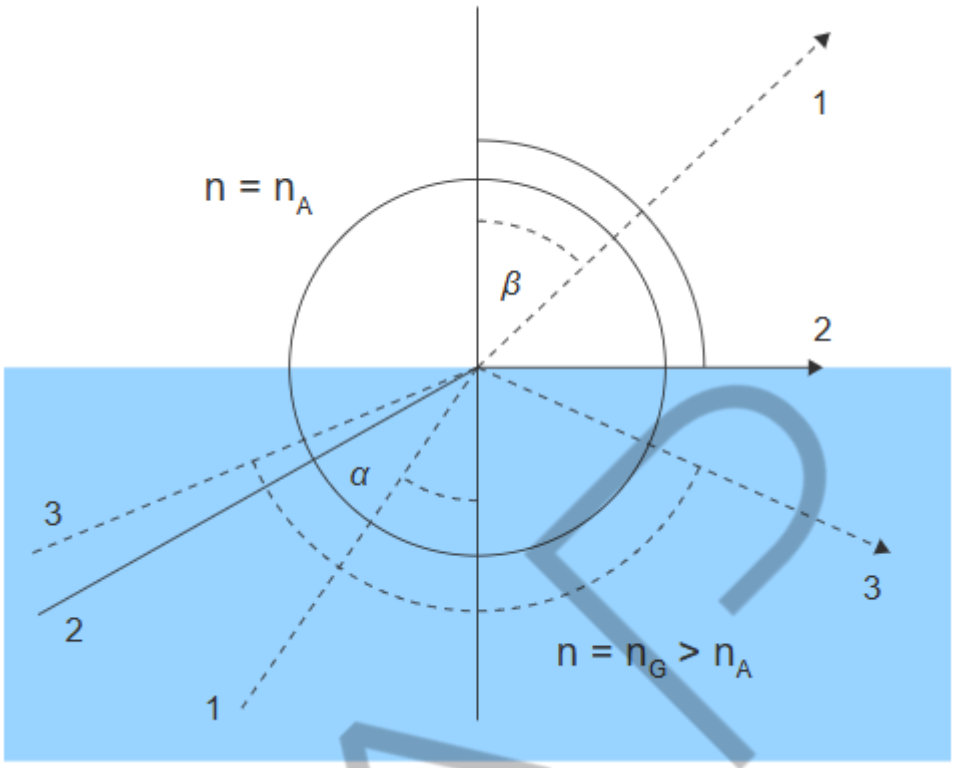


Figura 11 - Fenômeno de reflexão total
Fonte: Amiri *et al*. (2023), adaptado pelo autor (2025)

Esse princípio é fundamental para o funcionamento dessas fibras e pode ser explicado de forma simples e intuitiva: imagine um raio de luz viajando no interior de uma fibra óptica que consiste em um núcleo (parte central) envolto por uma casca (revestimento). O núcleo é fabricado com um material de maior índice de refração (n_G) do que a casca (n_A). Quando a luz atinge a interface entre esses dois materiais, parte dela pode ser refratada (transmitida para a casca) ou refletida de volta para o núcleo. A reflexão interna total ocorre quando todo o raio de luz é refletido, sem perdas por refração.

O comportamento da luz na interface entre dois meios é descrito pela Lei de Snell, veja a equação (3):

$$\frac{sin\alpha}{sin\beta} = \frac{n_2}{n_1} \qquad (3)$$

Em que:

- α = ângulo de incidência;
- β = ângulo de refração;

- n_A= índice de refração do meio A (casca);
- n_G = índice de refração do meio G (núcleo).

As fibras ópticas têm uma ampla gama de aplicações, desde telecomunicações até medicina e engenharia. Em telecomunicações, elas são utilizadas para transmitir dados em alta velocidade e com grande largura de banda, substituindo cabos de cobre tradicionais.

Na medicina, fibras ópticas são empregadas em endoscópios e lasers cirúrgicos, permitindo procedimentos minimamente invasivos. Já na engenharia, os sensores baseados em fibras ópticas são usados para monitorar tensão, temperatura e pressão em estruturas críticas, como pontes e aeronaves.

2.5 Classificação de sensores de fibra ótica

Os sensores de fibra óptica podem ser classificados de várias maneiras, dependendo do parâmetro físico medido, do sistema de detecção ou do tipo de sensor. Uma das classificações mais utilizadas divide os sensores em duas categorias principais: **intrínsecos** e **extrínsecos**. Sensores intrínsecos são aqueles em que a interação entre a luz e o parâmetro medido ocorre dentro da própria fibra óptica. Por outro lado, sensores extrínsecos utilizam a fibra apenas como um guia para a luz, enquanto a interação ocorre fora dela. Essa distinção é essencial para entender as aplicações e limitações de cada tipo de sensor.

Outra abordagem de classificação considera o tipo de modulação utilizado no sensor, como intensidade, comprimento de onda, fase ou polarização da luz. Sensores ópticos baseados em intensidade são considerados os mais simples entre as tecnologias disponíveis, pois operam com apenas uma fonte de luz e um detector para identificar variações na quantidade de luz transmitida ou refletida. Essa simplicidade, no entanto, vem acompanhada de uma limitação importante: esses sensores são altamente suscetíveis a interferências externas que afetam a intensidade da luz, como variações na fonte emissora, perdas por acoplamento ou perturbações ambientais. Essas interferências podem comprometer a precisão das medições, tornando esse tipo de sensor mais apropriado para aplicações em que tolerâncias maiores são aceitáveis.

Por outro lado, sensores baseados em comprimento de onda, como aqueles que utilizam redes de Bragg em fibra (FBG), oferecem maior robustez e confiabilidade. Eles são amplamente utilizados para monitoramento preciso de parâmetros como deformação mecânica (tensão) e temperatura, devido à sua capacidade de detectar pequenas variações espectrais provocadas por alterações físicas no meio.

Apesar de sua importância e popularidade crescente, as fibras com redes de Bragg não serão abordadas em profundidade no momento. Isso se deve ao fato de que seu funcionamento, princípios de fabricação e diversas possibilidades de aplicação exigem um tratamento mais detalhado e técnico, o que extrapolaria o escopo introdutório proposto aqui.

O objetivo deste capítulo é apresentar as bases conceituais dos sensores ópticos, com foco em suas estruturas fundamentais e nas categorias mais acessíveis do ponto de vista didático. Essa abordagem visa construir gradualmente o conhecimento necessário para que o leitor compreenda, em seções posteriores ou em materiais complementares, os sistemas mais avançados como os baseados em FBG.

Dando continuidade à exploração dos diferentes tipos de sensores ópticos, é importante destacar também os sensores de fase, que se caracterizam por sua extrema sensibilidade. Esses sensores detectam mudanças na fase da luz ao longo do percurso óptico e são utilizados em aplicações de alta precisão, como nos giroscópios de fibra óptica, onde pequenas variações angulares precisam ser medidas com grande exatidão.

Para complementar essa classificação, outra categoria relevante são os sensores de polarização, pois são capazes de detectar mudanças no estado de polarização da luz provocadas por fatores externos, como campos elétricos, magnéticos ou variações de pressão. Esses sensores encontram aplicação em ambientes industriais, sistemas de monitoramento estrutural e pesquisa científica, especialmente onde a imunidade a ruído eletromagnético é essencial.

A figura a seguir apresenta uma comparação esquemática entre sensores intrínsecos e extrínsecos. Nos sensores extrínsecos, a fibra atua como um guia para a luz, mas a interação com o parâmetro medido ocorre em um elemento externo. Já nos sensores intrínsecos, a interação ocorre diretamente dentro da fibra, tornando-os mais sensíveis e adequados para aplicações distribuídas.

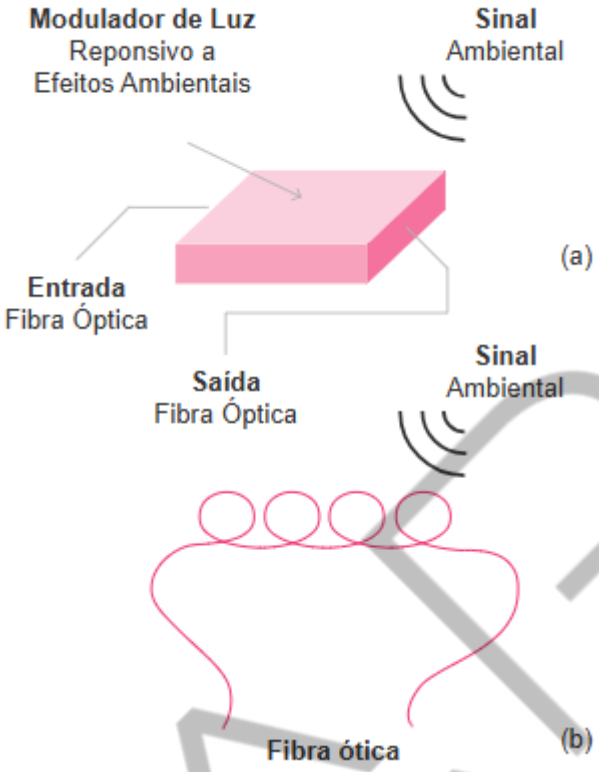


Figura 12 - Comparação entre (a) sensores extrínsecos e (b) sensores intrínsecos
Fonte: Amiri *et al.* (2023), adaptado pelo autor (2025)

3 EFICIÊNCIA ENERGÉTICA EM IOT – COMPARAÇÃO ENTRE ALGORITMOS SNN E ANN EM ARQUITETURAS VON NEUMANN

Esta seção baseia-se no artigo *Análise de Consumo de Algoritmos SNN Executados em IoT*, de Ester Porto de Freitas *et al*. O estudo investiga se a substituição de algoritmos tradicionais de Redes Neurais Artificiais (ANNs) por algoritmos de Redes Neurais Impulsionais (SNNs) pode gerar benefícios em termos de eficiência energética quando implementados em dispositivos IoT com arquitetura Von Neumann.

A relevância dessa análise está no contexto do avanço acelerado da Internet das Coisas e nos desafios energéticos impostos por sua escalabilidade. Embora os algoritmos SNN sejam considerados mais eficientes em sistemas neuromórficos dedicados, ainda é incerta a sua eficácia quando executados em plataformas computacionais convencionais.

Neste tópico, discutiremos os fundamentos que motivam essa investigação. Iniciaremos com uma exposição do problema energético associado ao crescimento da IoT, abordando as limitações da arquitetura Von Neumann nesse cenário. Em seguida, realizaremos uma comparação conceitual entre as Redes Neurais Artificiais e as Redes Neurais Impulsionais, destacando diferenças no tipo de dados, na complexidade das operações e no modelo de execução.

O objetivo é destacar que, embora os algoritmos SNN apresentem um potencial teórico de maior eficiência em operações como detecção de padrões esparsos, processamento de eventos e representações temporais discretas — típicas de sensores e sistemas neurais —, a arquitetura Von Neumann não é capaz de explorar essas vantagens de forma eficaz. Isso ocorre porque essa arquitetura impõe um modelo de execução sequencial e centralizado, que depende de um fluxo constante de dados entre memória e processador, gerando gargalos e aumentando o consumo energético.

Assim, mesmo com algoritmos mais leves e menos complexos, as características estruturais da arquitetura tradicional criam barreiras difíceis de contornar quando o objetivo é a eficiência energética em sistemas IoT. Essa constatação norteia as análises que serão apresentadas nas próximas seções, que

abordam a metodologia experimental, os resultados obtidos e as implicações desses achados para o projeto de sistemas embarcados sustentáveis.

3.1 O contexto energético da IoT e o desafio computacional

O crescimento da Internet das Coisas tem sido exponencial nas últimas décadas. Estimativas apontam que, até 2025, o número de dispositivos IoT ultrapassará a marca de 75 bilhões. Esses dispositivos estão presentes em diversas aplicações: desde sensores ambientais até sistemas inteligentes de transporte. Embora esses avanços tragam benefícios, também apresentam desafios importantes, sobretudo na área energética.

A maior parte desses dispositivos depende de arquiteturas de computação tradicionais, como a arquitetura de Von Neumann. Essa estrutura, amplamente utilizada desde meados do século XX, caracteriza-se por separar a unidade de processamento da memória, o que implica em constantes transferências de dados entre esses blocos. Esse modelo resulta em ineficiências que se tornam críticas em cenários com bilhões de dispositivos operando simultaneamente.

Cada operação computacional realizada por um dispositivo consome energia. Em microcontroladores classificados como de “muito baixo consumo”, como o ATMEGA328, o consumo médio é de aproximadamente 35 mW. Quando projetado para escalas globais, isso representa um impacto energético imenso. Com um trilhão de dispositivos em funcionamento contínuo, teríamos um consumo total de 35 gigawatts — equivalente à demanda de uma cidade inteira.

Além da questão energética direta, existem também as implicações ecológicas. Muitos dispositivos IoT funcionam com baterias que exigem metais raros como o lítio. A produção, substituição e descarte em larga escala desses componentes geram preocupações ambientais sérias, ameaçando a sustentabilidade da cadeia produtiva global de IoT.

Uma alternativa emergente à arquitetura Von Neumann é a computação neuromórfica. Inspirada no funcionamento do cérebro humano, essa abordagem promete realizar as mesmas tarefas com consumo energético significativamente menor — até mil vezes mais eficiente, segundo alguns estudos. Isso se deve ao uso

de Redes Neurais Impulsionais, que operam de forma esparsa e baseadas em eventos, reduzindo drasticamente as trocas de dados e os ciclos de processamento.

Contudo, os sistemas neuromórficos ainda são protótipos de pesquisa e não estão amplamente disponíveis em produtos comerciais. Como resultado, surge uma questão pertinente: seria possível aplicar algoritmos neuromórficos, como os SNNs, em dispositivos baseados em arquitetura Von Neumann e ainda assim colher ganhos energéticos?

Essa pergunta guiou a pesquisa analisada nesta seção. O objetivo central foi verificar, por meio de testes práticos, se a substituição de algoritmos tradicionais de redes neurais artificiais por SNNs em microcontroladores convencionais traria vantagens energéticas. Para isso, foram executados experimentos com algoritmos idênticos em topologia, porém diferentes em natureza computacional.

A expectativa inicial era de que os SNNs, por utilizarem operações mais simples e variáveis booleanas de menor tamanho (1 bit), apresentassem melhor desempenho energético. No entanto, como veremos, os resultados foram surpreendentes. Antes de apresentá-los, é necessário compreender melhor como foi estruturado o experimento e quais foram os parâmetros avaliados.

3.2 Metodologia experimental e comparação arquitetural

A avaliação experimental foi cuidadosamente projetada para garantir resultados realistas. Optou-se por testar dois tipos de algoritmos — ANN e SNN — implementados com a mesma topologia: um único neurônio com duas entradas e uma saída. Essa configuração, embora simples, é suficiente para gerar ciclos computacionais repetitivos que simulam o comportamento típico de processamento em redes neurais.

A principal diferença entre os dois algoritmos está no tipo de variável e na operação de ativação. O ANN utiliza variáveis do tipo float (32 bits) e opera com uma função não linear — a tangente hiperbólica. Já o SNN trabalha com variáveis booleanas (1 bit) e uma operação de comparação (“menor que”). Essa diferença resulta em circuitos computacionais mais simples no SNN, ao menos em teoria. Observe a figura “Estrutura da topologia das redes SNN e ANN”.

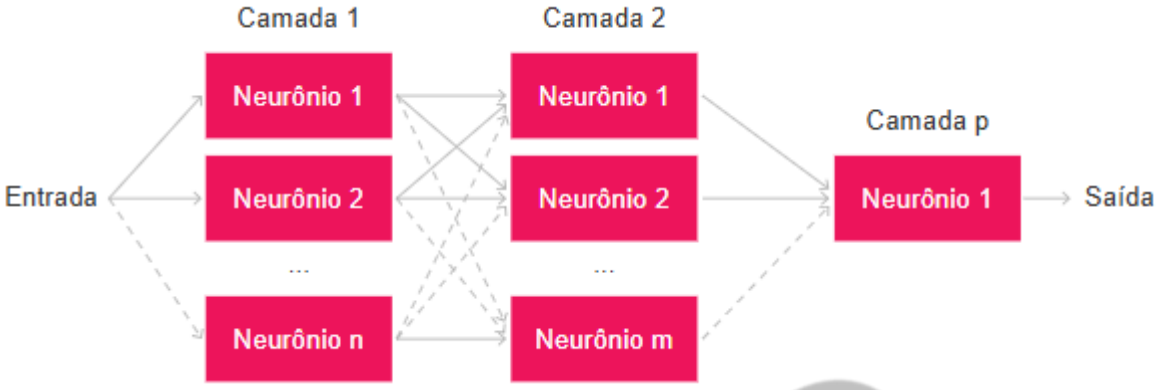


Figura 13 - Estrutura da topologia das redes SNN e ANN
Fonte: Ester Porto de Freitas *et al.* (2023), adaptado pelo autor (2025)

Dois microcontroladores foram selecionados: o ATMEGA328, de arquitetura mais antiga e comum em aplicações embarcadas, e o Tensilica Xtensa LX106, utilizado em módulos ESP e com tecnologia mais moderna de fabricação. O objetivo era também verificar se a geração de semicondutores influenciava nos resultados energéticos.

Como o laboratório utilizado para o experimento não possuía equipamentos para medir potência diretamente, a metodologia envolveu medir a corrente elétrica consumida em uma tensão contínua de 5V. A potência foi então estimada como o produto da corrente e da tensão, segundo a fórmula básica da eletricidade: P=V×IP = V \times IP=V×I.

Para garantir representatividade, foram realizadas 100 amostras de corrente para cada combinação (microcontrolador + algoritmo), com intervalo de 1 segundo entre elas. Os dados coletados foram então organizados em gráficos para facilitar a análise comparativa do consumo de corrente.

Um aspecto importante da metodologia foi considerar o ciclo de execução em dispositivos Von Neumann. Nessa arquitetura, cada instrução é processada de forma sequencial. Isso implica que, mesmo operações simples, se executadas repetidamente, podem gerar consumo considerável devido ao tráfego de dados entre a memória e a CPU.

Adicionalmente, os algoritmos foram configurados para operar em loop contínuo, simulando uma situação real onde o dispositivo IoT precisa processar dados o tempo todo — como ocorre em sensores ambientais ou sistemas de monitoramento.

A escolha de manter o número de operações e a estrutura algorítmica semelhante nos dois casos teve o intuito de isolar o fator “tipo de rede” (SNN *versus* ANN), tornando os resultados mais comparáveis. Isso é essencial para concluir se o tipo de algoritmo por si só pode influenciar no consumo de energia, independentemente do hardware.

Os resultados dessa metodologia foram apresentados na forma de gráficos de corrente média ao longo do tempo, permitindo uma visualização clara das diferenças de consumo entre os algoritmos e os dispositivos testados.

3.3 Resultados obtidos e análise crítica

Os resultados experimentais obtidos por Freitas *et al*. revelaram um comportamento inesperado e, ao mesmo tempo, bastante revelador sobre a relação entre algoritmos e arquitetura de hardware. Ao comparar o consumo de energia entre algoritmos SNN e ANN executados em dois microcontroladores de baixo consumo — o ATMEGA328 e o Tensilica Xtensa LX106 —, verificou-se que, contrariando as expectativas iniciais, os algoritmos SNN apresentaram um consumo de corrente ligeiramente maior do que os algoritmos ANN em ambos os dispositivos.

Essa conclusão foi alcançada por meio de medições precisas de corrente elétrica durante a execução dos algoritmos. A tensão de alimentação foi fixada em 5V, e a corrente foi monitorada com um multímetro digital de alta sensibilidade. A partir da relação P = V×I é possível estimar a potência instantânea consumida pelo sistema, considerando que, para uma tensão fixa, variações no consumo de corrente refletem diretamente em variações no consumo de energia.

Visualmente, os gráficos da figura “Consumo de corrente dos microcontroladores ATMEGA328 e Tensilica Xtensa LX106” revelam que a curva de corrente associada ao algoritmo SNN apresenta uma média ligeiramente superior à do algoritmo ANN ao longo dos 100 segundos de amostragem. Essa diferença, embora não dramática, é consistente entre os dois dispositivos analisados, o que confere maior confiabilidade aos resultados.

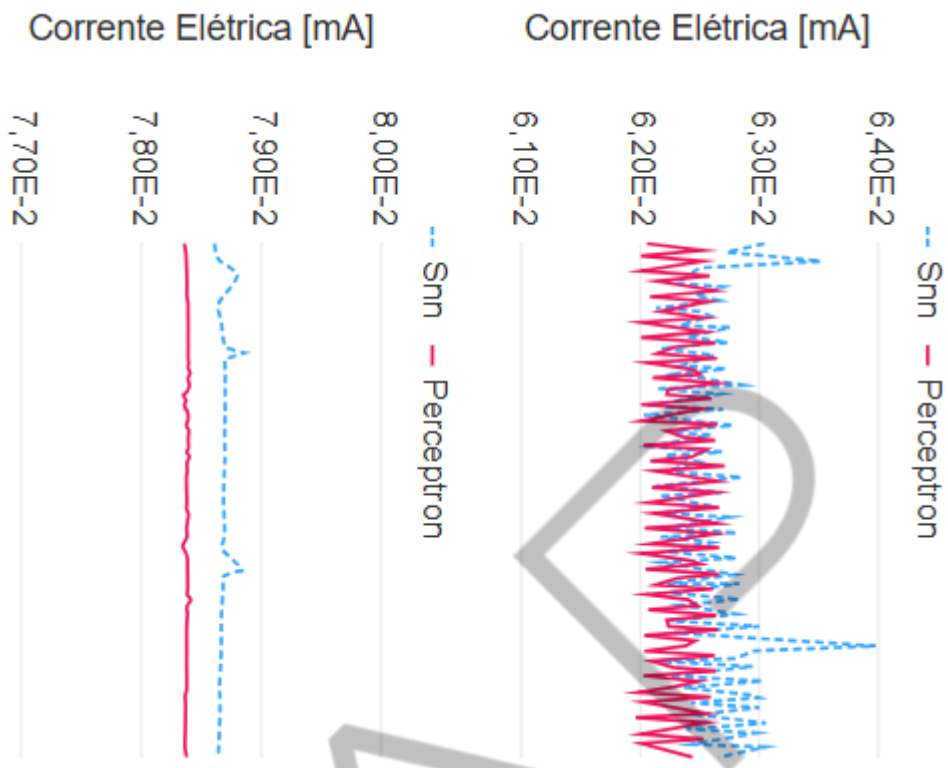


Figura 14 - Consumo de corrente dos microcontroladores ATMEGA328 e Tensilica Xtensa LX106
Fonte: Ester Porto de Freitas *et al.* (2023), adaptado pelo autor (2025)

Esse comportamento levanta um ponto técnico crucial: a eficiência de um algoritmo depende não apenas da sua complexidade algorítmica, mas também da compatibilidade com a arquitetura subjacente. Os SNNs são concebidos para funcionar em arquiteturas paralelas, esparsas e orientadas a eventos, como nos processadores neuromórficos. Já a arquitetura Von Neumann é sequencial por natureza: cada instrução é executada uma de cada vez, exigindo constante troca de dados entre a memória e a CPU.

Essa troca de dados se torna ainda mais crítica quando se trabalha com operações booleanas, como no caso dos SNNs. Apesar de utilizarem variáveis pequenas (1 bit), essas variáveis exigem checagens frequentes de estado. Esse comportamento pode desencadear ciclos contínuos de *polling*, nos quais o processador verifica repetidamente a ocorrência de eventos. Paradoxalmente, isso pode consumir mais energia do que simplesmente executar funções matemáticas mais pesadas, porém otimizadas — como a tangente hiperbólica utilizada nos ANNs.

Outro aspecto relevante está no suporte de hardware. Muitos microcontroladores modernos contam com unidades de ponto flutuante integradas (FPU), que aceleram e otimizam o processamento de operações matemáticas típicas

de algoritmos ANN. Isso significa que, na prática, a execução de uma função como a tangente hiperbólica pode ser muito mais eficiente energeticamente do que se imagina, justamente por contar com circuitos dedicados. Por outro lado, as comparações lógicas simples utilizadas nos SNNs não necessariamente se beneficiam de otimizações semelhantes, o que pode levar a ciclos de processamento mais longos e, portanto, maior consumo.

Ao analisar especificamente o comportamento dos dois microcontroladores utilizados no estudo, observou-se que mesmo o Tensilica Xtensa LX106, com tecnologia de fabricação mais recente e supostamente mais eficiente, não conseguiu apresentar ganhos energéticos com a execução dos algoritmos SNN. Isso reforça a ideia de que o problema não está no algoritmo em si, mas sim na incompatibilidade estrutural entre a lógica dos SNNs e a organização sequencial da arquitetura Von Neumann.

Essa constatação evidencia um conceito importante na engenharia de sistemas embarcados: a necessidade de co-projeto entre hardware e software. Em outras palavras, a escolha de algoritmos deve considerar o tipo de arquitetura em que serão executados, sob pena de inviabilizar ganhos de desempenho ou eficiência energética. No caso dos SNNs, o uso fora de arquiteturas neuromórficas especializadas pode não apenas anular seus benefícios, mas inclusive comprometer o consumo de energia total do sistema.

Adicionalmente, os resultados obtidos demonstram que a simplificação algorítmica não garante, por si só, menor consumo energético. A eficiência de um sistema computacional está ligada ao custo total da execução, incluindo número de instruções, acesso à memória, tempo de processamento e uso de blocos especializados do hardware. Em alguns casos, um algoritmo mais complexo matematicamente pode ser mais eficiente, desde que esteja melhor integrado à infraestrutura computacional disponível.

Esse tipo de análise é especialmente importante quando se busca escalabilidade em projetos de IoT. Se considerarmos a implantação de bilhões de dispositivos, mesmo pequenas ineficiências em consumo energético por dispositivo podem se traduzir em impactos ambientais e econômicos significativos. Por isso, a escolha de algoritmos deve ser guiada não apenas por sua simplicidade ou inspiração biológica, mas pela sua aderência ao perfil da plataforma computacional utilizada.

Assim, a análise crítica dos gráficos de consumo deixa uma mensagem clara: em dispositivos IoT com arquitetura Von Neumann, os algoritmos SNN não demonstraram vantagem energética frente aos ANNs. Pelo contrário, apresentaram desempenho inferior nesse aspecto. Isso ressalta a importância de cautela ao tentar transplantar soluções de um paradigma computacional (neuromórfico) para outro (Von Neumann), sem as devidas adaptações ou infraestrutura compatível.

Portanto, os resultados aqui discutidos não apenas contrariam a hipótese inicial do estudo, mas também trazem uma lição valiosa sobre o papel das arquiteturas de hardware na eficiência energética dos sistemas embarcados. O uso de SNNs só será vantajoso se acompanhado por mudanças estruturais no design computacional, como ocorre em processadores neuromórficos especializados.

Este estudo oferece uma contribuição relevante para o campo da engenharia de sistemas embarcados e para o desenvolvimento sustentável da IoT. A ideia de que algoritmos mais simples e inspirados no cérebro humano resultariam automaticamente em menor consumo energético mostrou-se, na prática, equivocada — ao menos em arquiteturas computacionais convencionais.

Essa constatação não invalida o potencial dos SNNs, mas ressalta a importância do contexto em que são aplicados. Em sistemas neuromórficos dedicados, os SNNs continuam sendo uma opção promissora para alcançar eficiências energéticas superiores. No entanto, a simples migração desses algoritmos para plataformas Von Neumann não é suficiente.

Do ponto de vista de design de sistemas, os resultados indicam que qualquer tentativa de otimização energética deve considerar a sinergia entre o algoritmo e a arquitetura de hardware. Uma abordagem promissora pode ser o desenvolvimento de microcontroladores híbridos, que integrem núcleos neuromórficos junto com núcleos tradicionais, possibilitando o melhor dos dois mundos.

Além disso, futuras pesquisas devem expandir o escopo do experimento para tarefas mais complexas. Avaliar o desempenho de SNNs e ANNs em aplicações como reconhecimento de padrões, navegação autônoma e análise de séries temporais pode trazer novos insights e revelar cenários onde os SNNs possam se destacar mesmo em plataformas tradicionais.

Outro ponto a ser considerado é a evolução das tecnologias de semicondutores. Com a miniaturização dos transistores e o avanço das técnicas de fabricação, é possível que novas gerações de microcontroladores passem a incluir suporte nativo para operações baseadas em eventos, favorecendo os SNNs mesmo fora de contextos neuromórficos puros.

Por fim, do ponto de vista da sustentabilidade, o estudo reforça a importância de decisões embasadas em evidências reais e medições concretas. A eficiência energética não deve ser apenas um objetivo teórico, mas um critério prático e mensurável no projeto de sistemas embarcados.

Como recomendação geral, desenvolvedores e pesquisadores devem ser cautelosos ao adotar soluções inspiradas em modelos biológicos. Embora promissoras, essas soluções requerem plataformas compatíveis e experimentação rigorosa antes de serem aplicadas em larga escala.

REFERÊNCIAS

AKOPYAN, Filipp *et al.* TrueNorth: Design and Tool Flow of a 65 mW 1 Million Neuron Programmable Neurosynaptic Chip. **IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems**, v. 34, n. 10, p. 1537–1557, out. 2015. Dispnível em: <https://ieeexplore.ieee.org/document/7229264>. Acesso em: 22 ago. 2025.

VALOV, I. Interfacial interactions and their impact on redox-based resistive switching memories (ReRAMs). **Semiconductor Science and Technology**, v. 32, n. 9, p. 093006, 2017.

AMIRI, Iraj Sadegh *et al.* Introduction to Photonics: Principles and the Most Recent Applications of Microstructures. **Micromachines**, v. 9, n. 9, p. 452, 2018. Disponível em: <https://www.mdpi.com/2072-666X/9/9/452>. Acesso em: 22 ago. 2025.

FREITAS, Ester Porto de *et al*. Análise de Consumo de Algoritmos SNN Executados em IoT. **Anais do Encontro Nacional de Engenharia de Produção – Enegep**, 2023. Disponível em: <https://www.abepro.org.br/publicacoes/artigo.asp?e=enegep&a=2023&c=45744>. Acesso em: 22 ago. 2025.

INTEL CORPORATION. **Intel builds world's largest neuromorphic system to enable more sustainable AI**. 2021b. Disponível em: <https://newsroom.intel.com/artificial-intelligence/intel-builds-worlds-largest-neuromorphic-system-to-enable-more-sustainable-ai>. Acesso em: 22 ago. 2025.

INTEL CORPORATION. **Taking neuromorphic computing to the next level with Loihi 2: Technology brief**. [*S.l.*]: Intel Labs, 2021a. Disponível em: <https://www.intel.com/content/www/us/en/research/neuromorphic-community.html>. Acesso em: 22 ago. 2025.

ROY, K.; JAISWAL, A.; PANDA, P. Towards spike-based machine intelligence with neuromorphic computing. **Nature**, v. 575, p. 607-617, 28 nov. 2019. Disponível em: https://www.nature.com/articles/s41586-019-1677-2. Acesso em: 26 ago. 2025.

YADAV, Pamul; MISHRA, Ashutosh; KIM, Shiho. Neuromorphic Hardware Accelerators. *In*: MISHRA, Ashutosh; CHOI, Jaeyoung; KIM, Shiho (Ed.). **Artificial Intelligence and Hardware Accelerators**. Cham: Springer, 2023. p. 225–268. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-031-22170-5_8>. Acesso em: 22 ago. 2025.